

Ide Implementasi Tahap 2 — Ekstraksi Entitas Klinis dari Teks Panjang

1. Tujuan

Tahap 2 bertujuan mengubah teks hasil normalisasi Bahasa Indonesia menjadi sekumpulan entitas klinis terstruktur. Satu dokumen dapat menghasilkan banyak entitas, seperti:

- diagnosis dan penyakit;
- gejala atau keluhan;
- temuan klinis;
- pemeriksaan laboratorium;
- tanda vital;
- obat dan suplemen;
- prosedur atau tindakan;
- anatomi;
- nilai dan satuan;
- konteks kunjungan;
- negasi, ketidakpastian, temporalitas, dan experiencer.

Output Tahap 2 menjadi masukan bagi:

1. Tahap 3 — pemilihan domain dan terminologi target;
2. Tahap 4 — query decomposition;
3. Tahap 5 — retrieval kandidat konsep.

2. Dasar Data Tahap 1

Sumber input:

```
Riset/crawler_alodokter/hasil_normalisasi_tahap_1.jsonl
```

Ringkasan 150 pasangan konsultasi:

Karakteristik	Question	Answer
Record tidak kosong	150	150
Rata-rata kata	53,1	200,3
Maksimum kata	173	862
Rata-rata kalimat	3,9	16,1
Maksimum kalimat	16	57
Penanda negasi	142	424

Karakteristik	Question	Answer
Penanda ketidakpastian	3	146
Penanda temporal	181	308
Nilai dan satuan klinis	15	43
Penanda rekomendasi	3	117

Implikasi:

- `question.normalized_text` terutama berisi fakta, keluhan, riwayat, dan kekhawatiran pasien;
- `answer.normalized_text` banyak memuat diagnosis banding, kemungkinan, edukasi, contoh hipotetis, dan rekomendasi;
- pertanyaan dan jawaban tidak boleh digabung menjadi satu dokumen;
- setiap entitas harus memiliki provenance, speaker, assertion, temporal, dan experiencer.

3. Acuan Library dan Algoritma

Mengacu pada `Panduan_Komponen_NLP_Formatted.xlsx` baris 13–21.

3.1 Medical LLM/NER

Contoh pada panduan:

- Numind/John Snow Labs Medical NER;
- model medis yang dapat menghasilkan entitas klinis terstruktur.

Rencana penggunaan:

- baseline pembandingan entity-span extraction;
- anggota ensemble setelah baseline Bahasa Indonesia stabil;
- bukan ekstraktor utama sebelum performa lintas bahasa dan lisensinya dievaluasi.

Risiko:

- model yang dirujuk berorientasi bahasa Inggris;
- data Alodokter informal dan berbahasa Indonesia;
- komponen klinis tertentu memerlukan lisensi.

3.2 Prompt Engineering

Gunakan instruksi yang eksplisit untuk:

- entity span;
- base entity;
- entity type dan domain;
- nilai dan unit;
- obat, dosis, frekuensi, dan route;
- assertion;

- temporal;
- experiencer;
- sumber dan evidence.

3.3 Few-shot Learning

Buat contoh terpisah untuk:

- pertanyaan pasien;
- jawaban dokter;
- negasi;
- diagnosis banding;
- riwayat keluarga;
- obat dan dosis;
- laboratorium dan tanda vital;
- rekomendasi;
- informasi medis umum.

3.4 Spark NLP Contextual Assertion

Potensial sebagai pembanding untuk:

- negasi;
- ketidakpastian;
- temporalitas.

Sebelum digunakan, evaluasi:

- dukungan Bahasa Indonesia;
- lisensi;
- kebutuhan model klinis;
- performa pada teks konsultasi informal.

3.5 Custom Rule-based

Gunakan sebagai:

- fallback jika LLM gagal;
- validasi output LLM;
- deteksi angka dan satuan;
- negasi;
- temporal expression;
- dosis dan frekuensi;
- tekanan darah;
- umur dan durasi.

3.6 JSON Mode dan Pydantic

JSON mode digunakan jika model/provider mendukung structured output. Hasil tetap harus divalidasi menggunakan Pydantic karena JSON valid belum menjamin:

- mention benar-benar terdapat dalam teks;
- offset benar;
- entity type sesuai;
- assertion dan temporal benar;
- nilai dan unit konsisten.

4. Arsitektur Awal yang Direkomendasikan

```
Output Tahap 1
  ↓
Adapter question/answer
  ↓
Sentence window atau semantic chunk
  ↓
LLM + prompt few-shot + JSON mode
  ↓
Pydantic schema validation
  ↓
Rule-based assertion, temporal, value, dan unit
  ↓
Deduplikasi dan konsolidasi
  ↓
Confidence dan provenance
  ↓
Adapter ke Tahap 3 dan Tahap 4
```

Untuk implementasi versi pertama:

```
Together AI/LLM
+ few-shot Bahasa Indonesia
+ JSON mode
+ Pydantic
+ rule-based validation
```

Medical NER dan Spark NLP ditambahkan sebagai pembanding atau anggota ensemble setelah baseline stabil.

5. Langkah Implementasi

Langkah 1 — Tetapkan kontrak input

Bentuk dua dokumen berbeda dari setiap record.

Pertanyaan:

```
{
  "document_id": "record-id-question",
  "parent_record_id": "record-id",
  "source_field": "question",
  "speaker": "patient",
  "normalized_text": "...",
  "sentences": []
}
```

Jawaban:

```
{
  "document_id": "record-id-answer",
  "parent_record_id": "record-id",
  "source_field": "answer",
  "speaker": "doctor",
  "normalized_text": "...",
  "sentences": []
}
```

Prioritas awal adalah `question.normalized_text`. Jawaban dokter diproses dalam eksperimen terpisah.

Langkah 2 — Tetapkan kebijakan sumber

Sumber	Interpretasi
Pertanyaan pasien	Fakta, keluhan, riwayat, obat, dan hasil pasien
Jawaban dokter	Hipotesis, diagnosis banding, rekomendasi, atau informasi umum
Judul	Metadata pendukung
Boilerplate	Tidak diproses sebagai fakta klinis

Entitas pada jawaban dokter tidak boleh otomatis dianggap sebagai kondisi pasien.

Langkah 3 — Definisikan taksonomi entitas

Taksonomi awal:

- `condition`;
- `symptom`;
- `clinical_finding`;
- `measurement`;
- `drug`;
- `procedure`;
- `anatomy`;
- `unit`;
- `demographic`;

- `visit`;
- `other`.

Tahap 2 hanya memberikan domain awal. Pemilihan vocabulary target dilakukan pada Tahap 3.

Langkah 4 — Definisikan skema JSON

```
{
  "document_id": "string",
  "entities": [
    {
      "entity_id": "string",
      "mention": "string",
      "normalized_mention": "string",
      "base_entity": "string",
      "entity_type":
"condition|symptom|clinical_finding|measurement|drug|procedure|anatomy|unit|demogr
aphic|visit|other",
      "domain": "condition|measurement|observation|drug|procedure|unit|visit|all",
      "associated_entities": [],
      "categories": [],
      "value": null,
      "unit": null,
      "dose": null,
      "frequency": null,
      "route": null,
      "method": null,
      "visit": null,
      "assertion": "present|negated|uncertain|hypothetical",
      "temporal": "present|past|future|unknown",
      "temporal_expression": null,
      "experiencer": "patient|family|other|unknown",
      "source_field": "question|answer",
      "speaker": "patient|doctor",
      "sentence_id": 0,
      "start_char": 0,
      "end_char": 10,
      "evidence": "string",
      "confidence": 0.0
    }
  ]
}
```

Field wajib untuk audit:

- `mention`;
- `sentence_id`;
- `start_char`;
- `end_char`;
- `evidence`;
- `source_field`;

- *speaker*;
- *experiencer*.

Langkah 5 — Siapkan chunking

Strategi:

- pertanyaan pendek diproses sebagai teks utuh;
- pertanyaan panjang menggunakan window beberapa kalimat;
- jawaban pendek diproses sebagai teks utuh;
- jawaban panjang dipotong berdasarkan kelompok kalimat;
- gunakan overlap satu kalimat;
- pertahankan sentence ID dan offset asli;
- evaluasi semantic segmentation untuk dokumen panjang.

Langkah 6 — Susun pedoman anotasi

Pedoman harus menjelaskan:

- batas entity span;
- span terpanjang atau span minimal;
- penyakit dan subtype;
- perbedaan gejala, diagnosis, dan temuan;
- merek dan zat aktif obat;
- nilai dan unit;
- negasi;
- ketidakpastian;
- temporalitas;
- riwayat keluarga;
- kondisi hipotetis;
- rekomendasi;
- informasi umum dokter.

Contoh:

"tidak mengalami demam"

```
mention      = demam
assertion    = negated
temporal     = present
experiencer  = patient
```

"ibu saya menderita diabetes"

mention = diabetes
assertion = present
experiencer = family

Langkah 7 — Bangun gold set

Ambil sampel terstratifikasi:

- pertanyaan pendek dan panjang;
- banyak entitas;
- obat dan dosis;
- laboratorium;
- tanda vital;
- negasi;
- temporalitas;
- riwayat keluarga;
- diagnosis banding;
- jawaban panjang;
- rekomendasi.

Tahap awal:

- 30–50 pasangan;
- dua anotator;
- adjudikasi tenaga klinis;
- hitung inter-annotator agreement.

Langkah 8 — Rancang prompt utama

Prompt harus memerintahkan model:

1. hanya mengekstrak entitas yang tertulis;
2. tidak menambahkan diagnosis baru;
3. mempertahankan mention persis;
4. membedakan fakta pasien dari hipotesis dokter;
5. memberi entity type dan domain awal;
6. mengekstrak nilai, unit, dosis, frekuensi, dan route;
7. menandai assertion, temporal, dan experiencer;
8. menyertakan evidence;
9. mengembalikan array kosong jika tidak ada entitas;
10. hanya mengeluarkan JSON sesuai skema.

Langkah 9 — Buat few-shot pertanyaan

Contoh harus mencakup:

- keluhan multipel;
- riwayat penyakit;
- obat dan dosis;
- laboratorium;
- tanda vital;
- negasi;
- durasi;
- kondisi keluarga.

Langkah 10 — Buat few-shot jawaban

Contoh harus mencakup:

- diagnosis banding;
- kemungkinan penyebab;
- informasi umum;
- rekomendasi pemeriksaan;
- tindakan yang disarankan;
- kondisi hipotetis;
- red flags;
- larangan menganggap semua entitas sebagai fakta pasien.

Langkah 11 — Ekstraksi dua tahap

Tahap A — Entity span detection

Temukan mention klinis dalam teks.

Contoh:

```
pinggul  
ngilu  
perut  
bahu  
sikut  
infeksi saluran kemih  
ciflos  
500 mg
```

Tahap B — Attribute extraction

Untuk setiap mention, tentukan:

- normalized mention;
- base entity;
- entity type;
- domain;
- nilai dan unit;

- associated entity;
- assertion;
- temporal;
- experiencer;
- evidence;
- confidence.

Langkah 12 — Tambahkan rule-based extractor

Aturan awal:

```
tidak|tanpa|bukan|belum  
→ kandidat negasi  
  
mungkin|kemungkinan|diduga|bisa jadi  
→ uncertain  
  
sejak|selama|dulu|sebelumnya|saat ini  
→ temporal expression  
  
mg|ml|kg|cm|mmHg|mg/dL|g/dL|%  
→ unit
```

Tambahkan aturan untuk:

- tekanan darah;
- dosis;
- frekuensi;
- durasi;
- umur;
- nilai laboratorium.

Rule digunakan untuk validasi atau warning, bukan selalu menimpa LLM.

Langkah 13 — Tangani assertion

Assertion minimal:

- **present**;
- **negated**;
- **uncertain**;
- **hypothetical**.

Untuk jawaban dokter, tambahkan **epistemic_status**:

- **general_information**;
- **differential_diagnosis**;
- **recommended**;
- **conditional**;

- `patient_fact`.

Langkah 14 — Tangani temporal dan experiencer

Contoh:

```
"sejak dua hari lalu"  
→ temporal: present  
→ temporal_expression: sejak dua hari lalu  
  
"dulu pernah mengalami"  
→ temporal: past  
  
"jika nanti muncul demam"  
→ temporal: future  
→ assertion: hypothetical  
  
"ibu saya menderita DM"  
→ experiencer: family
```

Langkah 15 — Validasi dengan Pydantic

Validasi:

- semua field wajib tersedia;
- enum valid;
- offset berada dalam batas teks;
- `mention` cocok dengan substring;
- entity ID unik;
- nilai dan unit konsisten;
- confidence berada pada rentang yang ditentukan;
- tidak ada teks naratif di luar JSON.

Jika gagal:

1. lakukan satu kali repair/retry;
2. jika masih gagal, jalankan fallback rule-based;
3. simpan raw output, error, dan warning.

Langkah 16 — Deduplikasi

Gabungkan entitas berdasarkan:

- overlap span;
- normalized mention;
- sentence ID;
- entity type;
- assertion;
- experiencer.

Jangan menggabungkan:

```
pasien tidak demam
ibu pasien mengalami demam
```

karena assertion dan experiencer berbeda.

Langkah 17 — Confidence dan provenance

Sinyal confidence:

- mention ditemukan pada teks;
- offset valid;
- kesepakatan LLM dan rule;
- konsistensi domain;
- konsistensi nilai dan unit;
- kesepakatan antar-ekstraktor;
- JSON valid;
- evidence tersedia.

Metadata:

```
extraction_method
model_name
model_version
prompt_version
rule_version
processing_time
```

Langkah 18 — Adapter ke Tahap 3 dan 4

Satu dokumen diubah menjadi beberapa query:

```
document
├─ entity 1 → query mapping
├─ entity 2 → query mapping
└─ entity 3 → query mapping
```

Pertahankan:

- parent record ID;
- source field;
- speaker;
- mention;
- normalized mention;

- base entity;
- domain;
- unit;
- assertion;
- temporal;
- experiencer;
- evidence.

Langkah 19 — Simpan audit artifact

```
{
  "document_id": "...",
  "input_text": "...",
  "chunks": [],
  "raw_model_output": {},
  "validated_entities": [],
  "rule_findings": [],
  "warnings": [],
  "errors": [],
  "model_name": "...",
  "prompt_version": "...",
  "processing_time": 0.0
}
```

6. Evaluasi

6.1 Entity extraction

- strict span precision;
- strict span recall;
- strict span F1;
- relaxed/overlap span F1;
- entity-type macro-F1;
- hallucination rate;
- missed-entity rate.

6.2 Attribute extraction

- base-entity accuracy;
- domain accuracy;
- value-unit accuracy;
- assertion macro-F1;
- temporal accuracy;
- experiencer accuracy;
- epistemic-status accuracy.

6.3 Keandalan sistem

- JSON-validity rate;
- Pydantic pass rate;
- fallback rate;
- duplicate rate;
- coverage;
- latency per dokumen;
- biaya per dokumen.

7. Ablation Study

Bandingkan:

1. LLM zero-shot;
 2. LLM + few-shot;
 3. LLM + rule negasi/temporal;
 4. LLM + rule + Pydantic;
 5. Medical NER saja;
 6. rule-based saja;
 7. ensemble LLM + Medical NER + rule;
 8. pertanyaan saja;
 9. pertanyaan dan jawaban diproses terpisah;
 10. tanpa chunking;
 11. sentence-window chunking;
 12. semantic segmentation.
-

8. Risiko dan Mitigasi

Risiko	Mitigasi
LLM menambahkan diagnosis	Wajib evidence dan mention-offset
Hipotesis dokter dianggap fakta pasien	Speaker, source field, dan epistemic status
Negasi salah cakupan	Rule window + validasi LLM
Entitas terpotong pada chunk	Overlap satu kalimat
Duplikasi antar-chunk	Span-aware deduplication
Model medis tidak mendukung Indonesia	Jadikan baseline pembanding
JSON rusak	JSON mode, Pydantic, retry, fallback
Nama obat salah dikenali	Protected lexicon dan validasi kamus obat
Biaya LLM tinggi	Chunk selektif dan cache
Gold set tidak konsisten	Pedoman anotasi dan adjudikasi klinis

9. Urutan Implementasi Praktis

1. Kontrak input question/answer
2. Skema entitas dan Pydantic
3. Pedoman anotasi
4. Gold set kecil
5. Prompt zero-shot
6. Prompt few-shot
7. Entity span extraction
8. Attribute extraction
9. Assertion, temporal, experiencer
10. Rule-based validation
11. JSON retry dan fallback
12. Deduplikasi
13. Confidence dan provenance
14. Adapter ke Tahap 3/4
15. Evaluasi
16. Ablation study

10. Keluaran Tahap 2

- modul ekstraksi entitas klinis;
- model Pydantic;
- adapter input Tahap 1;
- prompt Bahasa Indonesia;
- few-shot examples;
- rules negasi, temporal, value, dan unit;
- gold set;
- output JSON multi-entitas;
- audit artifact;
- adapter menuju Tahap 3 dan Tahap 4;
- laporan evaluasi;
- laporan error analysis dan ablation study.

11. Definisi Selesai

Tahap 2 dinyatakan selesai apabila:

- input question dan answer dipisahkan;
- multi-entitas dapat diekstrak;
- setiap entitas mempunyai mention dan evidence;
- offset mention valid;
- entity type dan domain tersedia;
- assertion, temporal, dan experiencer tersedia;
- output selalu lolos validasi atau masuk fallback;
- provenance model, prompt, dan rule tersimpan;
- tersedia adapter ke Tahap 3 dan Tahap 4;
- gold set dan metrik evaluasi tersedia;

- hasil error analysis terdokumentasi.

12. Kesimpulan

Output Tahap 1 sudah cukup untuk memulai Tahap 2. Implementasi awal yang paling sesuai adalah kombinasi:

```
LLM Bahasa Indonesia
+ prompt few-shot
+ JSON mode
+ Pydantic validation
+ custom rule-based
```

Prioritas utama bukan memilih model paling kompleks, tetapi memastikan:

- fakta pasien terpisah dari hipotesis dokter;
- setiap entitas memiliki evidence dan provenance;
- negasi, ketidakpastian, temporalitas, dan experiencer ditangani;
- output konsisten dan dapat diaudit;
- evaluasi dilakukan terhadap gold set yang disepakati.