

Panduan Anotasi Gold Set dengan INCEpTION dan doccano

1. Tujuan

Panduan ini menjelaskan cara menganotasi sampel Checkpoint 3 menggunakan INCEpTION atau doccano. Target akhirnya adalah dua hasil anotasi independen:

```
stage2_annotator_a.jsonl
stage2_annotator_b.jsonl
```

Setelah keduanya selesai, hasil dibandingkan, disagreement diadjudikasi oleh tenaga klinis, lalu dibekukan sebagai:

```
stage2_gold_v1.jsonl
```

Sumber tugas terdapat pada:

```
stage2_annotation_tasks.jsonl
```

Setiap tugas memuat pasangan **question** dan **answer**. Keduanya harus dianotasi sebagai dokumen terpisah karena mempunyai **source_field**, **speaker**, assertion, dan epistemic status yang dapat berbeda.

Pedoman label utama tetap:

```
../checkpoint_02/stage2_annotation_guideline.md
```

Dokumentasi alat:

- [INCEpTION User Guide](#)
- [doccano Get Started](#)
- [doccano NER Tutorial](#)

2. Prinsip wajib

1. Anotator A dan B bekerja secara independen.
2. Anotator tidak boleh melihat hasil anotator lain sebelum audit.
3. Teks yang dianotasi adalah **normalized_text**, bukan **raw_text**.
4. **mention** harus sama persis dengan substring teks.
5. Offset menggunakan interval half-open [**start_char**, **end_char**).

6. Kata pada posisi `end_char` tidak termasuk span.
7. Jangan menyimpulkan diagnosis yang tidak tertulis.
8. Question dan answer tidak boleh digabung menjadi satu teks tanpa penanda.
9. Entitas pada jawaban dokter tidak otomatis merupakan fakta pasien.
10. Label strata seperti `negation`, `long_answer`, atau `drug_or_dose` bukan label anotasi.
11. Jika informasi tidak tersedia, gunakan `null`, `unknown`, atau array kosong sesuai skema; jangan menebak.
12. Kasus ambigu dicatat dalam `notes` untuk adjudikasi.

Validasi offset:

```
normalized_text[start_char:end_char] == mention
```

3. Data label

3.1 Entity type

Label	Digunakan untuk	Contoh
<code>condition</code>	Diagnosis atau penyakit	diabetes melitus, hipertensi
<code>symptom</code>	Keluhan yang dirasakan	demam, batuk, nyeri dada
<code>clinical_finding</code>	Temuan klinis non-diagnosis	benjolan merah, ruam
<code>measurement</code>	Pemeriksaan yang menghasilkan nilai	tekanan darah, gula darah
<code>drug</code>	Obat, suplemen, zat aktif, atau produk farmakologis	parasetamol, vitamin D
<code>procedure</code>	Pemeriksaan atau tindakan	ultrasonografi, operasi
<code>anatomy</code>	Bagian tubuh	perut, dada, kulit
<code>demographic</code>	Karakteristik pasien	perempuan, usia 33 tahun, kehamilan
<code>unit</code>	Satuan pengukuran	mg, mmHg, kg
<code>visit</code>	Konteks kunjungan	kontrol, rawat jalan
<code>other</code>	Mention klinis yang tidak masuk tipe lain	wajib ditinjau saat adjudikasi

3.2 Domain

Nilai yang diperbolehkan:

```
condition
measurement
observation
drug
```

```

procedure
unit
visit
all

```

Pemetaan awal:

Entity type	Domain awal
condition	condition
symptom	condition atau observation, sesuai pedoman proyek
clinical_finding	observation
measurement	measurement
drug	drug
procedure	procedure
anatomy	observation
demographic	observation
unit	unit
visit	visit
other	all

3.3 Assertion

Label	Makna	Contoh
present	Entitas dinyatakan ada/terjadi	"saya demam"
negated	Entitas disangkal	"saya tidak demam"
uncertain	Entitas mungkin atau belum pasti	"mungkin infeksi"
hypothetical	Entitas bersifat syarat/skenario	"jika demam muncul"

3.4 Temporal

Label	Makna	Contoh
present	Sedang atau masih terjadi	"masih terasa sekarang"
past	Terjadi pada masa lalu	"pernah demam kemarin"
future	Direncanakan/akan terjadi	"akan diperiksa besok"
unknown	Waktu tidak dapat ditentukan	"memiliki diabetes" tanpa konteks waktu jelas

Ekspresi waktu literal disimpan pada **temporal_expression**, misalnya "sejak dua hari" atau "kemarin".

3.5 Experienter

Label	Makna	Contoh
patient	Dialami penanya/pasien	"saya demam"
family	Dialami anggota keluarga	"ibu saya diabetes"
other	Dialami orang lain non-keluarga	"teman saya batuk"
unknown	Pemilik kondisi tidak dapat ditentukan	pernyataan tanpa subjek jelas

3.6 Epistemic status

Label	Makna	Contoh
patient_fact	Fakta yang dilaporkan pasien	"saya minum parasetamol"
differential_diagnosis	Kandidat diagnosis	"dapat disebabkan penyakit jantung"
general_information	Informasi medis umum	"vaksin memicu pembentukan antibodi"
recommended	Rekomendasi dokter	"sebaiknya lakukan pemeriksaan darah"
conditional	Bergantung pada syarat	"jika demam muncul"
hypothetical	Skenario yang belum terjadi	"bila nanti mengalami..."
unknown	Status pengetahuan tidak dapat ditentukan	konteks tidak cukup

3.7 Atribut bebas atau opsional

Atribut	Aturan
normalized_mention	Bentuk mention yang dinormalisasi
base_entity	Konsep dasar tanpa modifier
associated_entities	Daftar entity_id yang berkaitan
categories	Modifier/kategori yang masih relevan
value	Nilai numerik atau tekstual
unit	Satuan yang terkait dengan nilai
dose	Dosis lengkap, misalnya 500 mg
frequency	Frekuensi, misalnya dua kali sehari
route	Rute pemberian, misalnya oral
method	Metode pemeriksaan/tindakan

Atribut	Aturan
<code>visit</code>	Jenis kunjungan
<code>sentence_id</code>	Indeks kalimat, mulai dari 0
<code>evidence</code>	Kalimat yang memuat mention
<code>confidence</code>	Nilai 0.0–1.0; bukan pengganti catatan ambiguitas

`source_field` dan `speaker` berasal dari dokumen:

Dokumen	<code>source_field</code>	<code>speaker</code>
Pertanyaan	<code>question</code>	<code>patient</code>
Jawaban	<code>answer</code>	<code>doctor</code>

4. Contoh anotasi

4.1 Negasi

Teks:

saya tidak demam sejak dua hari.

Span:

```
mention          = demam
start_char       = 11
end_char         = 16
entity_type      = symptom
domain           = condition
assertion        = negated
temporal         = present
temporal_expression = sejak dua hari
experiencer      = patient
epistemic_status = patient_fact
```

Kata `tidak` tidak dimasukkan ke span `demam`; maknanya direkam melalui `assertion=negated`.

4.2 Kondisi anggota keluarga

Teks:

ibu saya menderita diabetes melitus.

Span:

```
mention      = diabetes melitus
start_char   = 19
end_char     = 35
entity_type  = condition
assertion    = present
temporal     = unknown
experiencer  = family
epistemic_status = patient_fact
```

ibu saya adalah petunjuk experiencer. Fokus entitas klinisnya adalah diabetes melitus.

4.3 Measurement dan unit

Teks:

```
tekanan darah saya 160/100 mmHg.
```

Entitas pertama:

```
mention      = tekanan darah
start_char   = 0
end_char     = 13
entity_type  = measurement
value       = 160/100
unit        = mmHg
```

Entitas kedua, jika unit dipertahankan untuk pemetaan UCUM:

```
mention      = mmHg
start_char   = 27
end_char     = 31
entity_type  = unit
unit        = mmHg
```

Kedua entitas dapat dihubungkan melalui `associated_entities`.

4.4 Obat, dosis, dan frekuensi

Teks:

```
saya minum parasetamol 500 mg dua kali sehari.
```

```
mention      = parasetamol
start_char   = 11
end_char     = 22
entity_type  = drug
dose         = 500 mg
frequency    = dua kali sehari
assertion    = present
temporal     = present
experiencer  = patient
epistemic_status = patient_fact
```

Dosis dan frekuensi menjadi atribut obat, bukan bagian wajib dari span obat.

4.5 Diagnosis banding pada jawaban dokter

Teks:

keluhan nyeri dada dapat disebabkan oleh penyakit jantung.

Entitas **penyakit jantung**:

```
mention      = penyakit jantung
start_char   = 41
end_char     = 57
entity_type  = condition
assertion    = uncertain
temporal     = unknown
experiencer  = patient
epistemic_status = differential_diagnosis
source_field = answer
speaker      = doctor
```

Pernyataan ini tidak boleh dianotasi sebagai diagnosis pasien yang sudah pasti.

4.6 Rekomendasi bersyarat

Teks:

sebaiknya lakukan pemeriksaan darah jika demam muncul.

pemeriksaan darah:

```
entity_type  = procedure
assertion    = hypothetical
```

```
temporal          = future
epistemic_status = recommended
```

demam:

```
entity_type      = symptom
assertion        = hypothetical
temporal         = future
epistemic_status = conditional
```

5. Persiapan data untuk alat anotasi

Satu record Checkpoint 3 dipecah menjadi dua dokumen:

```
gold-v1-001-question
gold-v1-001-answer
```

Metadata minimal yang harus tetap dibawa:

```
{
  "task_id": "gold-v1-001",
  "document_id": "<parent_record_id>-question",
  "parent_record_id": "<parent_record_id>",
  "source_field": "question",
  "speaker": "patient",
  "text": "<question.normalized_text>"
}
```

Untuk answer:

```
source_field = answer
speaker      = doctor
text        = answer.normalized_text
```

Jangan mengimpor cuplikan teks yang ditampilkan notebook. Tampilan notebook memotong teks untuk inspeksi; anotasi harus memakai `normalized_text` lengkap.

6. Panduan menggunakan INCEption

INCEption direkomendasikan jika seluruh atribut ingin dicatat langsung pada span dan adjudikasi dilakukan di dalam satu platform.

6.1 Membuat proyek

1. Masuk sebagai project manager.
2. Buat project baru, misalnya **Tahap 2 - Gold v1**.
3. Tambahkan user anotator A, anotator B, dan adjudikator.
4. Berikan A dan B hak anotasi.
5. Berikan tenaga klinis hak curation.
6. Masukkan pedoman Checkpoint 2 ke bagian guidelines proyek.
7. Impor 80 dokumen: 40 question dan 40 answer.
8. Pastikan nama dokumen mempertahankan **task_id** dan **source_field**.

6.2 Membuat layer

Buat custom span layer:

```
Layer name : ClinicalEntity
Type       : span
Granularity: character atau token
Overlap    : aktifkan hanya jika pedoman memang membutuhkan nested span
```

Jika pemilihan harus menghasilkan offset karakter yang sama persis dengan skema, lakukan uji impor-ekspor pada beberapa dokumen sebelum anotasi massal.

6.3 Membuat feature

Feature dengan nilai tertutup:

```
entity_type
domain
assertion
temporal
experiencer
epistemic_status
```

Isi daftar nilai sesuai Bagian 3. Gunakan dropdown/tagset agar anotator tidak membuat ejaan baru seperti **negative**, **negation**, atau **current**.

Feature teks/numerik:

```
normalized_mention
base_entity
value
unit
dose
frequency
route
method
```

```
visit
temporal_expression
confidence
notes
```

mention, offset, dan teks evidence sebaiknya direkonstruksi dari span dan kalimat saat konversi ekspor. **source_field**, **speaker**, **document_id**, dan **parent_record_id** diambil dari metadata/nama dokumen, bukan diketik ulang oleh anotator.

6.4 Prosedur anotator

1. Buka dokumen question atau answer.
2. Baca seluruh dokumen sebelum menandai span.
3. Seleksi mention klinis terlengkap yang sesuai pedoman.
4. Pilih **entity_type**.
5. Isi seluruh feature wajib.
6. Isi atribut opsional hanya jika tertulis atau dapat ditentukan secara aman.
7. Periksa bahwa kata negasi tidak ikut ke span.
8. Periksa experiencer dan epistemic status.
9. Catat ambiguitas dalam **notes**.
10. Tandai dokumen sebagai finished/complete.

6.5 Anotasi independen

- A dan B mendapat kumpulan dokumen yang sama.
- Keduanya tidak membuka halaman curation.
- Project manager tidak menggabungkan anotasi sebelum seluruh paket selesai.
- Identitas user pada ekspor harus dipertahankan agar hasil dapat dipisahkan.

6.6 Curation/adjudikasi

1. Buka halaman curation setelah A dan B menandai dokumen selesai.
2. Periksa perbedaan span terlebih dahulu.
3. Periksa **entity_type**.
4. Periksa assertion, temporal, experiencer, dan epistemic status.
5. Adjudikator memilih salah satu anotasi atau membuat keputusan baru.
6. Setiap keputusan substantif dicatat pada **stage2_adjudication_log.md**.
7. Ekspor anotasi individual dan hasil curation secara terpisah.
8. Konversi hasil ekspor ke kontrak JSONL Checkpoint 2.
9. Jalankan validator skema dan audit Checkpoint 3.

6.7 Pemeriksaan sebelum ekspor

- Semua dokumen berstatus selesai.
- Tidak ada feature wajib yang kosong.
- **other** telah ditinjau.
- Question dan answer tidak tertukar.
- Semua disagreement sudah diputuskan.

- Versi project, pedoman, dan tanggal ekspor dicatat.

7. Panduan menggunakan doccano

doccano direkomendasikan untuk anotasi span dan **entity_type** yang sederhana. Karena skema penelitian memiliki banyak atribut per entitas, gunakan workflow dua bagian:

```
doccano          → span + entity_type
lembar atribut JSONL → atribut klinis setiap span
```

Jangan menganggap label dokumen atau komentar bebas sebagai pengganti atribut terstruktur.

7.1 Membuat proyek

1. Instal dan jalankan doccano sesuai dokumentasi resmi.
2. Buat project bertipe **Sequence Labeling**.
3. Nama project, misalnya **Tahap 2 Gold v1 - Annotator A**.
4. Aktifkan collaborative annotation hanya jika konfigurasi menjamin hasil setiap pengguna tetap terpisah.
5. Untuk isolasi yang paling mudah diaudit, buat dua project identik:

```
Tahap 2 Gold v1 - Annotator A
Tahap 2 Gold v1 - Annotator B
```

6. Tambahkan anggota sesuai project.
7. Salin pedoman Checkpoint 2 ke guideline project.
8. Impor 80 dokumen yang sama ke kedua project.

7.2 Membuat label NER

Buat sebelas label berikut, tanpa variasi ejaan:

```
condition
symptom
clinical_finding
measurement
drug
procedure
anatomy
demographic
unit
visit
other
```

Gunakan warna dan shortcut yang sama pada project A dan B.

7.3 Format impor konseptual

doccano menerima format sesuai tipe project dan versi yang digunakan. Data yang disiapkan minimal membawa teks dan metadata yang dapat ditelusuri:

```
{
  "text": "saya tidak demam sejak dua hari.",
  "task_id": "contoh-negasi",
  "document_id": "contoh-negasi-question",
  "parent_record_id": "contoh-negasi",
  "source_field": "question",
  "speaker": "patient"
}
```

Lakukan uji impor 2–3 record terlebih dahulu dan pastikan metadata tetap dapat dihubungkan kembali pada saat ekspor.

7.4 Prosedur anotator

1. Buka dokumen.
2. Baca seluruh teks.
3. Sorot mention klinis.
4. Pilih satu **entity_type**.
5. Hindari memasukkan kata negasi, kata penghubung, atau experiencer ke span, kecuali memang bagian dari konsep klinis.
6. Catat task yang ambigu pada daftar terpisah.
7. Selesaikan seluruh dokumen dan ekspor hasil per anotator.

Contoh keluaran span doccano:

```
{
  "text": "saya tidak demam sejak dua hari.",
  "labels": [
    [11, 16, "symptom"]
  ]
}
```

7.5 Melengkapi atribut

Setelah ekspor, setiap span diberi **entity_id**, lalu anotator melengkapi lembar atribut dengan kunci yang stabil:

```
{
  "document_id": "contoh-negasi-question",
  "entity_id": "contoh-negasi-question-e001",
  "mention": "demam",
  "start_char": 11,
```

```

"end_char": 16,
"entity_type": "symptom",
"normalized_mention": "demam",
"base_entity": "demam",
"domain": "condition",
"assertion": "negated",
"temporal": "present",
"temporal_expression": "sejak dua hari",
"experiencer": "patient",
"epistemic_status": "patient_fact",
"notes": ""
}

```

Lembar atribut A dan B harus tetap terpisah. Jangan menggunakan satu lembar bersama karena hal tersebut menghilangkan independensi.

7.6 Agreement dan adjudikasi

1. Ekspor project A dan B secara terpisah.
2. Cocokkan record menggunakan `document_id`.
3. Cocokkan entitas awal menggunakan:

```
start_char + end_char + entity_type
```

4. Bandingkan atribut pada span yang cocok.
5. Masukkan perbedaan ke `stage2_annotation_disagreement.jsonl`.
6. Tenaga klinis memutuskan hasil final.
7. Catat alasan pada `stage2_adjudication_log.md`.
8. Bangun dan validasi `stage2_gold_v1.jsonl`.

8. Contoh satu record final

Contoh berikut menunjukkan bentuk target setelah hasil alat dikonversi. Ini bukan format impor langsung INCEpTION atau doccano.

```

{
  "document_id": "schema-q1-question",
  "parent_record_id": "schema-q1",
  "source_field": "question",
  "speaker": "patient",
  "normalized_text": "saya tidak demam sejak dua hari.",
  "sentences": [
    "saya tidak demam sejak dua hari."
  ],
  "entities": [
    {
      "entity_id": "schema-q1-e1",

```

```

    "mention": "demam",
    "normalized_mention": "demam",
    "base_entity": "demam",
    "entity_type": "symptom",
    "domain": "condition",
    "associated_entities": [],
    "categories": [],
    "value": null,
    "unit": null,
    "dose": null,
    "frequency": null,
    "route": null,
    "method": null,
    "visit": null,
    "assertion": "negated",
    "temporal": "present",
    "temporal_expression": "sejak dua hari",
    "experiencer": "patient",
    "epistemic_status": "patient_fact",
    "source_field": "question",
    "speaker": "patient",
    "sentence_id": 0,
    "start_char": 11,
    "end_char": 16,
    "evidence": "saya tidak demam sejak dua hari.",
    "confidence": 1.0
  }
],
"schema_version": "1.0.0"
}

```

9. Checklist anotator

Untuk setiap dokumen:

- ☐ Saya membaca teks lengkap.
- ☐ Saya menggunakan `normalized_text`.
- ☐ Semua mention merupakan substring persis.
- ☐ Span tidak memasukkan kata negasi/penghubung yang tidak diperlukan.
- ☐ `entity_type` sesuai taksonomi.
- ☐ Assertion ditentukan dari konteks.
- ☐ Temporal dan ekspresi waktunya diperiksa.
- ☐ Experiencer diperiksa.
- ☐ Epistemic status diperiksa, khususnya pada jawaban dokter.
- ☐ Nilai, unit, dosis, frekuensi, dan route tidak ditebak.
- ☐ Kasus ambigu dicatat.
- ☐ Dokumen ditandai selesai.

10. Checklist project manager

- ☐ Project A dan B menggunakan dokumen serta label yang sama.
 - ☐ Anotator bekerja independen.
 - ☐ `task_id`, `document_id`, dan `source_field` dapat dipulihkan.
 - ☐ Ekspor A dan B disimpan terpisah.
 - ☐ Hash dan waktu ekspor dicatat.
 - ☐ Semua record lolos validasi skema.
 - ☐ Agreement dihitung sebelum adjudikasi.
 - ☐ Semua disagreement diselesaikan tenaga klinis.
 - ☐ Gold v1 tidak digunakan sebagai few-shot atau data pengembangan.
 - ☐ Gold v1 dibekukan dengan versi dan SHA-256.
-

11. Pemilihan alat

Gunakan INCEpTION apabila:

- atribut per span ingin diisi dalam satu antarmuka;
- diperlukan curation bawaan;
- adjudikator perlu melihat hasil A dan B berdampingan.

Gunakan doccano apabila:

- prioritas awal adalah span dan `entity_type`;
- tim membutuhkan antarmuka NER yang lebih sederhana;
- tersedia proses tambahan untuk melengkapi atribut dan adjudikasi.

Untuk kontrak Checkpoint 2 yang memiliki banyak atribut, INCEpTION adalah pilihan utama. doccano tetap layak sebagai workflow dua langkah selama identitas dokumen, offset, independensi anotator, dan audit trail dijaga.