

UJIAN KOMPREHENSIF

ADAPTASI CDE-MAPPER PEMETAAN TERMINOLOGI KLINIS UNTUK TEKS BAHASA INDONESIA: PENDEKATAN BERBASIS LLM DAN HYBRID RETRIEVAL



Diusulkan Oleh:
Anie Rose Irawati

Dosen Pembimbing:
Afiahayati, S.Kom., M.Cs., Ph.D
Dr. Lukman Heryawan, S.T., M.T.

PROGRAM DOKTOR ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

2026

HALAMAN PENGESAHAN

UJIAN KOMPREHENSIF

ADAPTASI CDE-MAPPER PEMETAAN TERMINOLOGI KLINIS UNTUK TEKS BAHASA INDONESIA: PENDEKATAN BERBASIS LLM DAN HYBRID RETRIEVAL

Anie Rose Irawati
24/551784/SPA/01084

Dipertahankan dihadapan Dewan Penguji Program Studi S3 Ilmu Komputer
Departemen Ilmu Komputer dan Elektronika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Gadjah Mada

Pada Tanggal 2026

.....
Ketua Penguji

Afiahayati, S.Kom., M.Cs., Ph.D
Promotor

Prof Dr. XYZ, M.SC
Penguji

Dr. Lukman Heryawan, S.T., M.T.
Ko-Promotor

Prof Dr. ABC, M.SC
Penguji

Prof Dr. XYZ, M.SC
Penguji

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR GAMBAR	v
DAFTAR TABEL	vi
DAFTAR ISTILAH	vii
RINGKASAN	xii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	7
1.3 Tujuan Penelitian	7
1.4 Manfaat Penelitian	8
1.4.1 Manfaat Teoritis	8
1.4.2 Manfaat Praktis	8
BAB II TINJAUAN PUSTAKA	9
2.1 FHIR dan <i>Clinical Terminology Mapping</i>	9
2.2 Evolusi Metode Terkait <i>Clinical Terminology Mapping</i>	10
2.2.1 Pendekatan Berbasis Aturan dan Hierarki	12
2.2.2 Otomatisasi <i>Mapping</i> dengan Model <i>Machine Learning</i> Tradisional dan NLP untuk Teks Klinis	14
2.2.3 Integrasi Data Multi-Sumber Menggunakan <i>Knowledge</i> <i>Graph</i> dan Harmonisasi Model Data	16
2.2.4 Adopsi <i>Sentence Transformer</i> , <i>Graph-Based Embeddings</i> , dan <i>Classifier Chains</i> untuk Akurasi Tinggi	17
2.2.5 LLM dan <i>Retrieval-Augmented Generation</i> (RAG)	18
2.3 Penelitian Tentang Terminologi Kesehatan di Indonesia	21
2.3.1 Adaptasi Terminologi Standar di SATUSEHAT	22
2.3.2 Penelitian Terkait <i>BioNER</i> di Indonesia	23
2.4 Identifikasi Kesenjangan Penelitian (<i>Research Gaps</i>)	25
2.4.1 Gap Metodologis: Keterbatasan Metode <i>Existing</i>	25
2.4.2 Gap Cakupan: Multi-Terminologi dan Teks Panjang	26

2.4.3	Gap Konteks: Bahasa Non-Inggris dan Kebutuhan Lokal Indonesia	28
2.4.4	Ringkasan Kesenjangan dan Posisi Penelitian	29
2.5	Relevansi Judul Penelitian	31
BAB III	LANDASAN TEORI	33
3.1	Konsep Dasar Terminologi Rujukan Klinis	33
3.1.1	SNOMED CT sebagai Terminologi Rujukan Klinis	34
3.1.2	LOINC sebagai Terminologi untuk Observasi dan Laboratorium	35
3.1.3	ICD sebagai Sistem Klasifikasi Statistik	36
3.1.4	Terminologi Lainnya dan Hubungan Antar Terminologi	36
3.2	LLM dan Arsitekturnya	37
3.2.1	Evolusi LLM	37
3.2.2	Transformer	38
3.2.3	Arsitektur <i>Encoder-Only</i> : BERT	40
3.2.4	Arsitektur <i>Decoder-Only</i> : Seri GPT	40
3.2.5	Arsitektur <i>Encoder-Decoder</i> : T5	41
3.2.6	Arsitektur Efisien dan Terbuka: LLaMA	41
3.3	<i>Retrieval-Augmented Generation</i> (RAG)	45
3.3.1	Arsitektur RAG	46
3.3.2	Evolusi RAG	48
3.4	Implementasi RAG dan LLM dalam CDE-Mapper	50
3.4.1	Framework CDE-Mapper Gilani	51
3.4.2	Temuan Utama Gilani	53
3.5	Dataset untuk <i>Clinical Terminology Mapping</i>	55
3.6	Metrik Evaluasi	57
3.6.1	Akurasi (<i>Accuracy</i>)	57
3.6.2	<i>Precision</i> , <i>Recall</i> , dan <i>F1-score</i>	57
3.6.3	<i>Coverage</i>	58
3.6.4	<i>Agreement</i> dan <i>Consistency</i>	59
3.6.5	Efisiensi	59
3.6.6	Metrik <i>Retrieval</i> Tambahan	60
3.6.7	Ringkasan Penggunaan Metrik	61
BAB IV	METODE PENELITIAN	63
4.1	Gambaran Umum Penelitian	63
4.2	Tahapan Penelitian	63

4.2.1	Persiapan dan Analisis	64
4.2.2	Perancangan dan Pengembangan Model	64
4.2.3	Implementasi Inti Model	65
4.2.4	Evaluasi dan Validasi	66
4.2.5	Analisis dan Dokumentasi	67
4.3	Deskripsi Usulan Model	68
4.3.1	Tujuan dan Keluaran Model	68
4.3.2	Arsitektur, Alur Proses, dan Komponen Utama	68
4.3.3	Formalisasi Matematis Model Usulan	76
4.3.4	Asumsi, Batasan, dan Strategi Mitigasi	78
4.4	Rancangan Pengujian	78
4.4.1	Desain Eksperimen dan Skenario Pengujian	78
4.4.2	Dataset, Pembagian Data, dan <i>Gold Standard</i>	79
4.4.3	<i>Baseline</i> , Model Pembanding, dan Varian (<i>Ablation Study</i>)	80
4.4.4	Metrik Evaluasi	82
4.4.5	Prosedur Pengujian dan Analisis Hasil	84
4.5	Jadwal Penelitian	85

DAFTAR PUSTAKA

86

DAFTAR GAMBAR

Gambar 3.1	Evolusi LLM berdasarkan kemampuan penyelesaian tugas	38
Gambar 3.2	Arsitektur Transformer	39
Gambar 3.3	Arsitektur umum RAG	46
Gambar 3.4	Paradigma dalam evolusi RAG	49
Gambar 3.5	Framework CDE-Mapper	51
Gambar 4.1	Tahapan penelitian	63
Gambar 4.2	Framework adaptasi pemetaan terminologi klinis Bahasa Indonesia	69
Gambar 4.3	Gambaran arsitektur dan alur <i>pipeline</i> yang diusulkan . .	75

DAFTAR TABEL

Tabel 1.1	Perbedaan Representasi Kode Diabetes Melitus Tipe 2 di SNOMED CT, LOINC, dan ICD-10	3
Tabel 2.1	Tren penelitian <i>clinical terminology mapping</i>	12
Tabel 2.2	Perbandingan metode <i>clinical terminology mapping</i> dan keterbatasannya	20
Tabel 2.3	Perbandingan kuantitatif metode pemetaan terminologi klinis representatif	21
Tabel 2.4	Identifikasi kesenjangan penelitian dan arah solusi	30
Tabel 3.1	Rangkuman data pretraining LLaMA	42
Tabel 3.2	Perubahan arsitektur utama pada LLaMA dibandingkan Transformer asli	42
Tabel 3.3	Hiperparameter utama model LLaMA	43
Tabel 3.4	Rangkuman hasil pengujian LLaMA pada beberapa ben- chmark utama	44
Tabel 3.5	Ringkasan metrik evaluasi untuk <i>clinical terminology mapping</i>	62
Tabel 4.1	Rencana jadwal pelaksanaan kegiatan penelitian	85

DAFTAR ISTILAH

Ablation study Teknik evaluasi untuk mengukur kontribusi setiap komponen model dengan cara menghapus atau menonaktifkan komponen tertentu secara bertahap.

AI (*Artificial Intelligence*) Cabang ilmu komputer yang mengembangkan sistem untuk meniru kemampuan kognitif manusia, termasuk pemahaman bahasa dan pengambilan keputusan.

Baseline Metode atau model pembandingan yang digunakan sebagai acuan untuk menilai peningkatan kinerja pendekatan yang diusulkan.

BERT *Bidirectional Encoder Representations from Transformers*, model bahasa berbasis transformer dua arah untuk memahami konteks kata berdasarkan hubungan dengan kata sebelum dan sesudahnya.

BiLSTM *Bidirectional Long Short-Term Memory*, jenis RNN yang memproses urutan teks dari dua arah (kiri dan kanan); sering digunakan untuk NER sebelum era transformer.

BioNER *Biomedical Named Entity Recognition*, teknik untuk mengenali dan mengekstraksi entitas penting pada teks biomedis atau klinis, seperti penyakit, obat, gejala, dan prosedur.

CDE (*Common Data Element*) Elemen data standar yang digunakan untuk menyeragamkan definisi, struktur, dan representasi data agar dapat digunakan lintas sistem.

CDE-Mapper *Framework* pemetaan yang dirancang untuk menghubungkan elemen data atau istilah ke kosakata terkendali; menjadi dasar adaptasi model dalam penelitian ini.

CDSS (*Clinical Decision Support System*) Sistem yang membantu tenaga kesehatan dalam pengambilan keputusan klinis melalui penyediaan rekomendasi, peringatan, atau informasi yang relevan.

Code-Mixing Fenomena pencampuran dua bahasa dalam satu ujaran atau teks; dalam konteks klinis Indonesia, sering mencampur istilah Indonesia dengan Inggris.

Controlled vocabulary Kosakata terkendali berupa himpunan istilah standar yang digunakan secara konsisten agar representasi data memiliki makna yang beragam.

Coverage Metrik evaluasi yang menunjukkan sejauh mana sistem mampu menghasilkan pemetaan untuk data atau istilah yang diuji.

CRF (*Conditional Random Field*) Lapisan probabilistik yang sering ditambahkan di atas BiLSTM atau BERT untuk memastikan konsistensi label berurutan dalam tugas NER.

cTAKES *clinical Text Analysis and Knowledge Extraction System*, toolkit NLP *open-source* dari Mayo Clinic untuk ekstraksi entitas klinis dari teks rekam medis.

Deep learning Pendekatan pembelajaran mesin berbasis jaringan saraf berlapis banyak yang mampu mempelajari representasi data yang kompleks.

EHR (*Electronic Health Record*) Rekam kesehatan elektronik yang menyimpan riwayat informasi kesehatan pasien secara digital dan dapat diakses lintas layanan.

Ensemble retrieval Strategi pencarian kandidat yang menggabungkan beberapa *retriever* secara paralel (misal SPLADE dan SapBERT) untuk menghasilkan daftar kandidat yang lebih kaya.

F1-score Metrik evaluasi yang menggabungkan *precision* dan *recall* untuk menilai keseimbangan antara ketepatan dan kelengkapan hasil model.

FHIR (*Fast Healthcare Interoperability Resources*) Standar pertukaran data kesehatan yang dikembangkan oleh HL7 untuk mendukung interoperabilitas sistem kesehatan secara digital.

Framework Kerangka kerja konseptual dan teknis yang memandu perancangan, integrasi, dan implementasi komponen dalam suatu sistem.

Gold standard Data acuan yang telah diverifikasi, umumnya oleh pakar, dan digunakan sebagai rujukan utama dalam pelatihan, pengujian, atau validasi sistem.

GPT (*Generative Pre-trained Transformer*) Model bahasa generatif berbasis transformer yang dilatih terlebih dahulu pada korpus besar untuk menghasilkan dan memahami teks.

Graph embeddings Teknik representasi simpul atau entitas dalam graf ke dalam bentuk vektor numerik agar hubungan semantik dapat diproses oleh model komputasional.

HL7 (*Health Level Seven*) Organisasi pengembang standar pertukaran data kesehatan, termasuk FHIR.

ICD (*International Classification of Diseases*) Sistem klasifikasi penyakit yang digunakan untuk pengodean diagnosis, pelaporan statistik, dan manajemen kesehatan.

ICD-10 Revisi kesepuluh dari *International Classification of Diseases* yang banyak digunakan untuk klasifikasi diagnosis dan kondisi kesehatan.

Inter-Annotator Agreement Tingkat kesepakatan antara dua atau lebih anotator dalam memberikan label pada dataset; diukur dengan koefisien Kappa.

Interoperabilitas Kemampuan dua atau lebih sistem untuk bertukar data dan memanfaatkan data tersebut secara efektif dalam konteks yang sama.

Knowledge graph Representasi pengetahuan dalam bentuk graf yang memodelkan entitas dan relasinya untuk mendukung penelusuran serta penalaran semantik.

Knowledge reservoir Basis penyimpanan pasangan label–kode yang telah tervalidasi untuk mempercepat inferensi dan meningkatkan konsistensi lintas dokumen.

KPTL Kode Pembiayaan Tindakan dan Layanan Kesehatan Nasional, terminologi nasional Indonesia untuk kebutuhan pembiayaan kesehatan.

LLaMA (*Large Language Model Meta AI*) Keluarga model bahasa besar terbuka dari Meta (7B–65B parameter) yang dioptimalkan untuk efisiensi inferensi.

LLM (*Large Language Model*) Model bahasa berukuran besar dengan miliaran parameter, mampu memahami, merangkum, dan menghasilkan teks secara kontekstual.

LOINC (*Logical Observation Identifiers Names and Codes*) Standar terminologi untuk observasi klinis, pemeriksaan laboratorium, dan pengukuran kesehatan.

Low-resource language Bahasa dengan sumber daya data, korpus, dan anotasi digital yang terbatas untuk pengembangan model komputasional.

Machine learning Pendekatan komputasional yang memungkinkan sistem mempelajari pola dari data untuk membuat prediksi atau keputusan tanpa diprogram secara eksplisit.

MRR (*Mean Reciprocal Rank*) Metrik evaluasi *retrieval* yang memberi bobot lebih tinggi jika kandidat benar muncul pada peringkat lebih awal.

NER (*Named Entity Recognition*) Teknik NLP untuk mengidentifikasi dan mengklasifikasikan entitas penting dalam teks.

NLP (*Natural Language Processing*) Bidang kecerdasan artifisial yang berfokus pada pengolahan, analisis, dan pemahaman bahasa manusia oleh komputer.

OMOP CDM *Observational Medical Outcomes Partnership Common Data Model*, model data standar untuk standardisasi struktur data observasional kesehatan.

Ontologi Representasi formal mengenai konsep-konsep dalam suatu domain beserta relasi antarkonsep untuk mendukung konsistensi makna.

Post-coordination Kemampuan membuat konsep baru dalam SNOMED CT dengan menggabungkan beberapa konsep yang sudah ada beserta relasinya.

Precision Metrik evaluasi yang menunjukkan proporsi hasil prediksi yang benar dari seluruh hasil yang diprediksi positif atau relevan oleh sistem.

Preprocessing Tahap pembersihan dan normalisasi teks sebelum pemrosesan lebih lanjut (*case folding*, *stemming*, normalisasi singkatan, dll.).

Query decomposition Tahap pemecahan CDE komposit menjadi komponen-komponen kecil (*base entity*, *domain*, *unit*, *visit*, dll.) menggunakan LLM.

RAG (*Retrieval-Augmented Generation*) Pendekatan yang menggabungkan pencarian informasi dengan generasi teks berbasis model bahasa untuk meningkatkan relevansi keluaran.

Recall Metrik evaluasi yang menunjukkan proporsi data relevan yang berhasil ditemukan atau dipetakan dengan benar oleh sistem.

Reranking Proses mengurutkan ulang kandidat hasil *retrieval* menggunakan model atau kriteria tambahan agar hasil teratas menjadi lebih relevan.

RME (*Rekam Medis Elektronik*) Istilah Bahasa Indonesia untuk *Electronic Health Record* (EHR) atau sistem pencatatan medis pasien secara digital.

Rule-based Pendekatan berbasis aturan eksplisit yang disusun secara manual untuk mengenali pola, istilah, atau relasi tertentu dalam data.

SapBERT *Retriever dense* berbasis BERT yang dirancang khusus untuk entitas biomedis, mampu mendekatkan representasi sinonim.

SATUSEHAT Platform interoperabilitas data kesehatan nasional di Indonesia yang mengintegrasikan data antar fasilitas dan sistem kesehatan.

Self-consistency Mekanisme pengulangan penilaian LLM beberapa kali dengan *prompt* yang sama untuk menghitung *confidence score* dari hasil yang konsisten.

Semantic retrieval Teknik penelusuran informasi yang memanfaatkan kemiripan makna, bukan hanya kecocokan kata, untuk menemukan kandidat yang relevan.

Sentence transformer Arsitektur transformer yang dirancang untuk menghasilkan representasi vektor tingkat kalimat sehingga cocok untuk pencarian semantik.

SNOMED CT *Systematized Nomenclature of Medicine – Clinical Terms*, terminologi klinis komprehensif untuk merepresentasikan konsep medis secara rinci dan terstruktur.

SPARQL Bahasa kueri untuk basis data RDF (*Resource Description Framework*).

SPLADE *Sparse Lexical and Dense Embedding, retriever sparse* yang mengombinasikan kecocokan leksikal dengan representasi *embedding*.

T5 (Text-to-Text Transfer Transformer) Model transformer yang memformulasikan berbagai tugas NLP dalam bentuk masukan teks dan keluaran teks.

Terminologi klinis Sistem istilah baku untuk merepresentasikan konsep klinis, seperti penyakit, prosedur, gejala, hasil pemeriksaan, dan intervensi.

Top-k accuracy Metrik yang mengukur apakah kode *gold standard* muncul di antara k kandidat teratas yang dihasilkan sistem.

Transformer Arsitektur model jaringan saraf yang memanfaatkan mekanisme *attention* untuk memproses hubungan antarkata atau antarsatuan teks secara efisien.

Two-step reranking Proses penilaian ulang kandidat oleh LLM: memberi skor relevansi lalu mengklasifikasikan ke kategori (*exact, highly, partial, not relevant*).

Vector embedding Representasi numerik dalam bentuk vektor yang menangkap makna atau karakteristik suatu kata, istilah, kalimat, atau entitas.

XLM-R *Cross-lingual Language Model – RoBERTa*, model transformer multibahasa yang dilatih pada 100 bahasa; *robust* untuk BioNER bahasa Indonesia.

RINGKASAN

Transformasi digital kesehatan di Indonesia menuntut interoperabilitas data yang tidak hanya memungkinkan pertukaran informasi, tetapi juga menjamin kesetaraan makna klinis antar sistem, terutama dalam ekosistem SATUSEHAT. Namun, istilah klinis Bahasa Indonesia masih sangat beragam, hadir dalam teks panjang, format lokal yang heterogen, dan dokumentasi yang belum sepenuhnya terstandar, sehingga sulit dipetakan secara akurat ke terminologi rujukan seperti SNOMED CT, LOINC, dan ICD-10; kondisi ini menunjukkan adanya kesenjangan metodologis pada pendekatan *clinical terminology mapping* yang ada, khususnya untuk pemetaan multi-standar, pemrosesan teks klinis panjang, dan adaptasi terhadap karakteristik bahasa Indonesia.

Penelitian ini bertujuan mengembangkan *framework* adaptif untuk pemetaan terminologi klinis Bahasa Indonesia ke beberapa kosakata terkendali standar guna mendukung interoperabilitas data kesehatan nasional. Penelitian ini merupakan penelitian pengembangan dengan pendekatan kuantitatif-eksperimental yang mengadaptasi *framework* CDE-Mapper melalui integrasi modul *long-text entity extraction* berbasis LLM, *retrieval ensemble*, serta mekanisme *filtering* dan *reranking* untuk pemetaan simultan multi-standar. Rancangan penelitian mencakup pengumpulan istilah dan dokumen klinis berbahasa Indonesia dari sumber sekunder, korpus atau dataset anotasi, serta penyusunan *gold standard* pemetaan untuk kebutuhan pelatihan, pengujian, dan validasi. Analisis data dilakukan melalui perbandingan dengan *baseline* dan *ablation study* menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, *coverage*, konsistensi, dan efisiensi komputasi.

Hasil yang diharapkan dari penelitian ini adalah terbentuknya *framework* adaptif dan prototipe sistem yang mampu mengekstraksi entitas klinis dari teks panjang dan memetakannya secara lebih relevan ke SNOMED CT, LOINC, dan ICD-10 dalam konteks Bahasa Indonesia. Penelitian ini diharapkan memberikan kontribusi pada pengembangan metode pemetaan terminologi klinis multi-standar untuk bahasa non-Inggris sekaligus memperkuat standardisasi data klinis nasional bagi layanan kesehatan, pengelolaan sistem, dan penelitian.

Kata kunci: *terminologi klinis Bahasa Indonesia, interoperabilitas kesehatan, pemetaan multi-standar, large language model, retrieval-augmented generation.*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Interoperabilitas sistem informasi kesehatan merupakan kebutuhan kritis dalam ekosistem kesehatan modern, di mana data medis harus dapat dipertukarkan dan diintegrasikan antar berbagai sistem dan institusi (Ayuningtyas dkk., 2025). Tanpa interoperabilitas, data medis akan terisolasi dalam silo-silo sistem yang menghambat integrasi dan pemanfaatan data secara holistik untuk kepentingan klinis maupun penelitian (Rinaldi dkk., 2023). Dalam konteks tersebut, pertukaran data saja belum cukup. Interoperabilitas baru bernilai apabila data yang dipertukarkan dipahami dengan makna yang sama oleh sistem yang berbeda.

Makna yang sama tersebut berkaitan langsung dengan konsistensi semantik, yaitu kemampuan sistem kesehatan yang berbeda untuk tidak hanya bertukar data secara struktural, tetapi juga memahami arti data tersebut secara konsisten. Tanpa konsistensi semantik, informasi klinis yang secara kasat mata tampak serupa dapat ditafsirkan secara berbeda oleh sistem yang berbeda, sehingga menurunkan kualitas integrasi data, analisis, dan pengambilan keputusan klinis. Karena itu, konsistensi semantik merupakan prasyarat utama bagi interoperabilitas yang benar-benar dapat digunakan.

Fast Healthcare Interoperability Resource (FHIR), yang dikembangkan Health Level Seven (HL7), merupakan salah satu standar interoperabilitas untuk mendukung pertukaran data kesehatan dalam format digital secara syntactic dan semantic dan digunakan secara luas. Berdasarkan laporan dari HL7 International & Firely pada bulan Mei 2025, paling tidak ada 52 negara yang dilaporkan menggunakan FHIR secara aktif, termasuk Indonesia (<https://hl7chile.cl/wp-content/uploads/2025/06/2025-State-of-FHIR-Survey-Report.pdf>). Apabila FHIR dapat dianggap sebagai framework pertukaran data, maka SNOMED CT (Systematized Nomenclature of Medicine-Clinical Terms), LOINC (Logical Observation Identifiers Names and Codes), ICD (International Statistical Classification of Diseases) adalah standar terminologi dan klasifikasi klinis/ data yang mengisi FHIR.

Penggunaan standar terminologi klinis yang diakui secara internasional tersebut memastikan bahwa konsep klinis direpresentasikan secara seragam, menghilangkan ambiguitas dan memungkinkan pertukaran data yang akurat lintas platform (Bidgood, 1998). Dengan kata lain, interoperabilitas teknis tanpa standarisasi terminologi tetap akan menyisakan persoalan pada level makna klinis.

SNOMED CT adalah terminologi klinis paling komprehensif dan multibahasa di dunia yang dikelola oleh SNOMED International, dirancang untuk merepresentasikan konsep klinis secara detail, mulai dari gejala, diagnosis, prosedur, temuan, hingga obat-obatan, dengan hierarki dan relasi semantik yang kaya (<https://www.snomed.org/>). Setiap konsep dalam SNOMED CT memiliki pengidentifikasi permanen yang secara unik merepresentasikan makna klinis tertentu. Di sisi lain, LOINC adalah standar yang dikembangkan oleh Regenstrief Institute untuk mengidentifikasi hasil observasi laboratorium dan klinis secara universal, seperti tes darah, urinalisis, tanda vital, dan parameter fisiologis (<https://loinc.org/>). LOINC menyediakan kode universal untuk setiap jenis pengukuran atau observasi, sehingga memfasilitasi pertukaran dan penggabungan hasil klinis untuk perawatan, manajemen outcomes, dan penelitian (Ayuningtyas dkk., 2025). Sementara itu, ICD adalah sistem klasifikasi penyakit yang dikelola oleh Organisasi Kesehatan Dunia (WHO), digunakan terutama untuk koding diagnosis dan prosedur kesehatan dengan tujuan statistik, manajemen kesehatan, dan pembiayaan. Perbedaan peran SNOMED CT, LOINC, dan ICD menunjukkan bahwa kebutuhan standarisasi data klinis tidak dapat dipenuhi oleh satu sistem terminologi saja: SNOMED CT unggul dalam kedalaman klinis, LOINC dalam identifikasi observasi, dan ICD dalam klasifikasi administratif dan epidemiologis. Bahkan secara resmi dinyatakan bahwa dengan kelengkapan terminologinya, SNOMED-CT dapat dipetakan ke standar internasional lain seperti ICD-10 dan ICD-9 CM. Tabel 1.1 menggambarkan perbedaan representasi kode untuk Diabetes Melitus Tipe 2 di ketiga standar tersebut, yang secara visual mempertegas bahwa masing-masing terminologi memiliki fungsi yang spesifik dan saling melengkapi, bukan menggantikan.

Tabel 1.1: Perbedaan Representasi Kode Diabetes Melitus Tipe 2 di SNOMED CT, LOINC, dan ICD-10

Aspek Informasi Pasien	SNOMED CT	LOINC	ICD-10
Apa yang dikodekan?	Konsep klinis (diagnosis, gejala, temuan, prosedur)	Pertanyaan observasi (tes, pengukuran, dokumen)	Diagnosis (penyakit, cedera, penyebab kematian)
Kode & Nama	44054006 – Type 2 diabetes mellitus	14771-9 – Glucose [Mass/volume] in Capillary blood by Glucometer – fasting	E11.9 – Type 2 diabetes mellitus without complications
Informasi tambahan yang bisa ditangkap	Lokasi anatomi (pankreas)	Nilai hasil tes (numerik: 126 mg/dL)	Komplikasi spesifik (E11.2 dengan komplikasi ginjal)
	Severitas (misal: terkontrol/tidak)	Waktu pengambilan sampel (puasa, 2 jam <i>post prandial</i>)	Ketoasidosis (E11.1)
	Etiologi (misal: karena obesitas)	Metode pengukuran (glukometer, serum)	Koma diabetik (E11.0)
	Komplikasi (nefropati, retinopati)	Satuan (mg/dL, mmol/L)	Tidak dapat menangkap detail anatomi atau etiologi secara rinci
	Riwayat pengobatan	–	–

Dalam konteks interoperabilitas kesehatan nasional, sebagaimana diimplementasikan melalui platform SATUSEHAT, ketiganya digunakan secara simultan, dimana data diagnosis wajib merujuk pada ICD-10, data observasi/laboratorium menggunakan LOINC, dan terminologi klinis rinci menggunakan SNOMED CT. Meskipun demikian, **SATUSEHAT belum menyediakan fitur pemetaan otomatis yang dapat mengonversi secara langsung antar terminologi. Tetapi** infrastruktur pendukung pemetaan telah dipersiapkan dalam bentuk panduan dan dokumentasi, di antaranya: (1) panduan penggunaan SNOMED-CT *terminology browser* untuk melakukan pemetaan antara kode lokal dengan SNOMED-CT *concept* yang sepadan; (2) buku panduan penggunaan terminologi LOINC yang memuat langkah-langkah pemetaan LOINC; (3) video tutorial pembelajaran mandiri untuk LOINC dan panduan mendaftar lisensi afiliasi SNOMED CT; serta (4) dokumentasi SNOMED-CT yang menjelaskan bahwa terminologi ini dapat dipetakan ke standar internasional lain seperti ICD-10, ICD-9 CM, dan LOINC. **Platform menyediakan ”peta jalan” dan alat bantu, namun proses pemetaan dari data lokal ke terminologi standar tetap menjadi tanggung jawab pengembang/vendor EMR untuk dilakukan secara manual atau melalui sistem yang mereka bangun sendiri.**

Kesenjangan ini memaksa pengembang untuk melakukan proses pemetaan se-

cara manual, yang menjadi salah satu *pain points* utama sebagaimana diidentifikasi dalam penelitian Heryawan dkk. (2025). Urgensi otomasi pemetaan antar terminologi klinis semakin mendesak. Tanpa pemetaan terstruktur, data lintas fasilitas tidak dapat diolah secara bermakna, menghambat interoperabilitas sebagai fondasi sistem kesehatan digital nasional.

Hal yang harus dipertimbangkan adalah bahwa pemetaan terminologi klinis menuntut kemampuan khusus, berbeda dengan pemetaan di bidang lain (misalnya e-commerce, perpustakaan, atau pendidikan), karena hal-hal berikut.

1. Perlunya pemahaman struktur ontologi yang dalam (relasi, atribut, post-coordination) (Kate, 2020; Park dkk., 2026).
2. Kemampuan menangani istilah komposit melalui dekomposisi dan penalaran (Gilani dkk., 2025).
3. Perlunya ekstraksi entitas dari teks naratif panjang sebelum pemetaan (Eslami dkk., 2026; Peterson & Liu, 2020).
4. Memiliki toleransi terhadap variasi bahasa ekstrem (teks panjang, singkatan, typo, istilah lokal, multilingual) (Y. Chen dkk., 2022).
5. Akurasi sangat tinggi karena berdampak langsung pada keselamatan pasien (Yu dkk., 2026).
6. Kepatuhan terhadap standar dan regulasi (misalnya FHIR). Pertukaran data kesehatan wajib mengikuti standar interoperabilitas tertentu. Di Indonesia, SATUSEHAT mewajibkan penggunaan format FHIR dan terminologi SNO-MED CT, LOINC, ICD-10.
7. Evaluasi oleh ahli klinis karena tidak ada gold standard otomatis (Y. Chen dkk., 2022; Eslami dkk., 2026; Gilani dkk., 2025).

Untuk mengatasi tantangan tersebut, metode pemetaan otomatis terminologi medis berevolusi dari pendekatan rule-based dan leksikal (transparan tetapi rentan variasi bahasa dan skalabilitas rendah), ke metode berbasis machine learning dan deep learning (lebih baik dalam variasi leksikal tetapi membutuhkan data latih besar dan komputasi intensif), hingga era terkini dengan pemanfaatan Large Language Models (LLM) dan Retrieval-Augmented Generation (RAG) untuk menangani kompleksitas dan variasi data klinis secara lebih cerdas.

Pendekatan rule-based dan leksikal untuk mapping konsep memiliki kelebihan dengan aturannya yang transparan, mudah dilacak, tidak memerlukan data latih

yang tinggi dan dengan pola yang tervalidasi dapat menghasilkan akurasi tinggi, tetapi memerlukan waktu dan biaya pengembangan besar, rentan terhadap variasi bahasa (seperti sinonim, singkatan dan ekspresi informal), dan skalabilitas (adaptasi) rendah (T. Y. Kim, 2014; Meizoso dkk., 2011).

Kelemahan rule-based diatasi oleh pendekatan machine learning, tetapi ternyata memerlukan data latih berlabel dalam jumlah cukup dan memiliki ketergantungan pada kualitas fitur (Agrawal, 2018; Januel dkk., 2011). Sementara itu, mapping dengan pendekatan deep learning, terutama dengan transformer telah berhasil membuat automatic feature learning, dan dengan NER (Named Entity Recognition) telah mampu menangkap konteks semantik yang kompleks. Akan tetapi pendekatan ini memerlukan data latih yang sangat besar, komputasi intensif (daya komputasi tinggi) dan rentan terhadap bias data (Hristov dkk., 2021; Soriano dkk., 2019; X. Zhou dkk., 2024).

Meskipun NER merupakan komponen penting dalam pipeline pemrosesan bahasa klinis, ia harus diintegrasikan dengan metode lain seperti semantic similarity matching, knowledge graph retrieval, atau RAG berbasis LLM untuk mencapai pemetaan terminologi yang akurat, terkoneksi, dan siap interoperabilitas. Penelitian terkini pun mengonfirmasi bahwa pendekatan hybrid yang menggabungkan rule-based, NER, dan retrieval semantik memberikan hasil yang lebih robust, khususnya dalam konteks bahasa rendah sumber dan data klinis yang heterogen (L. Chen dkk., 2020; Gilani dkk., 2025; Pezoulas dkk., 2021).

Beberapa penelitian juga telah dilakukan dengan kombinasi pendekatan yang telah disebutkan sebelumnya. Salah satunya adalah penelitian yang menunjukkan keunggulan mapping berbasis ontologi (gabungan graph dan deep learning mapping terms ke konsep embeddings SNOMED CT) untuk akurasi semantik dan menunjukkan hasil yang lebih baik dari corpus-based untuk similarity & normalization (Zahra & Kate, 2024).

Penelitian lain dilakukan dengan mengembangkan metode transcoding LOINC yang mempertimbangkan hierarki dan korelasi antar komponen kode LOINC. Penelitian tersebut bukan hanya berupa klasifikasi multi-label sederhana, tetapi juga untuk meningkatkan akurasi dan efisiensi, sebagai alternatif hemat biaya bagi model bahasa yang sangat baik (Michel-Picque dkk., 2024).

Di sisi lain, tren penggunaan LLM juga mempengaruhi metode untuk mapping terminologi klinis. Evaluasi teknik prompt engineering pada LLM standar, fine-tuning, dan Retrieval-Augmented Generation (RAG) telah dilakukan untuk meningkatkan akurasi mapping terminology medis lokal ke SNOMED CT. Hasilnya menunjukkan bahwa GPT-4 terutama dengan RAG, jauh lebih baik dari baseline LLM

biasa, dan relevan untuk rumah sakit di negara non-Inggris seperti Korea (Huh, 2025). Meskipun demikian, masih terdapat kendala dalam specificity (misalnya, mapping terlalu umum). Penelitian tersebut menekankan potensi AI-human collaboration untuk standarisasi data kesehatan, dengan saran penelitian lanjutan untuk refine specificity dan validasi klinis.

Penelitian terkini menunjukkan bahwa pendekatan hibrida yang menggabungkan rule-based, NER, dan retrieval semantik memberikan hasil lebih robust, terutama untuk bahasa dengan sumber daya rendah dan data klinis heterogen (L. Chen dkk., 2020; Gilani dkk., 2025; Pezoulas dkk., 2021). Salah satu terobosan penting adalah CDE-Mapper (Gilani dkk., 2025) yang menggunakan LLM dan RAG untuk memetakan Clinical Data Elements (CDE) ke beberapa controlled vocabularies (SNOMED CT, LOINC, ICD-10, dll.). Hasil penelitiannya terbukti lebih unggul dari metode baseline, terutama untuk CDE composite. Namun, CDE-Mapper memiliki tiga keterbatasan utama yang menjadi celah penelitian (research gap) dan berhubungan langsung dengan kebutuhan konteks Indonesia.

Pertama, meskipun CDE-Mapper mampu memetakan ke banyak standar, mayoritas penelitian pemetaan terminologi klinis masih berfokus pada SNOMED CT saja, padahal interoperabilitas melalui SATUSEHAT menuntut pemetaan simultan ke SNOMED CT, LOINC, dan ICD-10 secara terpadu. Kedua, CDE-Mapper dirancang khusus untuk memproses item data spesifik (CDE) dan tidak dirancang untuk menangani teks panjang (long text) yang menjadi ciri khas dokumen rekam medis seperti catatan dokter, resume kepulangan, atau catatan perawatan. Dokumen semacam itu dapat berisi puluhan entitas klinis dalam kalimat kompleks, sehingga diperlukan integrasi modul long-text entity extraction (NER) berbasis LLM sebelum pemetaan. Ketiga, CDE-Mapper diuji pada teks bahasa Inggris. Untuk dapat diterapkan di Indonesia, seluruh komponen retrieval ensemble perlu disesuaikan dengan karakteristik linguistik bahasa Indonesia, keterbatasan sumber daya terminologi (ketersediaan SNOMED CT dan LOINC dalam bahasa Indonesia masih terbatas), serta variasi istilah lokal yang luas.

Penelitian terkini juga mengonfirmasi bahwa performa model canggih sekalipun dapat menurun secara signifikan saat menghadapi variasi leksikal atau saat diaplikasikan pada data non-Inggris (Gallifant dkk., 2024; Michel-Picque dkk., 2024; Rohizadeh dkk., 2025). Oleh karena itu, dibutuhkan pendekatan yang lebih efisien, ringan secara komputasi, namun tetap mampu menangani karakteristik linguistik dan terminologi spesifik bahasa Indonesia untuk memetakan istilah klinis lokal ke standar internasional (Gehrmann dkk., 2025; Huh, 2025). Situasi ini membuka peluang penelitian untuk mengembangkan solusi pemetaan yang diadaptasi khusus

untuk konteks Indonesia sehingga potensi interoperabilitas data kesehatan mencapai potensi penuhnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang, dapat dirumuskan beberapa permasalahan utama dalam pemetaan terminologi klinis untuk konteks interoperabilitas data klinis di Indonesia sebagai berikut.

1. Interoperabilitas data kesehatan menuntut pemetaan otomatis lintas standar. Namun, mayoritas penelitian fokus pada SNOMED CT, sehingga diperlukan pipeline terpadu untuk pemetaan ke SNOMED CT, LOINC, dan ICD-10 secara simultan.
2. CDE-Mapper (Gilani dkk., 2025) efektif untuk item data spesifik tetapi tidak menangani teks panjang rekam medis. Oleh karena itu, diperlukan integrasi modul *long-text entity extraction* (NER) berbasis LLM untuk memetakan seluruh CDE dari satu dokumen klinis.
3. CDE-Mapper diuji pada teks Inggris. Agar dapat diterapkan di Indonesia, komponen retrieval ensemble perlu disesuaikan untuk teks klinis bahasa Indonesia mengingat perbedaan linguistik, keterbatasan terminologi, dan variasi istilah lokal.

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan dan mengevaluasi sebuah framework adaptif untuk pemetaan terminologi klinis Bahasa Indonesia ke kosakata terkendali standar untuk mendukung interoperabilitas. Secara spesifik, tujuan penelitian adalah sebagai berikut.

1. Memodifikasi arsitektur CDE-Mapper agar mampu melakukan pemetaan simultan istilah klinis berbahasa Indonesia ke tiga standar terminologi sekaligus, yaitu SNOMED CT, LOINC, dan ICD-10.
2. Mengadaptasi CDE-Mapper dengan integrasi modul *long-text entity extraction* (NER) berbasis LLM untuk pengenalan data klinis dari teks panjang.
3. Membangun dan mengintegrasikan komponen retrieval ensemble dalam arsitektur CDE-Mapper agar mampu memproses teks klinis berbahasa Indonesia.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi berupa solusi yang lebih terjangkau dan praktis untuk standardisasi data klinis di Indonesia, mendukung integrasi data, penelitian translasional, dan pada akhirnya meningkatkan pelayanan kesehatan. Manfaat secara teoritis dan praktis adalah sebagai berikut.

1.4.1 Manfaat Teoritis

1. Memperluas arsitektur RAG klinis ke domain teks panjang, retrieval ensemble untuk bahasa Indonesia, dan pemetaan simultan multi-standar.
2. Memberikan advancements dalam *transfer learning* untuk *clinical domain* bahasa non-Inggris.
3. Memberikan kontribusi pada *theoretical framework* untuk *semantic interoperability* dalam healthcare.

1.4.2 Manfaat Praktis

1. Meningkatkan kualitas dan konsistensi data nasional.
2. Meningkatkan efisiensi dokumentasi klinis.
3. Memfasilitasi pertukaran data yang *meaningful* antar fasilitas kesehatan.
4. Mengurangi beban mapping manual bagi fasilitas kesehatan.
5. Meningkatkan akurasi *clinical decision support systems*.
6. Memungkinkan *real-world evidence research* berkualitas tinggi.
7. Mendukung *clinical trials* dan *observational studies*.
8. Memfasilitasi *clinical data sharing* untuk *research collaborations*.

BAB II

TINJAUAN PUSTAKA

2.1 FHIR dan *Clinical Terminology Mapping*

Fast Healthcare Interoperability Resources (FHIR) adalah standar interoperabilitas kesehatan dari HL7 yang memungkinkan banyak sistem untuk bertukar informasi kesehatan menggunakan model data yang disepakati. Standar ini dibuat oleh *Health Level Seven International* (HL7), yaitu sebuah organisasi *not-for-profit* yang berfokus pada upaya pemberdayaan interoperabilitas data pelayanan kesehatan yang diakui secara global. Informasi resmi mengenai standar ini tersedia pada <https://www.hl7.org/fhir/>.

HL7 FHIR merupakan standar terkini dalam pertukaran data dan informasi kesehatan, serta telah digunakan di berbagai negara termasuk oleh *World Health Organization* (WHO) dan berbagai fasilitas layanan kesehatan. Standar ini menggunakan fitur API yang sudah dikenal oleh pengembang sistem informasi, sehingga memudahkan pertukaran data dan mengurangi waktu pengaturan interoperabilitas antar sistem. Karakteristik tersebut mendorong perkembangan teknologi data layanan kesehatan yang lebih baik (Gazzarata dkk., 2024; Heryawan dkk., 2025).

Transformasi digital kesehatan nasional Indonesia yang diwujudkan melalui platform SATUSEHAT menghadapi tantangan mendasar dalam interoperabilitas semantik (Ayuningtyas dkk., 2025; Heryawan dkk., 2025). SATUSEHAT merupakan platform interoperabilitas data kesehatan di Indonesia yang memungkinkan informasi kesehatan dipertukarkan sewaktu-waktu antara tenaga medis yang berbeda, entitas lain yang berwenang, dan pasien, dalam kondisi aman, rahasia, serta tetap memperhatikan perlindungan data. Dalam laman resminya dijelaskan bahwa SATUSEHAT berada di bawah pengelolaan Kementerian Kesehatan Republik Indonesia dan juga mengacu pada FHIR, sebagaimana terdokumentasi pada <https://satusehat.kemkes.go.id/platform/docs/id/fhir/>. SATUSEHAT, dalam melakukan pertukaran data sesuai standar HL7 FHIR, bekerja menggunakan *grammar*; oleh karena itu diperlukan *vocabulary* yang mendukung.

Berikut ini standar terminologi yang digunakan pada SATUSEHAT Platform (SSP) (Ayuningtyas dkk., 2025).

- Keluarga ICD, yaitu:
 - ICD-10 (versi 2010), digunakan sebagai standar diagnosis;
 - ICD-9 CM (versi 2010), digunakan sebagai standar penamaan prosedur dan tindakan medis;

- ICD-O, digunakan sebagai standar pengkodean neoplasma atau kanker;
 - ICD-MM (versi 2012), digunakan untuk melakukan identifikasi kematian ibu; dan
 - ICD-PM (versi 2016), digunakan untuk melakukan identifikasi kematian perinatal.
- LOINC, digunakan sebagai standar penamaan uji laboratorium.
 - SNOMED CT, digunakan sebagai standar penamaan istilah klinis.
 - Kode Pembiayaan Tindakan dan Layanan Kesehatan Nasional (KPTL). KPTL merupakan terminologi yang disusun dengan mengumpulkan dan memperinci terminologi tindakan yang selama ini terbatas menunjuk kepada konsep klinis saja, namun mengabaikan informasi dan variasi-variasi tindakan yang berbeda dalam sudut pandang biaya.

Heterogenitas representasi konsep klinis antara terminologi lokal dan standar internasional, seperti SNOMED CT, LOINC, dan ICD-10, menciptakan kesenjangan semantik yang menghambat pertukaran data bermakna (Januel dkk., 2011; Sathappan dkk., 2021). Analisis implementasi SATUSEHAT menunjukkan dominasi SNOMED CT untuk data klinis dan LOINC untuk laboratorium, namun adopsi terminologi lokal tetap signifikan, sehingga menciptakan kompleksitas yang unik dalam adaptasi konteks lokal (Ayuningtyas dkk., 2025). Lebih lanjut, pemetaan data rekam medis elektronik ke terminologi standar diidentifikasi sebagai salah satu *pain point* utama dalam implementasi teknis platform (Heryawan dkk., 2025).

Secara global, integrasi data klinis dari berbagai sumber merupakan tantangan kritis dalam informatika kesehatan (T. Y. Kim, 2014; Meizoso dkk., 2011). Pemetaan konsep klinis ke kosakata terkendali seperti SNOMED CT atau terminologi medis lainnya menjadi langkah fundamental untuk harmonisasi data dan penelitian biomedis (Agrawal, 2018; Seong dkk., 2021; Utter dkk., 2018).

2.2 Evolusi Metode Terkait *Clinical Terminology Mapping*

Evolusi algoritma pemetaan terminologi telah bergerak dari pendekatan berbasis aturan manual (Bidgood, 1998; Michel dkk., 2011) menuju pendekatan *hybrid* yang menggabungkan teknik *rule-based* dengan metode statistik (Khare dkk., 2012; Ruch dkk., 2008), kemudian mengalami revolusi melalui *word embeddings* dan model bahasa kontekstual (Banerjee dkk., 2018; H. K. Kim dkk., 2020), hingga memasuki era terkini yang didominasi oleh *Large Language Models* (LLMs) dan teknik *few-shot learning* (De Barros Vanzin dkk., 2025; Tu dkk., 2022).

Bidang *clinical terminology mapping* telah mengalami evolusi cepat dari metode sederhana berbasis aturan menuju ekosistem yang lebih canggih dengan memanfaatkan AI, *knowledge graph*, dan LLM. Pola umum menunjukkan pergeseran menuju interoperabilitas semantik yang lebih dalam dan skalabilitas lintas platform. Tren ini merefleksikan percepatan inovasi, dengan fokus terkini pada kemampuan generalisasi, efisiensi komputasi, dan adaptasi konteks lokal, yang menandakan fase matang menuju implementasi klinis yang lebih luas dan lebih otomatis.

Studi empiris telah banyak dilakukan terkait penerapan dan evaluasi metode *mapping* pada dataset dunia nyata seperti *Electronic Health Records* (EHR), dataset publik seperti MIMIC-IV, maupun data penelitian spesifik seperti Alzheimer dan kardiologi. Evaluasi juga dilakukan menggunakan metrik kuantitatif seperti akurasi, *F-score*, AUC, dan *coverage analysis*. Beberapa studi turut melibatkan validasi oleh ahli klinis atau penggunaan dataset multi-institusi untuk menguji generalisasi.

Pola umum pada *clinical terminology mapping* teramati sebagai berikut.

1. **Multi-standard mapping.** Penelitian tidak terpaku pada satu standar, tetapi melakukan pemetaan antar-standar, misalnya dari SNOMED CT ke LOINC atau ICD, dari FHIR ke OMOP, dan dari EHR ke CDISC.
2. **Dari manual ke otomatis.** Pergeseran terjadi dari metode *rule-based* dan kurasi manual menuju pendekatan berbasis *machine learning*, NLP, dan AI yang dapat dipelajari dari data.
3. **Dari struktural ke semantik.** Evolusi tampak dari *mapping* berbasis sintaks atau kata kunci menuju pendekatan semantik berbasis *embedding* dan *knowledge graph* yang lebih memahami makna dan konteks klinis.
4. **Domain-specific tailoring.** *Mapping* semakin disesuaikan dengan kebutuhan spesialisasi klinis, seperti oftalmologi, mikrobiologi, dan neurologi, serta konteks lokal seperti bahasa dan regulasi.

Perkembangan penelitian mengenai *clinical terminology mapping* dalam kurun waktu 2018–2025 disajikan dalam Tabel 2.1.

Tabel 2.1: Tren penelitian *clinical terminology mapping*

Periode	Tren Dominan	Contoh Studi Kunci
2018–2019	Hierarki dan <i>rule-based</i> — pendekatan berbasis hierarki SNOMED CT dan aturan logika Boolean untuk definisi kondisi klinis dan <i>value sets</i> .	(Chu dkk., 2019; Hong dkk., 2019; Willett dkk., 2018)
2020–2021	ML dan NLP dasar — otomatisasi <i>mapping</i> dengan model <i>machine learning</i> tradisional dan NLP untuk teks klinis.	(Ferté dkk., 2021; Hristov dkk., 2021; Kate, 2020; Latip dkk., 2021)
2022–2023	<i>Knowledge graph</i> dan integrasi lintas standar — integrasi data multi-sumber menggunakan <i>knowledge graph</i> dan harmonisasi model data seperti FHIR dan OMOP.	(Xiao dkk., 2022; D. Zhou dkk., 2022)
2024	Transformer dan embedding canggih — adopsi <i>sentence transformer</i> , <i>graph-based embeddings</i> , dan <i>classifier chains</i> untuk akurasi tinggi.	(Michel-Picque dkk., 2024; Zahra & Kate, 2024; X. Zhou dkk., 2024)
2025	LLM dan RAG — pemetaan dengan model bahasa besar yang diperkaya konteks, serta adopsi standar di tingkat nasional.	(Ayuningtyas dkk., 2025; Gilani dkk., 2025; Z. Wang dkk., 2025)

Berikut ini adalah penjelasan evolusi metode untuk *mapping* terminologi klinis.

2.2.1 Pendekatan Berbasis Aturan dan Hierarki

Metode pemetaan (*mapping*) terminologi klinis berkembang pesat dimulai dari penggunaan metode *rule-based* pada berbagai penelitian. Salah satu contohnya adalah pendekatan yang mengombinasikan pencocokan leksikal dan pencocokan berbasis struktur untuk memetakan *observation archetypes* dari openEHR ke konsep SNOMED CT secara otomatis (Meizoso dkk., 2011). Penelitian ini dimaksudkan untuk mendukung interoperabilitas antara struktur *data entry* klinis dan terminologi standar, serta membantu pembangunan *archetype* yang terikat terminologi. Metode tersebut menemukan adanya kesamaan semantik antara struktur pohon *archetype*,

seperti `ITEM.LIST`, `ELEMENT`, `QUANTITY`, dan `CODED.TEXT`, dengan relasi *is-a* dan *interprets* di SNOMED CT. Meskipun hasil penelitian menunjukkan presisi sekitar 94% dan dapat mengurangi pemetaan manual, *recall* masih berada pada kisaran 69%, yang menunjukkan masih banyak konsep yang tidak terpetakan (*false negative*).

Penggunaan *rule-based* yang lebih kompleks juga telah dilakukan, misalnya untuk memetakan kode klaim farmasi dari *National Health Insurance* (NHI) Korea Selatan ke SNOMED CT, terutama ke hierarki *Pharmaceutical/biologic product*, untuk memfasilitasi penelitian kolaboratif multisenter dan interoperabilitas semantik (Jung dkk., 2022). Pendekatan ini memanfaatkan *terminology server* berbasis pencarian terstruktur dan menerapkan beberapa aturan normalisasi untuk mengklasifikasikan korelasi menjadi *exact match*, *broader match*, dan *missing*. Hasil pemetaan divalidasi secara internal oleh terminolog dan apoteker. Hasilnya menunjukkan sekitar 50,6% *exact match*, 49,3% *broader match*, dan masih terdapat sejumlah kode yang tidak terpetakan, misalnya untuk obat lokal Korea. Temuan ini menunjukkan keterbatasan cakupan SNOMED CT internasional terhadap istilah lokal. Di sisi lain, studi ini memperlihatkan bahwa pendekatan berbasis aturan dapat memberikan tingkat kesepakatan antarpemetaan yang cukup tinggi, tetapi implementasinya sangat bergantung pada ketersediaan kode klaim yang telah terstruktur dan bukan teks bebas.

Meskipun *rule-based* merupakan metode yang tergolong sederhana, pendekatan ini masih terus digunakan dalam penelitian, misalnya untuk *mapping* diagnosis dermatologi berbentuk teks bebas dan tidak terstruktur (Sitaru dkk., 2024). Pada penelitian tersebut, metode yang digunakan memanfaatkan tabel sinonim, *fuzzy string matching* yang disempurnakan dengan pembobotan menggunakan koefisien Sørensen-Dice, aturan normalisasi, serta skor kepercayaan untuk setiap pemetaan yang dihasilkan. Hasil evaluasi menunjukkan akurasi keseluruhan pada kisaran 75,5% sampai 81,5%. Pendekatan ini unggul karena transparan dan *explainable*, mudah di-*debug*, mudah diperluas melalui pembaruan tabel sinonim, dan tidak memerlukan data *training* atau GPU. Walaupun demikian, metode ini tetap menunjukkan kelemahan berupa kesulitan memahami konteks dalam teks, yang dapat berakibat pada kesalahan pemetaan, serta ketidakmampuan mengenali kata dengan *typo* secara andal.

Penerapan *rule-based* pada berbagai penelitian tersebut menunjukkan bahwa meskipun metode ini tidak kompleks dan tidak memerlukan sumber daya komputasi tinggi, pemahaman terhadap konteks kata atau kalimat tetap terbatas. Oleh karena itu, pendekatan ini pada praktiknya sering perlu dikombinasikan dengan metode

lain untuk meningkatkan akurasi pemetaan.

2.2.2 Otomatisasi *Mapping* dengan Model *Machine Learning* Tradisional dan NLP untuk Teks Klinis

Salah satu kekurangan metode *rule-based* untuk *mapping* terminologi medis adalah kurang mumpuni dalam menangani variasi bahasa alami seperti sinonim, singkatan, dan *typo*, yang justru sering muncul dalam teks klinis. Selain itu, pendekatan *rule-based* dan *machine translation* untuk pemetaan lintas bahasa, misalnya Mandarin–Inggris, juga dapat memiliki akurasi rendah karena perbedaan struktur linguistik (Y. Chen dkk., 2022). Perbaikan metode untuk keperluan *mapping* kemudian bergeser kepada penggunaan *machine learning* (ML) dan eksplorasi *natural language processing* (NLP).

Evaluasi terhadap *pipeline* normalisasi data klinis berbasis FHIR yang dapat menstandarkan data EHR tidak terstruktur dan mengintegrasikannya dengan data terstruktur telah dilakukan dengan menerapkan ML dan NLP (Hong dkk., 2019). Penelitian ini mengintegrasikan cTAKES untuk ekstraksi entitas, MedXN untuk ekstraksi obat ke RxNorm, dan MedTime untuk informasi temporal, serta menggunakan 30 *mapping rules* dan 62 *normalization rules* untuk memetakan keluaran NLP ke elemen FHIR. Hasilnya menunjukkan bahwa *pipeline* yang dikembangkan, yaitu NLP2FHIR, tidak menyebabkan penurunan kinerja dibandingkan *tools* NLP asli. Nilai *F-score* berada pada rentang 0,69–0,99 untuk berbagai elemen FHIR, dan *negated modifier* mencapai *F-score* 0,995. Meskipun demikian, masih terdapat kesenjangan semantik antara keluaran *NLP tools* dan spesifikasi FHIR, serta *terminology binding* masih dilakukan secara manual.

Penelitian untuk mengonversi istilah klinis menjadi konsep SNOMED CT secara lengkap, termasuk mendukung konsep *post-coordinated*, dilakukan oleh Kate (2020) dengan mempelajari probabilitas dari data SNOMED CT. Langkah penelitian ini meliputi penentuan jenis konsep dalam teks, pencarian konsep yang paling sesuai, dan pembentukan konsep keluaran berupa kumpulan relasi serta konsep terkait yang teridentifikasi. Metode ini tidak memerlukan anotasi manual, tetapi langsung “belajar” dari SNOMED CT, sehingga relatif cepat, dapat diskalakan, transparan, dan mampu mendeteksi relasi yang hilang atau *semantic type* yang salah. Meskipun demikian, evaluasi menunjukkan bahwa *full conversion rate* masih rendah, yaitu sekitar 32%, dengan kesalahan umum pada *body structure*. Selain itu, metode ini tidak memanfaatkan informasi urutan kata atau sintaksis karena masih berbasis *bag-of-words* dan belum mampu menangani *nested relations*.

Pengembangan sistem *end-to-end* yang secara otomatis mengubah deskripsi

masalah klinis dalam bentuk teks bebas menjadi ekspresi SNOMED CT terstruktur juga telah dievaluasi dengan membandingkan penggunaan BiLSTM, CNN, dan Naive Bayes (Peterson & Liu, 2020). *Pipeline* pada penelitian ini terdiri dari tiga tahap berurutan, yaitu: (1) ekstraksi konsep menggunakan MetaMap untuk mengekstraksi konsep UMLS dan mencocokkannya dengan SNOMED CT; (2) pemilihan fokus konsep menggunakan *dependency parsing* dengan spaCy dan scispaCy; serta (3) identifikasi relasi menggunakan model *deep learning*, seperti BiLSTM dan CNN, dengan ClinicalBERT sebagai *embedding*, pada data latih lebih dari 1,5 juta catatan untuk 78 tipe relasi. Hasil evaluasi menunjukkan bahwa BiLSTM sedikit lebih unggul dari CNN, terutama pada *macro-F1*. *Fine-tuning* pada *dependency parser* juga dapat meningkatkan akurasi penentuan fokus dari sekitar 75% menjadi 91%. Namun, variasi nilai F1 pada data klinis nyata yang sangat lebar menunjukkan bahwa model masih belum mampu menangani teks klinis dunia nyata secara stabil.

Pemanfaatan *deep learning* untuk *encoding* otomatis ke dalam terminologi klinis, terutama SNOMED CT, juga dikerjakan pada data yang tidak seimbang dan anotasi terbatas. Dengan tujuan mencapai akurasi tinggi untuk pengkodean SNOMED CT pada teks klinis, terutama pada penyakit onkologis dan penyakit langka, Hristov dkk. (2021) mengembangkan *pipeline* multi-tahap yang menggabungkan: (1) *automatic dataset generation* dari sumber data publik dan *linked open data*; (2) *label clustering* untuk mengurangi kompleksitas klasifikasi; (3) *multi-cluster classification* dengan *fine-tuning* BioBERT; dan (4) *clusters-to-labels refinement* menggunakan *one-vs-all SVM* per klaster. Hasil evaluasi menunjukkan bahwa pendekatan ini secara signifikan lebih unggul dari *state-of-the-art*, baik dari segi akurasi maupun cakupan SNOMED CT. Meskipun demikian, karena tidak menggunakan data klinis nyata, performa model pada lingkungan produksi masih perlu diuji lebih lanjut.

Pemetaan terminologi klinis lintas bahasa juga merupakan tantangan tersendiri karena adanya perbedaan struktur bahasa dan istilah lokal yang tidak tersedia pada konsep baku di SNOMED CT, terlebih untuk bahasa yang sangat berbeda dari bahasa Inggris, seperti bahasa Mandarin. Bahasa Mandarin memiliki karakteristik unik, yaitu tidak adanya spasi pemisah kata, setiap karakter memiliki makna, dan tidak adanya penanda morfologis yang jelas. Penelitian untuk menghasilkan model *deep learning* yang dapat melakukan pencocokan semantik langsung antara teks Mandarin dan deskripsi SNOMED CT bahasa Inggris tanpa melalui mesin penerjemah dilakukan dengan memanfaatkan mekanisme *attention* untuk menangkap hubungan semantik lintas bahasa (Y. Chen dkk., 2022). Model ini terdiri atas lima lapisan utama, yaitu *input*, *word embedding*, *encoder* (BiLSTM dan *self-attention*),

decomposable attention, dan *output*. Hasil evaluasi menunjukkan bahwa kombinasi BiLSTM, *self-attention*, *decomposable attention*, dan BERT memiliki kinerja terbaik pada pencocokan lintas bahasa tanpa terjemahan. Penelitian ini menunjukkan kelayakan *cross-lingual semantic matching* tanpa penerjemah, tetapi dataset yang digunakan masih terbatas pada pasangan istilah dan belum diuji pada data klinis nyata yang panjang.

2.2.3 Integrasi Data Multi-Sumber Menggunakan *Knowledge Graph* dan Harmonisasi Model Data

Perkembangan penggunaan *knowledge graph* (KG) untuk pemetaan terminologi klinis didasari oleh kebutuhan interoperabilitas data kesehatan skala besar, *explainable AI*, dan harmonisasi lintas institusi, yang belum dapat dipenuhi secara optimal oleh metode ML, DL, atau NLP sederhana.

Salah satu penelitian pada arah ini bertujuan mengembangkan sistem yang mampu membangun *clinical knowledge graphs* (CKGs) dari basis data OMOP CDM yang sesuai dengan standar FHIR RDF (Xiao dkk., 2022). Penelitian ini menjembatani kesenjangan antara data relasional yang tersimpan dalam format OMOP dengan kebutuhan representasi data yang semantik, terstandar, dan dapat diproses mesin berbasis FHIR. Arsitektur yang digunakan terdiri atas tiga lapisan utama, yaitu: (1) modul masukan yang memanfaatkan basis data OMOP, ontologi model FHIR, dan pemetaan OMOP–FHIR; (2) modul generasi CKG yang menggunakan sistem Ontop untuk menerjemahkan kueri SPARQL menjadi SQL; dan (3) modul kueri semantik berupa *endpoint* SPARQL yang dilengkapi kemampuan *reasoning*. Penelitian ini juga menggunakan *FHIR Model Ontology*, *Shape Expressions* (ShEx), dan Ontop *Virtual Knowledge Graph* untuk menghindari materialisasi *triple* secara penuh. Hasil evaluasi menunjukkan bahwa RDF *triples* untuk 100 pasien sepenuhnya *compliant* dengan spesifikasi FHIR RDF ShEx. Namun, pemetaan yang dihasilkan masih bersifat awal karena masih banyak elemen FHIR yang belum dipetakan secara lengkap dan validasinya masih terbatas pada dataset MIMIC-III OMOP.

Penelitian lain yang bertujuan mengatasi masalah harmonisasi data EHR lintas institusi akibat perbedaan kode dan praktik dokumentasi dilakukan dengan mengembangkan algoritma MIKGI (*Multiview Incomplete Knowledge Graph Integration*) yang menghasilkan vektor *embedding* terharmonisasi untuk kode EHR dari beberapa institusi (D. Zhou dkk., 2022). Penelitian ini menggabungkan dua sumber informasi, yaitu deskripsi teks kode melalui SapBERT dan pola *co-occurrence* kode dalam EHR melalui SPPMI-SVD. *Embedding* yang dihasilkan memungkinkan

deteksi konsep serupa, pemetaan kode lintas institusi, dan seleksi fitur untuk studi penyakit seperti COVID-19.

Kelebihan model yang digunakan dalam penelitian ini antara lain: (1) menggabungkan dua sumber informasi yang saling melengkapi, yaitu semantik teks dan relasi praktik klinis; (2) hanya memerlukan data ringkasan sehingga lebih aman untuk privasi; (3) dapat diperbarui secara inkremental ketika muncul konsep baru; (4) skalabel ke banyak institusi; (5) memiliki performa yang robust; dan (6) mendukung *semi-automated mapping*. Namun, hasil penelitian juga menunjukkan bahwa performa *unsupervised* untuk laboratorium masih terbatas, terutama karena deskripsi lab lokal sering ambigu atau tidak standar. Selain itu, model ini tetap memerlukan *hyperparameter tuning* dan masih bergantung pada kualitas SapBERT.

2.2.4 Adopsi Sentence Transformer, Graph-Based Embeddings, dan Classifier Chains untuk Akurasi Tinggi

Keterbatasan metode ML dan DL untuk *mapping* mendorong pergeseran ke arah pendekatan yang memanfaatkan *sentence transformer*, *graph-based embeddings*, dan *classifier chains* untuk mencapai akurasi yang lebih tinggi.

Salah satu penelitian penting dalam arah ini dilakukan oleh Zahra dan Kate (Zahra & Kate, 2024) untuk mengatasi keterbatasan *corpus-based word embeddings* seperti Word2Vec, GloVe, dan BERT. Permasalahan utamanya adalah istilah klinis yang jarang muncul sering kali memiliki *embedding* yang buruk bila hanya dipelajari dari korpus. Pada penelitian tersebut, mereka mengusulkan pembentukan *clinical term embeddings* langsung dari ontologi SNOMED CT, bukan dari korpus teks. Dengan pendekatan ini, *SNOMED CT embeddings* dilaporkan mengungguli semua *corpus-based embeddings* yang dibandingkan pada dataset yang digunakan. Evaluasi juga menunjukkan kinerja yang kompetitif pada tugas *clinical term normalization* bahkan tanpa pelatihan khusus untuk tugas tersebut. Meskipun demikian, pendekatan ini sangat bergantung pada kualitas dan kelengkapan relasi di SNOMED CT. Selain itu, proses normalisasi dengan *embeddings* tetap memerlukan perbandingan kemiripan dengan banyak istilah di UMLS, sehingga kurang praktis untuk aplikasi *real-time* berskala besar.

Zhou (X. Zhou dkk., 2024) membandingkan *sentence-transformer* berukuran lebih kecil dengan LLM yang jauh lebih besar dan menunjukkan bahwa *sentence-transformer* yang di-*fine-tune* dengan baik dapat lebih cepat dan lebih akurat untuk tugas *mapping* obat. Hal ini menunjukkan bahwa model transformer yang lebih kecil tetapi lebih terarah kadang justru lebih efektif daripada model yang lebih besar. Pendekatan ini menghasilkan *embeddings* yang lebih ekspresif untuk perbandingan

semantik, yang merupakan inti dari tugas pemetaan terminologi.

Ketersediaan model transformer yang telah dilatih pada data medis dalam berbagai bahasa juga mempercepat pengembangan sistem dan meningkatkan performa untuk tugas klinis. X. Zhou dkk. (2024) menggunakan model seperti BioLORD dan GatorTron sebagai *backbone*, serta membandingkannya dengan model yang lebih besar. Michel-Picque dkk. (Michel-Picque dkk., 2024) menggunakan CamemBERT dan DrBERT untuk konteks bahasa Prancis. Di sisi lain, Zahra dan Kate (Zahra & Kate, 2024) menemukan bahwa ClinicalBERT tidak selalu lebih baik pada tugas *clinical term similarity* karena model tersebut lebih efektif ketika menerima konteks kalimat, bukan istilah tunggal. Temuan ini menunjukkan bahwa pemilihan model harus disesuaikan dengan karakteristik tugas *mapping* yang dihadapi.

2.2.5 LLM dan *Retrieval-Augmented Generation* (RAG)

Pergeseran dari arsitektur transformer standar, seperti BERT, RoBERTa, dan *sentence-transformer*, menuju *Large Language Models* (LLMs) dan *Retrieval-Augmented Generation* (RAG) bukanlah pergeseran yang tiba-tiba, melainkan respons terhadap keterbatasan mendasar dari model transformer yang berdiri sendiri. Transformer merupakan fondasi yang baik untuk representasi semantik, tetapi tidak selalu cukup untuk tugas *concept linking* di dunia nyata yang membutuhkan pengetahuan terminologi yang luas, selalu berubah, dan kemampuan menangani struktur komposit. RAG bersama LLM menjawab kebutuhan tersebut dengan menggabungkan *retrieval* yang bersifat non-parametrik dan *generation* yang bersifat parametrik.

Beberapa penelitian menunjukkan bahwa LLM seperti GPT-4, Llama 3.1, dan GPT-4o-mini memiliki kemampuan *reasoning* dan pemahaman konteks yang lebih baik daripada transformer yang digunakan secara terpisah. Namun, LLM murni juga memiliki kelemahan besar berupa halusinasi, keterbatasan pengetahuan domain, dan biaya komputasi yang tinggi.

Memperhatikan celah tersebut, dikembangkan kerangka kerja CDE-Mapper yang menggunakan LLM dan RAG untuk secara otomatis menghubungkan *clinical data elements* (CDE), baik atomik maupun komposit, ke terminologi terkontrol seperti SNOMED CT, LOINC, ICD, ATC, dan RxNorm dalam OMOP CDM (Gilani dkk., 2025). Modul yang digunakan dalam penelitian ini meliputi: (1) *knowledge base creation*, yaitu bagian yang memperkaya setiap konsep dalam *controlled vocabularies* dengan sinonim tambahan; (2) *query decomposition*, yang menggunakan LLM untuk memecah CDE komposit menjadi komponen-komponennya dalam format JSON terstruktur; (3) *ensemble retrieval*, yang menggabungkan SPLA-

DE dan SapBERT; (4) *knowledge filter*, yang menyaring kandidat berdasarkan *threshold similarity* dan aturan metadata; (5) *two-step reranking*, di mana LLM memberi skor relevansi dan mengklasifikasikan kandidat ke kategori relevansi tertentu serta menerapkan *self-consistency prompting*; dan (6) *knowledge reservoir*, yang menyimpan pasangan label dan konsep tervalidasi untuk digunakan kembali guna mengurangi waktu inferensi.

Gilani dkk. (Gilani dkk., 2025) menggunakan empat dataset untuk evaluasi, yaitu BC5CDR-D, NCBI-DC, MIID, dan HF Studies, dengan SapBERT, KRISS BERT, BioBERT-SNOMED, dan PromptLink sebagai *baseline*. Hasil evaluasi menunjukkan bahwa penggunaan LLM dan RAG secara keseluruhan unggul dibandingkan *baseline*. Kelemahan utama pendekatan ini adalah biaya komputasi inferensi yang signifikan dan kebutuhan rekayasa prompt agar hasil berkualitas. Keterbatasan lain terletak pada kemampuan menangani negasi dan temporalitas, karena CDE-Mapper belum secara eksplisit memodelkan konteks seperti “tidak ada riwayat” atau “masa lalu” dan “saat ini”.

Penelitian lain dilakukan oleh Yu dkk. untuk membandingkan performa ChatGPT-4.0, Gemini, dan Perplexity pada tugas *mapping* ke kode LOINC untuk tes laboratorium menggunakan *zero-shot prompting* tanpa *retrieval* (Yu dkk., 2026). Hasil evaluasi menunjukkan bahwa performa *complete match* masih lebih rendah daripada pendekatan yang menggunakan konteks tambahan. Temuan ini mempertegas bahwa LLM saja sering belum cukup dan masih memerlukan RAG atau konteks tambahan seperti metode pemeriksaan, spesimen, dan unit.

Kinerja LLM dengan RAG juga ditunjukkan oleh penelitian Huh (Huh, 2025) untuk pemetaan istilah diagnosis lokal dari rumah sakit di Korea ke SNOMED CT. Penelitian ini membandingkan empat pendekatan, yaitu *baseline*, *prompt engineering*, *fine-tuning*, dan RAG. Hasil evaluasi menunjukkan bahwa RAG mencapai *valid match* 96,2% dan *exact match* 57,6%, serta secara konsisten melampaui pendekatan lain. Namun, model ini masih memiliki kelemahan pada tingkat *specificity*, yaitu kecenderungan memilih konsep yang terlalu umum.

Kinerja arsitektur berbasis RAG pada terminologi skala besar juga ditunjukkan oleh penelitian Vanzin dkk. (De Barros Vanzin dkk., 2025). Penelitian ini berfokus pada penerapan RAG untuk *vocabulary mapping* skala besar dan menunjukkan adanya *trade-off*. Pipeline RAG dengan *filtering* multi-tahap cenderung lebih presisi, sedangkan pendekatan agen dengan *dynamic query refinement* lebih unggul pada *recall*. Penelitian ini menegaskan bahwa RAG lebih praktis karena dapat menggunakan LLM *open-source*, sedangkan pendekatan agen membutuhkan model dengan kemampuan *tool-calling*. Hasil evaluasi menunjukkan bahwa RAG mengungguli

baseline berbasis *nearest embedding* pada subset obat, sementara pendekatan agen unggul pada *recall*. Temuan ini menegaskan bahwa pemilihan arsitektur bergantung pada prioritas antara presisi, *recall*, biaya, dan kompleksitas implementasi.

Perkembangan metode pemetaan terminologi klinis menunjukkan pergeseran signifikan dari pendekatan leksikal manual menuju pemanfaatan model bahasa skala besar. Berbagai penelitian telah mengevaluasi efektivitas metode-metode tersebut, mulai dari model berbasis transformer hingga integrasi RAG. Perbandingan komprehensif mengenai karakteristik, keunggulan, serta keterbatasan utama dari masing-masing metode dirangkum dalam Tabel 2.2.

Tabel 2.2: Perbandingan metode *clinical terminology mapping* dan keterbatasannya

Kategori Metode	Teknik Utama	Kelebihan	Kelemahan
<i>Manual & rule-based</i>	<i>Expert review, lexical matching</i>	Akurasi tinggi karena divalidasi pakar.	Sangat lambat, tidak skalabel, dan sulit menangani sinonim yang kompleks.
<i>Machine learning klasik</i>	<i>SVM, Random Forest</i>	Lebih cepat daripada manual untuk dataset besar.	Membutuhkan <i>feature engineering</i> yang rumit dan performanya menurun pada terminologi yang sangat spesifik.
<i>Deep learning & word embedding</i>	Word2Vec, FastText, BERT	Mampu menangkap konteks semantik antarkata.	Membutuhkan data latih yang sangat besar dan sering kali bersifat <i>black box</i> .
<i>Large Language Models (LLM)</i>	GPT-4, model medis umum	Sangat baik dalam memahami bahasa alami dan konteks medis.	Berisiko mengalami halusinasi medis dan masih memiliki keterbatasan pada istilah medis lokal.

Tabel 2.3 merangkum performa terukur dari empat metode representatif yang

mewakili evolusi dari *rule-based* hingga LLM dengan RAG, disertai dengan kelemahan utama yang masih belum teratasi.

Tabel 2.3: Perbandingan kuantitatif metode pemetaan terminologi klinis representatif

Metode	Dataset (Bahasa)	Akurasi / Performa	Kelemahan Utama
<i>Rule-based</i> (Sitaru dkk., 2024)	Dermatologi (Jerman)	75,5%–81,5%	Tidak menangani <i>typo</i> dan konteks kalimat.
BiLSTM + ClinicalBERT / <i>deep learning</i> (Hristov dkk., 2021; Peterson & Liu, 2020)	Teks klinis nyata (Inggris)	F1 bervariasi 0,22–0,97 pada data klinis nyata; performa tinggi pada data terkontrol	Performa tidak stabil pada data tidak terstruktur dan dunia nyata.
CDE-Mapper (Gilani dkk., 2025)	NCBI-DC, BC5CDR-D, MIID, HF Studies (Inggris)	Akurasi tinggi, misalnya 94,4% pada NCBI-DC	Tidak dirancang untuk teks panjang, melainkan fokus pada <i>single CDE</i> .
GPT-4 + RAG (Huh, 2025)	Data rumah sakit (Korea)	<i>Valid match</i> 96,2%; <i>exact match</i> 57,6%	<i>Specificity</i> rendah sehingga pemetaan kadang terlalu umum.

Dari Tabel 2.3, terlihat bahwa pendekatan berbasis aturan memberikan akurasi yang moderat namun rapuh terhadap variasi bahasa; *deep learning* menjanjikan tetapi tidak stabil pada data klinis nyata; CDE-Mapper mencapai akurasi sangat tinggi namun hanya untuk input pendek berbahasa Inggris; sementara GPT-4 dengan RAG berhasil diterapkan pada bahasa non-Inggris, tetapi masih mengalami kendala tingkat generalisasi konsep. Temuan ini secara langsung memandu kebutuhan adaptasi yang akan diuraikan pada sub-bab identifikasi kesenjangan penelitian.

2.3 Penelitian Tentang Terminologi Kesehatan di Indonesia

Dalam konteks Indonesia, implementasi interoperabilitas medis sudah dilakukan misalnya dengan membangun SATUSEHAT sebagai *backbone* arsitekturnya, tetapi *mapping terminology* medis sebagai syarat utama interoperabilitas belum dilakukan secara otomatis, sebagaimana dibahas oleh Ayuningtyas (Ayuningtyas dkk., 2025) berikut.

2.3.1 Adaptasi Terminologi Standar di SATUSEHAT

Dalam penelitian berjudul *Bringing Interoperability into Action: Adoption of Health Terminology Standard in Indonesia*, Ayuningtyas (Ayuningtyas dkk., 2025) melakukan analisis kuantitatif-deskriptif terhadap dokumen kebijakan resmi interoperabilitas kesehatan di Indonesia. Sumber data utama studi ini adalah pedoman implementasi interoperabilitas yang diterbitkan oleh Kementerian Kesehatan Indonesia pada 30 November 2024. Unit analisis mencakup variabel-variabel data yang didefinisikan dalam lima *use case*, yaitu pelayanan kehamilan, tuberkulosis, *Pelaporan Kematian Ibu dan Perinatal*, vaksinasi COVID-19, dan skrining serta *testing* HIV.

Proses analisis dilakukan melalui beberapa tahap sistematis: pertama, mengekstraksi variabel dan terminologi dari pedoman ke dalam basis data; kedua, mengategorikan dan menghitung kode untuk setiap standar terminologi, termasuk SNOMED CT, LOINC, ICD-10, ICD-9-CM, KFA, serta terminologi lokal; dan ketiga, menghitung *mapping success rate* yang merepresentasikan persentase konsep yang berhasil dipetakan ke standar internasional. Metodologi ini memiliki kelebihan dalam memberikan gambaran resmi dan terstruktur mengenai implementasi yang diharapkan secara normatif, sekaligus memungkinkan kuantifikasi penggunaan relatif berbagai standar. Namun, studi ini juga memiliki keterbatasan signifikan karena hanya menganalisis aspek *de jure* (“apa yang diatur dalam pedoman”) dan belum mencakup aspek *de facto* (“apa yang benar-benar diadopsi di lapangan”). Penulis sendiri menyadari keterbatasan ini dan merekomendasikan penelitian lanjutan menggunakan data produksi sesungguhnya untuk mengukur adopsi riil dalam praktik klinis sehari-hari (Ayuningtyas dkk., 2025).

Temuan Ayuningtyas mengenai standar terminologi medis adalah sebagai berikut.

1. **Dominasi SNOMED CT dan LOINC.** SNOMED CT paling banyak digunakan untuk data klinis, terutama pada pelaporan kematian ibu dan perinatal, sedangkan LOINC mendominasi untuk data laboratorium pada *use case* tuberkulosis dan pelayanan kehamilan. Hal ini sesuai dengan cakupan masing-masing standar.
2. **Peran kritis terminologi lokal.** Temuan paling signifikan adalah tingginya penggunaan terminologi lokal, yakni 315 konsep, bahkan melebihi penggunaan SNOMED CT yang berjumlah 266 konsep. *Mapping success rate* ke standar internasional hanya 62,3%, menunjukkan bahwa konteks lokal Indonesia belum sepenuhnya terakomodasi oleh standar internasional.

3. **Kesenjangan semantik.** Artikel tersebut menunjukkan jenis-jenis konsep yang membutuhkan terminologi lokal, seperti klasifikasi program imunisasi khas Indonesia, jenis makanan tambahan, hingga istilah-istilah klinis spesifik yang belum ada padanannya dalam SNOMED CT atau LOINC.

Penelitian ini bertujuan untuk *mengidentifikasi masalah ini* dan *mengusulkan kerangka solusinya*, yang membuka peluang besar bagi penelitian lanjutan di bidang NER dan *automated semantic linking* untuk kesehatan Indonesia. Temuan tersebut juga sejalan dengan pembahasan bahwa pemetaan data rekam medis elektronik ke terminologi standar masih menjadi salah satu *pain point* utama dalam implementasi teknis SATUSEHAT (Heryawan dkk., 2025).

2.3.2 Penelitian Terkait *BioNER* di Indonesia

Penelitian terkait pemanfaatan NER dalam bidang medis secara aktif telah dilakukan oleh Diana Purwitasari dkk. Salah satu penelitiannya membandingkan kinerja beberapa model transformer dan BiLSTM untuk NER (Purwitasari dkk., 2023).

Model yang dibangun dan dibandingkan performanya dalam penelitian ini adalah sebagai berikut.

1. Word2Vec-BPEmb + BiLSTM (SoftMax)
2. Word2Vec-BPEmb + BiLSTM + CRF
3. Flair + BiLSTM (SoftMax)
4. BERT + *fine-tuning* (lapisan SoftMax langsung di atas output BERT)
5. XLM-R + *fine-tuning* (lapisan SoftMax langsung di atas output XLM-R)
6. BERT + BiLSTM + CRF (model hibrida)

Latar belakang penelitian ini adalah perlunya mengembangkan model BioNER yang efektif untuk Bahasa Indonesia pada domain teks *Online Health Consultation* (OHC), dengan memanfaatkan teknik *self-training* dan anotasi berbasis ahli guna mengatasi keterbatasan data serta mendukung interoperabilitas dan pemanfaatan data konsultasi kesehatan digital secara lebih cerdas dan terstruktur (Purwitasari dkk., 2023).

Tugas utama dari *Biomedical Named Entity Recognition* (BioNER) adalah untuk mengidentifikasi secara otomatis entitas biomedis seperti gejala, penyakit, atau bagian tubuh. Ekstraksi kata kunci, topik, dan entitas menjadi kunci untuk navigasi dan sistem rekomendasi dalam platform OHC.

Pada penelitian tersebut, Purwitasari dkk. (Purwitasari dkk., 2023) menulis bahwa meskipun metode *deep learning* seperti LSTM dan transformer telah terbukti sangat berhasil untuk BioNER pada bahasa *high-resource* seperti Inggris, pengembangan model serupa untuk bahasa *low-resource*, termasuk Bahasa Indonesia, menghadapi tantangan besar akibat keterbatasan data teranotasi. Pendekatan ini diambil untuk mengatasi kesenjangan, dengan memadukan anotasi manual oleh ahli dengan strategi *semi-supervised* atau *self-training* guna memperluas data latih tanpa ketergantungan pada korpus berlabel skala besar.

Pengembangan model BioNER yang efektif untuk Bahasa Indonesia pada domain teks OHC, dengan memanfaatkan teknik *self-training* dan anotasi berbasis ahli, digunakan untuk mengatasi keterbatasan data serta mendukung interoperabilitas dan pemanfaatan data konsultasi kesehatan digital secara lebih cerdas dan terstruktur.

Hasil dan temuan pada penelitian ini adalah sebagai berikut (Purwitasari dkk., 2023).

1. **Mengatasi keterbatasan bahasa rendah sumber.** Penelitian ini berhasil menunjukkan bahwa model BioNER yang efektif dapat dibangun untuk bahasa rendah sumber, yaitu Indonesia, meskipun dengan data teranotasi yang terbatas. Hal ini dicapai dengan memanfaatkan teks non-formal dari platform konsultasi kesehatan online, yang merupakan sumber data alternatif yang kaya namun belum banyak dieksplorasi untuk tugas ini.
2. **Superioritas arsitektur transformer.** Kesimpulan utama yang tegas adalah bahwa model berbasis transformer, khususnya XLM-R, secara signifikan mengungguli model berbasis BiLSTM dalam tugas BioNER pada teks OHC. XLM-R terbukti lebih *robust* dalam menangani kalimat yang panjang, tidak formal, dan masalah kosakata di luar kamus (OOV) yang lazim ditemui dalam teks OHC.
3. **Keberhasilan strategi *self-training*.** Pendekatan *semi-supervised learning* dengan *self-training* yang dilengkapi fungsi filter dengan *confidence threshold* = 0.85 terbukti sukses. Strategi ini mampu memanfaatkan data tidak teranotasi dalam jumlah besar untuk meningkatkan kinerja model tanpa memerlukan tambahan anotasi manual yang mahal, sekaligus meminimalkan *noise* yang masuk ke dalam data latih.
4. **Aplikasi praktis yang nyata.** Model BioNER yang dihasilkan tidak hanya unggul secara teknis tetapi juga memiliki nilai aplikasi praktis yang tinggi.

Entitas yang diekstraksi dapat berfungsi sebagai kata kunci topik yang memudahkan navigasi informasi bagi pengguna OHC dan sebagai sumber data untuk sistem peringatan dini (*early warning system*) dan surveilans kesehatan berbasis peristiwa (*event-based surveillance*) bagi pemerintah dan pemangku kebijakan.

5. **Kemandirian dari solusi yang spesifik.** Penelitian ini menggunakan kerangka kerja NLP yang sudah ada, seperti SparkNLP, dan tidak memerlukan pengembangan solusi khusus yang rumit. Hal ini menunjukkan kelayakan penerapan (*practical feasibility*) model ini untuk diintegrasikan ke dalam platform OHC yang nyata.

2.4 Identifikasi Kesenjangan Penelitian (*Research Gaps*)

Tinjauan pustaka terhadap evolusi metode pemetaan terminologi klinis (2.2), penelitian implementasi di Indonesia (2.3), serta diskusi tantangan umum pada bagian sebelumnya mengungkap sejumlah kesenjangan yang masih belum teratasi. Agar penelitian ini memiliki fokus yang tajam, kesenjangan tersebut dikelompokkan ke dalam tiga lapis: **metodologis** (keterbatasan pendekatan yang ada), **cakupan** (batasan ruang lingkup fungsional), dan **konteks** (kekhususan bahasa dan lokasi). Ketiga lapis ini saling terkait dan menjadi justifikasi utama perlunya adaptasi CDE-Mapper untuk bahasa Indonesia.

2.4.1 Gap Metodologis: Keterbatasan Metode *Existing*

Meskipun metode pemetaan terminologi telah berevolusi dari *rule-based* menuju *Large Language Models* (LLM) dan *Retrieval-Augmented Generation* (RAG), masing-masing pendekatan menyisakan kelemahan fundamental yang belum terpecahkan secara bersamaan.

Pendekatan *rule-based* dan leksikal (Jung dkk., 2022; Meizoso dkk., 2011; Sitaru dkk., 2024) menawarkan transparansi dan tidak memerlukan GPU, tetapi *recall* rendah, hanya 69% pada penelitian Meizoso dkk. (2011), dan tidak mampu menangani variasi bahasa alami seperti sinonim, singkatan, atau *typo*. Selain itu, pembuatan aturan manual tidak berskala (*not scalable*) untuk ribuan konsep klinis.

Pendekatan *machine learning* (ML) dan *deep learning* (DL) (Hong dkk., 2019; Hristov dkk., 2021) berhasil menangani variasi leksikal lebih baik, namun membutuhkan data latih berlabel dalam jumlah besar. Hristov dkk. (2021) melaporkan bahwa performa model BiLSTM+ClinicalBERT sangat bervariasi, dengan

F1 antara 0,22–0,97, ketika diuji pada data klinis nyata yang tidak terstruktur. Ketergantungan pada kualitas dan kuantitas data latih menjadi hambatan utama, terutama untuk *low-resource language* seperti bahasa Indonesia.

Pendekatan LLM murni tanpa *retrieval* (Yu dkk., 2026) menunjukkan bahwa *zero-shot prompting* pada ChatGPT-4.0 hanya mencapai *complete match* 53,3% untuk pemetaan ke LOINC. Tanpa konteks eksternal, LLM rentan terhadap **halusi-nasi**, pengetahuan yang usang, dan biaya komputasi yang tinggi (Brown dkk., 2020; Lewis dkk., 2021).

Pendekatan RAG (termasuk CDE-Mapper) (Gilani dkk., 2025; Huh, 2025) terbukti mengungguli *baseline* dengan akurasi hingga 94,4% pada dataset Inggris. Namun, CDE-Mapper memiliki tiga kelemahan metodologis utama yang diakui oleh penulisnya sendiri: (1) *input* terbatas pada satu CDE (*single item*), sehingga tidak dirancang untuk mengekstrak dan memetakan banyak entitas dari teks panjang; (2) ketergantungan pada kualitas *prompt* dan contoh kontekstual, sehingga kinerja menurun drastis ketika variasi bahasa tidak tercakup dalam *prompt*; dan (3) belum teruji pada bahasa non-Inggris karena seluruh evaluasi dilakukan pada data berbahasa Inggris, seperti NCBI-DC, BC5CDR, dan MIMIC-III.

Implikasi gap metodologis: Diperlukan suatu pendekatan *hybrid* yang menggabungkan keunggulan *retrieval* (SPLADE untuk kecocokan leksikal dan SapBERT untuk kesamaan semantik) dengan LLM untuk *reranking*, sekaligus menambahkan *modul ekstraksi entitas dari teks panjang* yang tidak tersedia pada CDE-Mapper asli (Formal dkk., 2021; Gilani dkk., 2025; Liu dkk., 2021). Selain itu, literatur yang ditinjau belum menyediakan mekanisme keputusan yang secara eksplisit dan transparan menggabungkan bukti leksikal, semantik, kesesuaian domain terminologi, kelengkapan atribut klinis, tingkat kekhususan konsep, dan konsistensi penilaian LLM dalam satu skor kandidat. Oleh karena itu, penelitian ini mengusulkan skor multi-komponen agar alasan pemilihan kandidat dapat ditelusuri dan kontribusi setiap komponen dapat diuji melalui studi ablasi.

2.4.2 Gap Cakupan: Multi-Terminologi dan Teks Panjang

Selain keterbatasan metodologis, terdapat dua kesenjangan cakupan yang menghambat penerapan sistem pemetaan pada skala nasional seperti SATUSEHAT.

Keterbatasan pemetaan lintas standar (*cross-terminology mapping*)

Mayoritas penelitian hanya berfokus pada pemetaan ke satu standar, dengan SNOMED CT sebagai target dominan (Y. Chen dkk., 2022; Kate, 2020; Zahra & Kate, 2024). Padahal, ekosistem interoperabilitas Indonesia melalui SATUSE-

HAT mewajibkan penggunaan minimal tiga terminologi sekaligus: *SNOMED CT* untuk data klinis, *LOINC* untuk laboratorium, dan keluarga *ICD* untuk diagnosis serta *billing* (Ayuningtyas dkk., 2025). Hanya sebagian kecil studi, seperti D. Zhou dkk. (2022) dan Gilani dkk. (2025), yang secara eksplisit mengeksplorasi *multi-terminology mapping*. Akibatnya, belum ada **kerangka kerja terpadu** (*unified pipeline*) yang mampu melakukan pemetaan simultan ke ketiga standar tersebut dengan mekanisme *routing* otomatis berdasarkan tipe entitas klinis.

Tavakoli dkk. (2023) menunjukkan bahwa bahkan terminologi terbaik sekalipun, yaitu SNOMED CT, masih memiliki celah cakupan sekitar 18% untuk konsep klinis yang umum digunakan, sementara ICD-10-CM dan ICD-11 memiliki celah yang jauh lebih besar, yaitu lebih dari 60% konsep tidak terwakili secara setara. Temuan ini secara langsung memperkuat urgensi pengembangan metode pemetaan otomatis yang mampu menangani konsep yang tidak tersedia dalam terminologi target, misalnya melalui *post-coordination*, seperti yang diusulkan oleh Kate (2020), atau melalui pemetaan ke konsep yang lebih luas dengan tetap mempertahankan informasi semantik yang hilang. Pemetaan otomatis tidak cukup hanya mencocokkan teks ke kode yang sudah ada, tetapi juga harus mampu mengusulkan representasi alternatif ketika kode eksak tidak tersedia.

Ketidakmampuan menangani teks panjang (*long-text*)

Sebagaimana diakui oleh Gilani dkk. (Gilani dkk., 2025), CDE-Mapper dirancang untuk *input* berupa **satu item data spesifik**, misalnya satu baris dalam *data dictionary*. Namun, di dunia nyata, dokumen rekam medis elektronik (RME) atau catatan perkembangan pasien berupa **teks naratif panjang** yang dapat mengandung puluhan entitas klinis, seperti penyakit, gejala, obat, prosedur, dan hasil laboratorium, dalam satu dokumen (Eslami dkk., 2026; Peterson & Liu, 2020). Tanpa adanya modul *long-text entity extraction* (NER) yang terintegrasi dalam alur RAG, CDE-Mapper tidak dapat dipakai secara *end-to-end* pada data klinis Indonesia yang sebagian besar masih berupa teks bebas (Hossain dkk., 2025).

Penelitian lain melakukan NER secara terpisah sebelum *mapping* (Peterson & Liu, 2020) atau menggunakan LLM untuk ekstraksi (Eslami dkk., 2026). Namun, hasil ekstraksi tersebut tidak diintegrasikan dengan komponen *retrieval ensemble* dan *knowledge reservoir*. Akibatnya, terjadi **error propagation** dan *lost opportunity* untuk memperkaya konteks semantik.

Implikasi gap cakupan: Penelitian ini perlu mengadaptasi CDE-Mapper dengan (a) menambahkan **modul ekstraksi entitas berbasis LLM** untuk mengurai teks panjang menjadi daftar CDE terstruktur, (b) memperluas *linking rules* agar

mampu melakukan **routing multi-terminologi** (SNOMED CT, LOINC, ICD-10) secara otomatis, serta (c) memastikan bahwa *query decomposition* dan *ensemble retrieval* tetap bekerja pada setiap entitas hasil ekstraksi.

2.4.3 Gap Konteks: Bahasa Non-Inggris dan Kebutuhan Lokal Indonesia

Kesenjangan paling khas yang dihadapi oleh negara berkembang seperti Indonesia adalah **minimnya penelitian pemetaan terminologi klinis untuk bahasa non-Inggris**, terutama yang bertipe *low-resource language*.

Dominasi bahasa Inggris dalam literatur

Hampir seluruh metode mutakhir, termasuk CDE-Mapper, diuji pada data berbahasa Inggris, seperti MIMIC-III, NCBI-DC, dan BC5CDR. Studi yang secara spesifik menangani bahasa non-Inggris masih sangat terbatas: untuk bahasa Perancis (Michel-Picque dkk., 2024), untuk bahasa Korea (Huh, 2025; Park dkk., 2026), dan untuk bahasa Indonesia (Ayuningtyas dkk., 2025; Purwitasari dkk., 2023). Rohizadeh dkk. (2025) secara eksplisit menunjukkan bahwa LLM mengalami penurunan performa signifikan saat menghadapi istilah medis dalam bahasa non-Inggris, terutama untuk konsep yang jarang muncul. Gallifant dkk. (2024) juga menemukan bahwa model bahasa rapuh terhadap variasi nama obat, seperti merek versus generik, pada data non-Inggris.

Karakteristik unik bahasa Indonesia klinis

Bahasa Indonesia dalam konteks klinis memiliki tantangan spesifik yang belum banyak diakomodasi oleh model *multilingual* seperti XLM-R atau mT5, yaitu: (1) **campuran kode** (*code-mixing*), ketika tenaga kesehatan sering mencampur istilah Indonesia dengan Inggris; (2) **singkatan non-standar**, karena setiap rumah sakit atau puskesmas dapat memiliki singkatan lokal yang tidak terdaftar dalam terminologi baku; (3) **istilah lokal tanpa padanan langsung**, karena Ayuningtyas dkk. (2025) menemukan bahwa dalam kebijakan SATUSEHAT saja terdapat 315 konsep terminologi lokal, melebihi jumlah konsep SNOMED CT yang hanya 266, dan *mapping success rate* ke standar internasional hanya 62,3%; serta (4) **variasi ejaan dan typo**, karena dokumen klinis sering ditulis dengan ejaan tidak baku dan tanpa tanda baca yang konsisten.

Kesenjangan antara kebijakan dan implementasi teknis

Secara kebijakan, Indonesia telah menetapkan penggunaan FHIR dan terminologi standar melalui SATUSEHAT (Ayuningtyas dkk., 2025; Heryawan dkk., 2025). Namun, di lapangan, implementasi RME masih menghadapi kendala sumber daya manusia, infrastruktur, dan manajemen, sehingga banyak fasilitas kesehatan masih menggunakan data berbasis kertas atau sistem dengan format lokal (Sugiarto dkk., 2024). Akibatnya, **potensi penuh interoperabilitas tidak tercapai** karena data klinis tidak dapat secara otomatis dipetakan ke terminologi standar yang dipersyaratkan.

Penelitian Purwitasari dkk. (Purwitasari dkk., 2023) telah menunjukkan bahwa model transformer, yaitu XLM-R, dengan *self-training* efektif untuk *Biomedical Named Entity Recognition* (BioNER) pada teks konsultasi kesehatan daring berbahasa Indonesia. Namun, penelitian tersebut **tidak terintegrasi dengan modul semantic retrieval dan mapping to controlled vocabularies**, sehingga belum menghasilkan kode standar seperti SNOMED CT atau LOINC. Dengan kata lain, komponen NER sudah mulai ada untuk bahasa Indonesia, tetapi *pipeline* dari teks panjang ke entitas lalu ke kode standar masih kosong.

Implikasi gap konteks: Penelitian ini harus membangun dan mengevaluasi sebuah *end-to-end pipeline* yang (a) mampu mengekstrak entitas klinis dari teks panjang berbahasa Indonesia, dengan mengadaptasi temuan Purwitasari, (b) melakukan *ensemble retrieval* dengan *knowledge base* yang diperkaya sinonim dan variasi lokal, serta (c) menghasilkan kode SNOMED CT, LOINC, dan ICD-10 yang sesuai dengan kebutuhan SATUSEHAT.

2.4.4 Ringkasan Kesenjangan dan Posisi Penelitian

Tabel 2.4 merangkum ketiga lapis kesenjangan beserta indikator bukti dari literatur dan arah solusi yang diusulkan dalam penelitian ini.

Tabel 2.4: Identifikasi kesenjangan penelitian dan arah solusi

Jenis Gap	Indikator / Bukti dari Literatur	Akibat bagi Interoperabilitas	Arah Solusi dalam Penelitian
Metodologis	<i>Rule-based</i> memiliki <i>recall</i> rendah (Meizoso dkk., 2011); ML/DL membutuhkan data besar (Hristov dkk., 2021); LLM rentan halusinasi (Yu dkk., 2026); CDE-Mapper hanya mendukung <i>single item</i> dan belum merumuskan skor keputusan multi-komponen yang transparan (Gilani dkk., 2025).	Tidak ada metode yang sekaligus akurat, efisien, mampu menangani teks panjang, dan menyediakan dasar keputusan kandidat yang dapat ditelusuri.	Mengintegrasikan <i>long-text entity extraction, hybrid retrieval, self-consistency</i> , dan skor akhir berbobot yang memadukan bukti leksikal, semantik, domain, atribut, granularitas, serta konsistensi.
Cakupan (multi-terminologi dan teks panjang)	Mayoritas riset hanya menargetkan SNOMED CT; CDE-Mapper tidak dirancang untuk teks panjang; NER terpisah tidak terintegrasi (Peterson & Liu, 2020).	Tidak dapat memenuhi kebutuhan tiga standar sekaligus dan berisiko menimbulkan <i>error propagation</i> pada <i>pipeline</i> terpisah.	Membangun <i>linking rules</i> multi-terminologi (SNOMED CT, LOINC, ICD-10) dan mengintegrasikan ekstraksi serta <i>retrieval</i> dalam satu <i>framework</i> .
Konteks (bahasa non-Inggris, Indonesia)	<i>Mapping success rate</i> SATUSEHAT hanya 62,3%; terdapat 315 konsep lokal (Ayuningtyas dkk., 2025); bahasa Indonesia tergolong <i>low-resource</i> (Purwitasari dkk., 2023); LLM rapuh pada non-Inggris (Gallifant dkk., 2024; Rouhizadeh dkk., 2025).	Data klinis Indonesia tidak dapat diintegrasikan secara semantik dan kebijakan nasional tidak terimplementasi optimal di lapangan.	Memperkaya <i>knowledge base</i> dengan sinonim lokal, singkatan, dan variasi ejaan, serta menguji model pada <i>gold standard</i> berbahasa Indonesia dengan validasi ahli.

Dengan mengisi ketiga kesenjangan tersebut secara simultan, penelitian ini tidak sekadar mereplikasi CDE-Mapper, tetapi **mengadaptasinya secara kontekstual** untuk menjawab kebutuhan nyata interoperabilitas data kesehatan di Indonesia. Pendekatan *hybrid* yang diusulkan, yaitu LLM, *hybrid retrieval*, *long-text NER*, dan skor keputusan multi-komponen, diharapkan menjadi *blueprint* bagi pengembangan sistem pemetaan terminologi klinis pada lingkungan berbahasa Indonesia dan wilayah dengan karakteristik serupa. Skor tersebut juga membedakan kontribusi penelitian ini dari sekadar penerapan ulang CDE-Mapper karena setiap kandidat dinilai menggunakan bukti yang terukur dan dapat dianalisis secara terpisah.

2.5 Relevansi Judul Penelitian

Judul penelitian yang diusulkan, yaitu “Adaptasi CDE-Mapper Untuk Pemetaan Terminologi Klinis Bahasa Indonesia: Pendekatan *Hybrid* Berbasis LLM dan *Semantic Retrieval*”, secara langsung dan komprehensif menjawab berbagai kesenjangan yang teridentifikasi.

1. **Mengatasi *technical gap* pada pemetaan multi-terminologi.** CDE-Mapper (Gilani dkk., 2025) secara desain mendukung pemetaan ke berbagai standar (*multiple controlled vocabularies*). Adaptasinya akan mempertahankan dan mengembangkan kemampuan ini, sehingga berkontribusi pada pengembangan *unified mapping framework* yang selama ini masih minim.
2. **Memperbaiki CDE-Mapper agar dapat mengenali banyak CDE dalam teks panjang.** Penelitian ini menempatkan kebutuhan untuk mengekstraksi dan memetakan *multiple CDE* dalam teks panjang, sebagaimana yang lumrah ditemukan pada dokumen klinis, sebagai pengembangan inti dari arsitektur CDE-Mapper yang semula berfokus pada *single item* (Eslami dkk., 2026; Gilani dkk., 2025; Peterson & Liu, 2020).
3. **Menutup *domain-specific gap* untuk bahasa non-Inggris dan konteks lokal.** Fokus pada Bahasa Indonesia secara langsung mengisi celah penelitian untuk bahasa non-Inggris. Pendekatan *hybrid* yang diusulkan memungkinkan penyesuaian dengan karakteristik linguistik dan klinis lokal, termasuk variasi istilah, singkatan, dan terminologi lokal yang telah diidentifikasi dalam implementasi SATUSEHAT serta pada studi BioNER bahasa Indonesia (Ayuningtyas dkk., 2025; Purwitasari dkk., 2023).

Dengan demikian, penelitian ini tidak hanya mengatasi kesenjangan teknis dan linguistik, tetapi juga menawarkan solusi praktis dan kontekstual untuk memper-

cepat interoperabilitas data kesehatan di Indonesia dan wilayah dengan tantangan serupa.

BAB III

LANDASAN TEORI

3.1 Konsep Dasar Terminologi Rujukan Klinis

Menurut De Lusignan (2005), dalam sistem informasi kesehatan, data klinis direpresentasikan melalui tiga pendekatan utama yang berbeda secara fundamental, yaitu **klasifikasi**, **terminologi**, dan **nomenklatur**.

Klasifikasi (*classification*) adalah pengelompokan seluruh elemen dalam suatu domain ke dalam kategori berdasarkan kriteria yang telah ditetapkan, biasanya bersifat hierarkis dan saling eksklusif (*mutually exclusive*), serta ditujukan untuk agregasi data statistik dan administrasi. ICD (*International Classification of Diseases*) adalah contoh prototipikal dari klasifikasi karena mengelompokkan penyakit ke dalam kode-kode yang terstruktur secara hierarkis (*mono hierarchy*) dan setiap kondisi hanya dapat ditempatkan di satu tempat. Karena itu, ICD ideal untuk pelaporan epidemiologi dan klaim asuransi, tetapi tidak cukup ekspresif untuk merekam detail klinis yang kaya (De Lusignan, 2005; Rodrigues Jean-Marie dkk., 2015).

Sementara itu, **terminologi** (*terminology*) adalah kumpulan label bahasa yang melekat pada konsep-konsep dalam suatu domain profesional secara komprehensif. LOINC (*Logical Observation Identifiers Names and Codes*) dapat dipandang sebagai terminologi untuk observasi laboratorium dan klinis karena menyediakan nama dan kode baku untuk setiap jenis pertanyaan tes, namun tanpa relasi semantik yang mendalam. Adapun **nomenklatur** (*nomenclature*) adalah sistem penamaan yang lebih canggih, di mana kode-kode diberikan pada konsep medis dan konsep-konsep tersebut dapat dikombinasikan menurut aturan tertentu untuk membentuk konsep yang lebih kompleks. SNOMED CT (*Systematized Nomenclature of Medicine-Clinical Terms*) adalah contoh nomenklatur sekaligus terminologi rujukan klinis (*clinical reference terminology*) untuk pencatatan klinis yang ekspresif dan mendukung penalaran komputer (De Lusignan, 2005; Schulz Stefan dkk., 2017).

Di samping ketiganya, **terminologi rujukan klinis** (*clinical reference terminology*) adalah tingkatan paling tinggi yang tidak hanya bersifat komprehensif, tetapi juga didasari oleh model konsep yang terdefinisi secara formal dan kaya akan relasi semantik, seperti *is-a*, *part-of*, dan *caused by*, yang dapat diproses oleh komputer untuk melakukan penalaran logis, misalnya inferensi subsumpsi. Hal ini sesuai dengan *desiderata* atau karakteristik ideal yang dirumuskan oleh Cimino (1998), seperti *concept orientation*, *formal definitions*, dan *polyhierarchy*, yang menjadi tolok ukur sebuah terminologi rujukan. Prinsip-prinsip tersebut kemudian dipertegas kembali oleh Cimino (2006) sebagai landasan untuk menilai apakah suatu kosakata

medis dapat dipakai secara luas dalam sistem informasi kesehatan.

SNOMED CT merupakan implementasi paling lengkap dari konsep terminologi rujukan klinis. Sistem ini diorganisir sebagai sebuah ontologi yang menggunakan pendekatan *description logic* untuk memberikan definisi formal pada setiap konsep, sehingga memungkinkan klasifikasi otomatis dan deteksi konsistensi oleh komputer (Schulz & Cornet, 2009; Spackman, 2001). SNOMED CT memiliki cakupan konsep yang sangat luas, relasi semantik yang kaya, dan kemampuan merepresentasikan detail klinis kompleks yang tidak dapat direpresentasikan secara memadai oleh sistem klasifikasi biasa. Selain itu, SNOMED CT merupakan *controlled medical vocabulary* yang memenuhi banyak karakteristik ideal terminologi medis sehingga dapat digunakan secara *multipurpose*, yaitu untuk pencatatan klinis, penalaran, interoperabilitas, dan retrospeksi data (Cimino, 1998, 2006; Fennelly dkk., 2021). Hal ini membuat SNOMED CT menjadi target utama dalam proses *mapping* terminologi klinis.

Penempatan SNOMED CT sebagai target utama *mapping* didasari oleh beberapa alasan. Pertama, SNOMED CT memiliki cakupan konsep yang sangat luas dan tingkat kedetailan (*granularity*) yang tinggi (Chang & Sung, 2025). Kedua, data yang telah kaya dengan relasi semantik dalam SNOMED CT dapat menjadi sumber untuk diringkas atau diagregasi menjadi kode statistik yang lebih kasar dalam ICD, namun proses sebaliknya tidak dapat dilakukan secara setara (El-Sappagh dkk., 2018; Rodrigues Jean-Marie dkk., 2015). Ketiga, pendekatan pemetaan dari SNOMED CT ke terminologi lain memungkinkan terciptanya peta konsep yang lebih terintegrasi, di mana satu konsep induk dalam terminologi rujukan dapat terhubung dengan berbagai kode dalam sistem klasifikasi maupun terminologi khusus lainnya (Harris dkk., 2003; Schulz Stefan dkk., 2017).

Mapping atau pemetaan diperlukan karena data klinis, misalnya diagnosis, hasil laboratorium, dan prosedur, berasal dari berbagai sumber dengan nama yang berbeda-beda, dapat mengandung sinonim, menggunakan bahasa yang tidak baku, dan memiliki tingkat detail yang bervariasi. Melalui pendekatan pemetaan ini, sistem informasi kesehatan dapat mencapai interoperabilitas semantik yang lebih baik, di mana data dari berbagai sumber dapat dipertukarkan, dipahami, dan dianalisis secara lebih otomatis oleh komputer (Fennelly dkk., 2021; Harris dkk., 2003).

3.1.1 SNOMED CT sebagai Terminologi Rujukan Klinis

SNOMED CT adalah terminologi rujukan klinis yang dirancang untuk mendukung pencatatan klinis yang ekspresif dan komputabel. Dalam praktiknya, SNOMED CT tidak hanya menyediakan daftar istilah, tetapi juga struktur ontologis yang

memungkinkan setiap konsep memiliki definisi formal, relasi semantik, dan posisi dalam struktur polihierarki (Schulz & Cornet, 2009; Spackman, 2001). Dengan karakteristik ini, SNOMED CT dapat digunakan untuk merepresentasikan kondisi klinis, temuan, prosedur, organisme, struktur anatomi, zat, serta berbagai entitas klinis lain secara konsisten dan terhubung.

Keunggulan utama SNOMED CT terletak pada kemampuannya mendukung representasi klinis yang rinci sekaligus mendukung penalaran komputasional. Sebagai contoh, satu konsep diagnosis dapat dihubungkan dengan lokasi anatomi, etiologi, atau konteks klinis tertentu. Hal ini menjadikan SNOMED CT bukan sekadar alat pengkodean, melainkan infrastruktur semantik yang dapat dimanfaatkan untuk interoperabilitas, *clinical decision support*, dan analisis data klinis sekunder (Fennelly dkk., 2021; Schulz Stefan dkk., 2017).

Dalam konteks penelitian ini, SNOMED CT diposisikan sebagai terminologi target utama karena paling sesuai untuk menangkap variasi istilah klinis Bahasa Indonesia yang beragam, termasuk istilah rinci yang tidak selalu dapat direpresentasikan secara tepat oleh sistem klasifikasi statistik. Oleh karena itu, keberhasilan *mapping* ke SNOMED CT menjadi komponen penting dalam pembangunan interoperabilitas semantik pada data klinis Indonesia.

3.1.2 LOINC sebagai Terminologi untuk Observasi dan Laboratorium

LOINC adalah nomenklatur universal yang menyediakan identifikasi baku untuk pertanyaan atau analit (*question/analyte*) dari suatu tes atau observasi, bukan untuk hasilnya (*answer*). Dalam terminologi komputasional, LOINC berfungsi sebagai semacam *registry* atau *namespace* dengan metadata terstruktur yang dibangun di atas sejumlah sumbu utama, seperti komponen, properti, waktu, sistem, skala, dan metode (Spackman, 2001).

LOINC melengkapi peran SNOMED CT dengan menjadi standar untuk variabel observasi, khususnya pada pemeriksaan laboratorium dan pengukuran klinis. Dengan kata lain, jika SNOMED CT lebih tepat untuk mewakili makna klinis atau nilai suatu temuan, maka LOINC lebih tepat untuk mewakili jenis observasi atau jenis pemeriksaan yang dilakukan. Hubungan komplementer ini penting karena sistem informasi kesehatan umumnya memerlukan keduanya secara simultan: LOINC untuk mengidentifikasi jenis tes, dan SNOMED CT untuk menggambarkan hasil, kondisi, atau makna klinis yang terkait (Harris dkk., 2003; Schulz Stefan dkk., 2017).

Dalam konteks interoperabilitas, keberadaan LOINC sangat penting untuk memastikan bahwa data hasil laboratorium dari berbagai fasilitas kesehatan dapat di-

representasikan dengan cara yang seragam. Oleh sebab itu, pemetaan istilah klinis ke LOINC menjadi komponen penting dalam penelitian ini, khususnya untuk entitas yang termasuk kategori observasi atau pemeriksaan laboratorium.

3.1.3 ICD sebagai Sistem Klasifikasi Statistik

ICD adalah sistem klasifikasi statistik dengan hierarki kaku (*monohierarchy*) untuk mengelompokkan penyakit atau morbiditas ke dalam kode yang saling eksklusif (*mutually exclusive*). Tujuan utamanya adalah agregasi data untuk laporan epidemiologi, kebijakan kesehatan, dan klaim biaya (*reimbursement*), bukan untuk merepresentasikan detail klinis yang sangat rinci (De Lusignan, 2005; Rodrigues Jean-Marie dkk., 2015).

Kelebihan ICD terletak pada kegunaannya untuk tujuan pelaporan dan administrasi karena struktur kategorinya dirancang untuk konsistensi agregasi. Namun, jika dibandingkan dengan SNOMED CT, ICD memiliki keterbatasan dalam hal ekspresivitas semantik dan granularity. Hal ini berarti suatu konsep klinis yang rinci dalam praktik pelayanan sering kali harus disederhanakan agar dapat masuk ke dalam satu kategori ICD tertentu (Chang & Sung, 2025; El-Sappagh dkk., 2018).

Meskipun demikian, ICD tetap penting dalam konteks penelitian ini karena ekosistem interoperabilitas kesehatan di Indonesia, termasuk SATUSEHAT, masih membutuhkan ICD untuk pelaporan, statistik, dan tujuan pembiayaan layanan. Dengan demikian, *mapping* yang baik tidak hanya perlu menuju SNOMED CT sebagai terminologi rujukan utama, tetapi juga perlu mampu menghubungkan data klinis ke ICD ketika konteks penggunaannya adalah klasifikasi, pelaporan, atau *billing*.

3.1.4 Terminologi Lainnya dan Hubungan Antar Terminologi

Selain SNOMED CT, LOINC, dan ICD, ekosistem informatika kesehatan juga mengenal berbagai jenis terminologi lain, seperti terminologi antarmuka (*interface terminologies*), terminologi agregasi, dan terminologi lokal yang berkembang di fasilitas pelayanan kesehatan (Schulz Stefan dkk., 2017). Terminologi lokal sering kali muncul sebagai konsekuensi dari kebutuhan operasional sehari-hari, kebiasaan dokumentasi, penggunaan singkatan, dan adaptasi bahasa lokal. Meskipun praktis di tingkat lapangan, terminologi lokal ini sering menjadi sumber utama kesenjangan semantik karena tidak selalu memiliki padanan langsung yang baku dalam terminologi standar.

Hubungan antar terminologi tersebut tidak bersifat kompetitif, melainkan saling melengkapi. Terminologi rujukan seperti SNOMED CT diperlukan untuk menjaga makna klinis yang kaya dan konsisten; terminologi observasi seperti LOINC diper-

lukan untuk standarisasi pemeriksaan; sedangkan klasifikasi seperti ICD diperlukan untuk agregasi statistik dan administrasi (De Lusignan, 2005; Schulz Stefan dkk., 2017). Oleh karena itu, tantangan utama dalam interoperabilitas bukan memilih satu terminologi untuk menggantikan yang lain, melainkan membangun mekanisme pemetaan yang memungkinkan aliran informasi yang mulus antar berbagai sistem terminologi.


Dalam konteks penelitian ini, pemahaman terhadap perbedaan mendasar antara klasifikasi, terminologi, nomenklatur, dan terminologi rujukan klinis menjadi fondasi teoritis yang penting. Fondasi ini menjelaskan mengapa pemetaan terminologi klinis tidak dapat direduksi menjadi sekadar pencocokan kata, tetapi harus dipahami sebagai proses penyelarasan makna antarsistem representasi pengetahuan medis. Dengan demikian, Bab III ini menegaskan bahwa adaptasi model pemetaan untuk Bahasa Indonesia harus mempertimbangkan struktur konseptual terminologi target sekaligus variasi linguistik dan semantik pada data sumber.

3.2 LLM dan Arsitekturnya

Berdasarkan telaah penelitian dengan tema *mapping* terminologi medis, teknologi atau model yang memanfaatkan *Large Language Model* (LLM) dan *Retrieval-Augmented Generation* (RAG) saat ini mengungguli banyak model lainnya dalam berbagai tugas pemahaman dan penautan konsep. Oleh karena itu, penjelasan lebih lanjut mengenai LLM dan RAG, terutama pada konteks *mapping* terminologi medis, diperlukan untuk memahami alasan keunggulan dan optimasi penggunaannya pada penelitian ini (Gilani dkk., 2025; Zhao dkk., 2026).

3.2.1 Evolusi LLM

LLM telah menjadi tema yang saat ini paling banyak menarik perhatian dalam penelitian bidang kecerdasan buatan karena kemampuannya dalam memahami bahasa manusia dibandingkan dengan model-model sebelumnya. Evolusi LLM, jika dilihat dari perspektif kapasitas penyelesaian tugas, dapat digambarkan secara ringkas pada Gambar 3.1 (Zhao dkk., 2026).




Gambar 3.1: Evolusi LLM berdasarkan kemampuan penyelesaian tugas

Gambar 3.1 menunjukkan bahwa paradigma NLP bergeser menuju LLM, yaitu model AI yang bersifat serbaguna (*task-agnostic*) dan memiliki kemampuan membaca serta memahami teks untuk tugas-tugas seperti memahami isi bacaan, menjawab pertanyaan, menilai apakah suatu pernyataan logis atau tidak, dan berbagai tugas bahasa lainnya (Brown dkk., 2020; Zhao dkk., 2026). Pergeseran ini juga menegaskan bahwa hampir semua LLM modern dibangun di atas arsitektur Transformer yang diperkenalkan dalam makalah *Attention Is All You Need* oleh Vaswani dkk. (2017). Model seperti GPT-3, misalnya, memiliki 175 miliar parameter yang menyimpan pengetahuan dari data pelatihan dan mampu melakukan tugas-tugas baru hanya dengan beberapa contoh tanpa perlu *fine-tuning* khusus (Brown dkk., 2020).

3.2.2 Transformer

Sebelum Transformer, RNN (*Recurrent Neural Network*), terutama LSTM (*Long Short-Term Memory*) dan GRU (*Gated Recurrent Unit*), merupakan teknologi terbaik untuk pemrosesan bahasa dan terjemahan mesin. Namun, RNN memiliki kelemahan mendasar, yaitu memproses data secara berurutan sehingga tidak dapat diparalelkan dengan baik, lambat, dan boros memori untuk kalimat panjang. Berbagai upaya perbaikan hanya memberikan sedikit peningkatan tanpa menghilangkan kelemahan utama tersebut. Sementara itu, mekanisme *attention* telah dikenal mampu menangkap hubungan jarak jauh antarkata, tetapi selama mekanisme itu masih ditempelkan pada RNN, potensinya belum maksimal.

Vaswani dkk. (2017) kemudian memperkenalkan Transformer dengan membuang RNN sepenuhnya dan hanya mengandalkan *attention*. Hasilnya adalah paralelisasi penuh, pelatihan yang jauh lebih cepat, dan akurasi terjemahan yang lebih baik. Arsitektur Transformer ditunjukkan secara konseptual pada Gambar 3.2.



Gambar 3.2: Arsitektur Transformer

Gambar 3.2 menunjukkan struktur *encoder* yang menerima *input sequence* dan *decoder* yang menerima *output sequence* yang telah digeser ke kanan, khas Transformer untuk tugas *sequence-to-sequence* seperti terjemahan mesin. *Decoder* memeriksa *encoder* melalui *cross-attention*, yaitu lapisan *multi-head attention* kedua di *decoder*. Arsitektur ini meninggalkan pendekatan *recurrent* dan hanya mengandalkan mekanisme perhatian serta jaringan *feed-forward* (Vaswani dkk., 2017).

Transformer tidak harus selalu berupa gabungan *encoder* dan *decoder*; arsitektur ini dapat menggunakan salah satu komponennya saja sesuai tujuan. Transformer dengan *encoder* murni dimanfaatkan untuk pemahaman bahasa, sedangkan *decoder*

murni digunakan untuk generasi bahasa. Sementara itu, arsitektur *encoder-decoder* dimanfaatkan untuk tugas *text-to-text* yang memerlukan transformasi dari satu bentuk teks ke bentuk teks lainnya (Raffel dkk., 2023; Vaswani dkk., 2017).

3.2.3 Arsitektur *Encoder-Only*: BERT

Dasar munculnya BERT (*Bidirectional Encoder Representations from Transformers*) adalah kritik terhadap keterbatasan model representasi bahasa pada saat itu, terutama ELMo dan GPT, padahal arsitektur Transformer telah menunjukkan potensi yang sangat kuat. ELMo terbatas karena hanya memiliki *shallow bidirectionality*, yaitu dua LSTM independen yang digabung, serta pendekatan *feature-based* yang kurang adaptif. Sementara itu, GPT generasi awal terbatas karena bersifat *unidirectional*, yaitu hanya memanfaatkan konteks kiri, dan belum memiliki mekanisme *pre-training* yang kuat untuk hubungan antarkalimat (Peters dkk., 2017; Radford dkk., 2018).

BERT mengatasi kelemahan tersebut dengan menerapkan *deep bidirectional representations* melalui Transformer *encoder* dan *objective masked language modeling* (MLM), ditambah *next sentence prediction* untuk memahami relasi antarkalimat, serta *fine-tuning end-to-end* dengan arsitektur yang seragam dan sederhana. Hasilnya, BERT mencapai performa tinggi pada berbagai tugas NLP dan menjadi fondasi bagi banyak model berikutnya, seperti RoBERTa, ALBERT, dan DistilBERT, sekaligus membuka jalan bagi era *pre-training + fine-tuning* yang didominasi oleh representasi bidirectional (Devlin dkk., 2019).

3.2.4 Arsitektur *Decoder-Only*: Seri GPT

Belajar dari keterbatasan model yang memerlukan *fine-tuning* dengan dataset besar untuk setiap tugas baru, Brown dkk. mengembangkan GPT-3 dengan 175 miliar parameter (Brown dkk., 2020). Arsitektur yang digunakan masih berakar pada GPT generasi sebelumnya, tetapi disertai sejumlah modifikasi penting, seperti penggunaan *pre-normalization*, perhatian yang lebih efisien, dan strategi distribusi komputasi pada GPU skala besar. Hasil evaluasi menunjukkan bahwa kemampuan *few-shot* mengungguli *one-shot* atau *zero-shot*; semakin banyak contoh dalam konteks, semakin baik performa model.

Meskipun demikian, kekuatan utama GPT-3 bukan sekadar pada skalanya, melainkan pada kemampuannya melakukan tugas baru hanya dengan beberapa contoh dalam *prompt*, tanpa pembaruan parameter atau *fine-tuning* tradisional. Penelitian GPT-3 membuktikan bahwa skala model yang ekstrem dapat menghasilkan kemampuan *emergent*, yaitu *in-context learning* tanpa pembaruan gradien. Temuan

ini membuka jalan bagi model bahasa yang lebih general dan *task-agnostic*, serta mengurangi ketergantungan pada *fine-tuning*. Namun, kelemahan mendasar seperti sifat *unidirectional*, bias, biaya komputasi, dan potensi penyalahgunaan tetap menjadi tantangan penting (Brown dkk., 2020; Zhao dkk., 2026).

3.2.5 Arsitektur *Encoder-Decoder*: T5

Penelitian *transfer learning* untuk NLP berkembang sangat pesat melalui model seperti ELMo, BERT, GPT, dan RoBERTa, tetapi menyisakan pertanyaan mendasar: arsitektur mana yang paling efektif, objective *pre-training* mana yang terbaik, seberapa penting kualitas dan domain data *pre-training*, strategi *training* mana yang optimal, dan apa yang terjadi jika model diskalakan. Untuk menjawab pertanyaan-pertanyaan tersebut, Raffel dkk. (2023) memperkenalkan kerangka kerja *Text-to-Text Transfer Transformer* (T5), yang menyamaratakan semua tugas NLP ke dalam format teks-ke-teks.

T5 menyatukan berbagai tugas NLP, seperti klasifikasi, terjemahan, dan ringkasan, ke dalam format yang sama: teks sebagai *input* dan teks sebagai *output*. Pendekatan ini menyederhanakan proses pengembangan model dan memungkinkan *transfer learning* yang sangat efektif lintas tugas. Melalui serangkaian eksperimen menggunakan variasi Transformer hingga *scaling*, T5 menunjukkan bahwa satu model dengan arsitektur yang relatif sederhana, objective denoising yang efisien, dan skala besar dapat mencapai atau melampaui hasil metode yang lebih rumit. Pendekatan ini menjadi salah satu fondasi penting bagi perkembangan model generasi berikutnya (Raffel dkk., 2023).

3.2.6 Arsitektur Efisien dan Terbuka: LLaMA

Pada saat penelitian Touvron dkk. (2023) dilakukan, model-model bahasa besar seperti GPT-3, PaLM, dan Chinchilla telah menunjukkan kemampuan luar biasa, tetapi masih menyisakan beberapa persoalan penting, yaitu banyak model tidak terbuka, biaya inferensi tinggi, dan fokus pengembangan yang terlalu menitikberatkan pada *training compute* tanpa cukup memperhatikan *inference budget*. Touvron dkk. kemudian memperkenalkan LLaMA, yaitu sekumpulan model bahasa berukuran 7B, 13B, 33B, dan 65B parameter, yang dilatih pada triliunan token data publik dengan arsitektur yang dioptimalkan untuk efisiensi.

Prinsip utama yang digunakan dalam penelitian tersebut adalah: (1) menggunakan data publik sepenuhnya, seperti CommonCrawl, C4, GitHub, Wikipedia, Books, ArXiv, dan StackExchange; (2) melatih lebih lama pada lebih banyak token daripada yang disarankan aturan skala tertentu, karena inferensi model kecil yang

dilatih lama dapat lebih murah; dan (3) menggunakan arsitektur yang efisien, dengan inovasi seperti RMSNorm, SwiGLU, *rotary positional embeddings* (RoPE), dan optimasi implementasi seperti *FlashAttention* dan *checkpointing* (Touvron dkk., 2023).

Metode penelitian yang digunakan mencakup data *pre-training*, arsitektur, optimizer dan *training*, efisiensi implementasi, serta evaluasi pada berbagai benchmark. Rangkuman data *pre-training* LLaMA ditunjukkan pada Tabel 3.1.

Tabel 3.1: Rangkuman data pretraining LLaMA

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB

Perubahan arsitektur utama dari Transformer asli dapat diringkas pada Tabel 3.2.

Tabel 3.2: Perubahan arsitektur utama pada LLaMA dibandingkan Transformer asli

Komponen	Modifikasi	Inspirasi
<i>Pre-normalization</i>	RMSNorm pada input sub-lapisan, bukan pada output.	GPT-3
Aktivasi	SwiGLU, bukan ReLU, dengan pengaturan dimensi tersembunyi yang lebih efisien.	PaLM
<i>Positional encoding</i>	<i>Rotary Position Embeddings</i> (RoPE) per lapisan, bukan posisi absolut.	GPT-Neo
<i>Attention</i>	Implementasi efisien berbasis pustaka <i>xformers</i> , termasuk teknik seperti <i>FlashAttention</i> .	Rabe & Staats; Dao dkk.

Detail hiperparameter utama yang digunakan pada model-model LLaMA ditunjukkan pada Tabel 3.3.

Tabel 3.3: Hiperparameter utama model LLaMA

Model	Parameters	d_{model}	n_{heads}	n_{layers}	Learning rate	Batch size	Tokens
7B	6.7B	4096	32	32	3.0e-4	4M	1.0T
13B	13.0B	5120	40	40	3.0e-4	4M	1.0T
33B	32.5B	6656	52	60	1.5e-4	4M	1.4T
65B	65.2B	8192	64	80	1.5e-4	4M	1.4T

Optimizer dan strategi *training* yang digunakan adalah AdamW dengan parameter $\beta_1 = 0.9$ dan $\beta_2 = 0.95$, *weight decay* 0.1, serta *gradient clipping* 1.0. *Learning rate schedule* menggunakan *cosine decay* hingga 10% dari nilai maksimum dengan *warmup* 2000 langkah. Dari sisi perangkat keras, pelatihan model besar dilakukan menggunakan ribuan GPU A100, dan versi 65B memerlukan waktu pelatihan sekitar 21 hari (Touvron dkk., 2023).

Efisiensi implementasi didukung oleh beberapa teknik penting, yaitu *FlashAttention*, *checkpointing* manual, tumpang tindih komunikasi antargpu dengan komputasi, serta kombinasi *model parallelism* dan *sequence parallelism*. Evaluasi dilakukan dalam skenario *zero-shot* dan *few-shot* pada lebih dari 20 benchmark, dengan strategi decoding seperti *greedy decoding* dan *beam search*, serta perbandingan dengan GPT-3, Gopher, Chinchilla, PaLM, dan model terbuka lain seperti OPT dan GPT-NeoX (Touvron dkk., 2023).

Hasil utama menunjukkan bahwa LLaMA memiliki performa yang sangat kompetitif. Pada *common sense reasoning*, LLaMA-13B mengungguli GPT-3 175B pada banyak tugas, sedangkan LLaMA-65B kompetitif dengan Chinchilla-70B dan PaLM-540B. Pada *closed-book question answering*, LLaMA-65B mencapai hasil yang sangat kuat. Pada *reading comprehension*, model besar LLaMA mampu mengungguli GPT-3 dan PaLM pada benchmark tertentu. Pada *mathematical reasoning*, LLaMA masih tertinggal dari model yang secara khusus di-*fine-tune* untuk matematika, sedangkan pada *code generation*, LLaMA-65B setara atau kompetitif dengan model raksasa lain walaupun tidak di-*fine-tune* khusus untuk kode (Touvron dkk., 2023).

Rangkuman hasil pengujian LLaMA pada beberapa benchmark utama ditunjukkan pada Tabel 3.4.

Tabel 3.4: Rangkuman hasil pengujian LLaMA pada beberapa benchmark utama

Kelompok Uji	Inti Temuan	Model Pem-banding	Posisi LLaMA
<i>Common sense reasoning</i>	LLaMA-13B mengungguli GPT-3 175B pada banyak tugas; LLaMA-65B kompetitif dengan model yang jauh lebih besar.	GPT-3, Chinchilla, PaLM	Kompetitif
<i>Closed-book QA</i>	LLaMA-65B mencapai <i>state-of-the-art</i> pada beberapa benchmark seperti NQ dan TriviaQA.	GPT-3, Chinchilla	Sangat kuat
<i>Reading comprehension</i>	LLaMA-65B mengungguli GPT-3 dan PaLM pada benchmark tertentu seperti RACE.	GPT-3, PaLM	Unggul pada tugas tertentu
<i>Mathematical reasoning</i>	Kompetitif, tetapi masih tertinggal dari model yang di- <i>fine-tune</i> khusus untuk matematika.	PaLM, Minerva	Menengah
<i>Code generation</i>	Setara atau unggul pada beberapa benchmark dasar, meskipun tidak di- <i>fine-tune</i> khusus untuk kode.	PaLM	Kompetitif
<i>MMLU</i>	Masih di bawah Chinchilla dan PaLM, diduga karena keterbatasan data buku.	Chinchilla, PaLM	Di bawah model tertinggi

Selain keunggulannya, Touvron dkk. juga menyoroti keterbatasan LLaMA. Toksisitas meningkat seiring ukuran model. Pada evaluasi bias sosial, LLaMA-65B menunjukkan bias rata-rata yang lebih rendah daripada GPT-3 dan OPT pada beberapa kategori, tetapi tetap menunjukkan bias pada kategori tertentu seperti agama dan orientasi seksual. Model ini juga masih rentan terhadap halusinasi dan misinformasi, misalnya pada TruthfulQA, meskipun performanya lebih baik daripada beberapa model pembanding (Touvron dkk., 2023). Di sisi lain, dari perspektif biaya dan emisi karbon, pelatihan LLaMA tetap mahal, tetapi Touvron dkk. berargumen bahwa ketersediaan model ke komunitas dapat mengurangi kebutuhan melatih model dari awal di masa depan.

Secara keseluruhan, dapat disimpulkan bahwa LLaMA menunjukkan bahwa skala parameter bukan satu-satunya faktor penentu performa. Dengan data yang

lebih banyak, arsitektur yang efisien, dan strategi pelatihan yang tepat, model yang lebih kecil dapat mendekati atau menyaingi model yang jauh lebih besar, sekaligus lebih murah untuk inferensi. Temuan ini penting bagi penelitian ini karena memberi dasar teoritis bahwa pemilihan model LLM untuk *mapping* terminologi medis tidak semata-mata bergantung pada ukuran model, tetapi juga pada efisiensi, keterbukaan, dan kecocokan arsitektur terhadap kebutuhan tugas.

3.3 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) adalah sebuah kerangka kerja arsitektural yang menggabungkan dua kemampuan utama, yaitu *retrieval* atau pengambilan informasi dari sumber eksternal dan *generation* atau pembangkitan teks, dalam satu sistem terpadu (Lewis dkk., 2021). Secara sederhana, RAG memungkinkan model bahasa untuk tidak hanya mengandalkan pengetahuan yang telah dipelajari dan tersimpan di dalam parameter model, tetapi juga secara dinamis mengakses data yang lebih mutakhir, relevan, dan dapat ditelusuri dari basis pengetahuan eksternal sebelum menghasilkan jawaban (Wu dkk., 2025). Dalam konteks penelitian ini, karakteristik tersebut sangat penting karena tugas *mapping* terminologi klinis memerlukan kombinasi antara pemahaman bahasa alami, akses terhadap terminologi standar, dan kemampuan menelusuri kandidat konsep yang paling sesuai.

Secara probabilistik, hubungan antara *retriever* dan generator pada RAG dapat diringkas sebagai (Lewis dkk., 2021):

$$p(y | q) = \sum_{z \in Z_k(q)} p_\eta(z | q) p_\theta(y | q, z), \quad (3.1)$$


dengan q sebagai kueri, $Z_k(q)$ sebagai himpunan k konteks atau kandidat teratas, $p_\eta(z | q)$ sebagai probabilitas kandidat menurut *retriever*, dan $p_\theta(y | q, z)$ sebagai probabilitas keluaran generator setelah mempertimbangkan kandidat z . Persamaan 3.1 menunjukkan bahwa kualitas keluaran RAG ditentukan bersama oleh keberhasilan menemukan konteks yang relevan dan kemampuan generator memanfaatkan konteks tersebut.

Beberapa penelitian menunjukkan bahwa RAG efektif bahkan pada LLM berukuran relatif kecil. Lewis dkk. (2021) membandingkan model parametrik besar dengan model RAG yang jauh lebih hemat parameter pada berbagai tugas *knowledge-intensive*. Hasilnya menunjukkan bahwa RAG mampu mengungguli model parametrik murni, misalnya pada dataset *Natural Questions* (NQ) ketika RAG mencapai *exact match* 44,5%, sedangkan T5-11B hanya mencapai 34,5%. Temuan ini menegaskan bahwa augmentasi pengetahuan eksternal dapat menjadi strategi yang lebih

efisien daripada sekadar memperbesar kapasitas parameter model.

RAG lahir sebagai respons terhadap tiga masalah mendasar pada LLM parametrik murni (Lewis dkk., 2021). Pertama, model dapat mengalami halusinasi, yaitu menghasilkan keluaran yang tampak meyakinkan tetapi tidak sesuai fakta. Kedua, pengetahuan model cenderung usang dan sulit diperbarui karena fakta yang tersimpan bergantung pada data pelatihan; pembaruan pengetahuan sering menuntut pelatihan ulang yang mahal dan berisiko menimbulkan *catastrophic forgetting*. Ketiga, model parametrik besar relatif kurang transparan dan sulit ditelusuri sumber pengetahuannya. Keterbatasan inilah yang mendorong gagasan *non-parametric memory*, yaitu menyimpan pengetahuan di luar parameter model dan memanggilnya hanya saat diperlukan.

3.3.1 Arsitektur RAG



Gambar 3.3: Arsitektur umum RAG

Gambar 3.3 menggambarkan alur umum RAG yang terdiri atas tiga jalur utama, yaitu input, *retriever* beserta mekanisme *retrieval fusion*, dan generator (Wu dkk., 2025). Pada tahap **input**, pengguna memasukkan pertanyaan atau perintah dalam bentuk teks. Input ini kemudian dikirim secara paralel ke dua komponen, yaitu ke *retriever* untuk mengambil pengetahuan eksternal dan ke generator sebagai bagian dari *prompt* awal.

Pada tahap **retriever**, sistem mencari dokumen atau potongan teks yang paling relevan dari basis pengetahuan eksternal, misalnya basis data vektor, koleksi do-

kumen, atau repositori terminologi. Keluaran dari tahap ini biasanya berupa *top-k documents* yang paling mirip secara semantik dengan kueri. Dokumen-dokumen terpilih tersebut kemudian diteruskan ke modul *retrieval fusion*.

Pada *dense retrieval*, kueri dan kandidat direpresentasikan sebagai vektor. Salah satu ukuran kesamaan yang umum digunakan adalah *cosine similarity*:

$$s_{\text{dense}}(q, c) = \frac{\mathbf{e}_q^\top \mathbf{e}_c}{\|\mathbf{e}_q\|_2 \|\mathbf{e}_c\|_2}, \quad (3.2)$$

dengan $\mathbf{e}_q$ dan $\mathbf{e}_c$ masing-masing sebagai representasi vektor kueri dan kandidat. Dalam terminologi biomedis, SapBERT menggunakan penyelarasan representasi sinonim untuk memperbaiki kedekatan semantik antarnama entitas (Liu dkk., 2021). Sebaliknya, *sparse retrieval* merepresentasikan kueri dan kandidat sebagai vektor berbobot pada ruang kosakata V :

$$s_{\text{sparse}}(q, c) = \mathbf{w}_q^\top \mathbf{w}_c = \sum_{t \in V} w_{q,t} w_{c,t}, \quad (3.3)$$

sehingga kecocokan token penting, istilah, dan ekspansi leksikal tetap dipertahankan. Formulasi ini sesuai dengan prinsip SPLADE sebagai model representasi jarang untuk tahap awal pemeringkatan (Formal dkk., 2021). Setelah kedua skor dinormalisasi, keduanya dapat digabungkan sebagai *hybrid retrieval*:

$$s_{\text{hybrid}}(q, c) = \alpha \tilde{s}_{\text{sparse}}(q, c) + (1 - \alpha) \tilde{s}_{\text{dense}}(q, c), \quad 0 \leq \alpha \leq 1, \quad (3.4)$$

dengan α mengatur kontribusi kecocokan leksikal dan semantik. Himpunan kandidat kemudian dibentuk melalui:

$$C_k(q) = \text{TopK}_{c \in \mathcal{K}} s_{\text{hybrid}}(q, c), \quad (3.5)$$

dengan $\mathcal{K}$ sebagai seluruh konsep pada basis pengetahuan. Nilai α dan k merupakan parameter metode yang ditentukan pada data pengembangan, sehingga prosedur penentuannya dijelaskan pada Bab IV.

Menurut Wu dkk. (2025), terdapat tiga cara utama untuk menggabungkan pengetahuan hasil *retrieval* ke dalam generator. Pertama, *query-based fusion*, yaitu pendekatan yang langsung menyisipkan pengetahuan ke dalam *input prompt*. Pendekatan ini paling sederhana dan paling banyak digunakan, misalnya dengan pola instruksi seperti “Berdasarkan dokumen berikut, jawablah pertanyaan berikut”. Kedua, *logits-based fusion*, yaitu pendekatan yang memproses pengetahuan secara terpisah untuk menghasilkan distribusi logit, lalu menggabungkannya dengan lo-

git dari input asli pada lapisan keluaran. Contoh pendekatan ini adalah kNN-LM dan REPLUG. Ketiga, *latent fusion*, yaitu pendekatan yang menginjeksikan pengetahuan langsung ke dalam *hidden states* generator, misalnya melalui mekanisme *cross-attention* seperti pada RETRO atau melalui *weighted addition*. Dibanding dua pendekatan sebelumnya, *latent fusion* lebih mendalam tetapi juga menuntut modifikasi arsitektur yang lebih kompleks.

Tahap terakhir adalah **generator**, yaitu komponen yang menghasilkan respons akhir dalam bentuk teks. Generator umumnya berupa LLM seperti BART, GPT, atau LLaMA yang menerima input yang telah diperkaya dengan konteks eksternal. Dengan demikian, keluaran akhir tidak hanya bergantung pada memori parametrik model, tetapi juga pada bukti atau konteks yang berhasil diambil selama proses *retrieval*.

3.3.2 Evolusi RAG


Berdasarkan sintesis yang disampaikan oleh Gao dkk. (2024), perkembangan RAG dapat dibagi menjadi tiga paradigma utama yang menunjukkan peningkatan bertahap dari sisi kualitas *retrieval*, fleksibilitas alur, dan kemampuan penalaran, yaitu *Naive RAG*, *Advanced RAG*, dan *Modular RAG*.

Naive RAG merupakan bentuk paling dasar dari arsitektur ini. Paradigma tersebut umumnya terdiri atas tiga tahap, yaitu *indexing*, *retrieval*, dan *generation*. Pada tahap *indexing*, dokumen dibersihkan, dipotong menjadi *chunk*, diubah menjadi representasi vektor, lalu disimpan ke dalam basis data vektor. Pada tahap *retrieval*, kueri juga diubah menjadi vektor untuk menghitung kemiripan dan mengambil *top-k chunk* dengan skor tertinggi. Selanjutnya, pada tahap *generation*, kueri dan dokumen yang terambil digabungkan ke dalam *prompt* agar LLM dapat menyusun jawaban yang koheren. Meskipun sederhana dan efektif sebagai fondasi, *Naive RAG* memiliki beberapa kelemahan, yaitu akurasi pengambilan yang masih terbatas, potensi kehilangan informasi penting jika kueri tidak dirumuskan dengan baik, kecenderungan tetap mengalami halusinasi bila konteks yang diambil tidak memadai, dan integrasi konteks yang kadang terputus-putus atau berulang (Gao dkk., 2024).

Advanced RAG berkembang dari arsitektur dasar tersebut dengan menambahkan optimasi pada tahap sebelum dan sesudah *retrieval*. Pada tahap *pre-retrieval optimization*, perbaikan dapat dilakukan melalui optimasi indeks, misalnya dengan segmentasi yang lebih halus, penambahan metadata seperti *timestamp*, nama penulis, atau kategori, serta penggunaan *hybrid retrieval* yang menggabungkan BM25 dengan *dense embedding*. Selain itu, dilakukan pula optimasi kueri melalui *query rewriting*, *query expansion*, dan metode seperti HyDE yang menghasilkan dokumen

hipotesis untuk memandu pencarian (Gao dkk., 2024). Pada tahap *post-retrieval optimization*, dokumen dapat di-*rerank* agar informasi paling relevan muncul pada posisi yang strategis di dalam *prompt*, sehingga mengurangi fenomena *lost in the middle*. Konteks juga dapat dikompresi melalui *context compression* untuk membuang kata atau kalimat yang tidak penting, sehingga prompt menjadi lebih ringkas dan biaya komputasi lebih efisien. Meskipun kualitasnya meningkat, *Advanced RAG* pada dasarnya masih mengikuti alur sekuensial yang relatif tetap dan belum sepenuhnya fleksibel untuk tugas kompleks dengan penalaran multi-langkah.

Paradigma yang lebih mutakhir adalah *Modular RAG*, yaitu pendekatan yang memperkenalkan modul-modul khusus serta pola aliran yang lebih dinamis. Dalam paradigma ini, RAG tidak lagi dibatasi pada urutan *retrieve-generate* yang kaku. Gao dkk. (2024) menjelaskan bahwa modul yang dapat ditambahkan antara lain *search module* untuk mengakses berbagai sumber seperti mesin pencari web, basis data, atau *knowledge graph*; *memory module* untuk membentuk memori eksternal yang lebih persisten; *routing module* untuk memilih jalur inferensi yang paling sesuai bagi tiap kueri; *predict module* untuk mengurangi redundansi dan derau; serta *task adapter module* untuk menyesuaikan sistem terhadap berbagai tugas hi-lir. Pola aliran yang muncul pun lebih bervariasi, misalnya *Rewrite-Retrieve-Read*, *Generate-Read*, *Iterative Retrieval-Generation*, *Self-RAG*, dan *FLARE*. Keunggulan utama *Modular RAG* adalah adaptabilitas dan kemampuannya mendukung penalaran multi-langkah, tetapi kompleksitas rancangan dan kebutuhan komputasinya juga lebih tinggi dibandingkan paradigma sebelumnya.



Gambar 3.4: Paradigma dalam evolusi RAG

Gambar 3.4 merangkum bahwa evolusi RAG bergerak dari bentuk yang seder-


hana menuju arsitektur yang semakin adaptif. Dalam penelitian ini, pemahaman terhadap evolusi tersebut penting karena kebutuhan *mapping* terminologi medis Bahasa Indonesia tidak hanya memerlukan pencarian kandidat konsep, tetapi juga kemampuan menangani variasi ejaan, singkatan, konteks panjang, serta penalaran bertahap pada entitas klinis komposit. Relevansi konteks bahasa Indonesia ini juga sejalan dengan temuan Purwitasari dkk. (2023) bahwa data kesehatan berbahasa Indonesia menghadirkan variasi leksikal yang menuntut model lebih robust terhadap bentuk-bentuk istilah nonbaku.

Secara keseluruhan, RAG telah terbukti menjadi pendekatan yang kuat untuk mengatasi keterbatasan fundamental LLM parametrik murni, terutama pada tugas yang membutuhkan pengetahuan faktual, transparansi sumber, dan kemampuan memperbarui konteks secara dinamis. Melalui evolusi dari *Naive RAG* yang sederhana hingga *Modular RAG* yang adaptif, pendekatan ini semakin mampu menangani kueri kompleks dan penalaran multi-langkah sambil tetap mempertahankan keunggulan efisiensi parameter dan keterlacakan sumber pengetahuan. Oleh karena itu, RAG menjadi landasan penting bagi penelitian ini dalam merancang sistem *mapping* terminologi klinis yang lebih akurat, fleksibel, dan sesuai dengan karakteristik data klinis Indonesia.

3.4 Implementasi RAG dan LLM dalam CDE-Mapper

CDE-Mapper merupakan kerangka kerja yang dikembangkan untuk memetakan *clinical data elements* (CDE), baik yang bersifat atomik maupun komposit, ke terminologi terkontrol seperti SNOMED CT, LOINC, ATC, dan RxNorm (Gilani dkk., 2025). Fokus utamanya adalah membangun *framework* otomatis yang mampu mengatasi tantangan standarisasi data klinis, terutama masalah *inconsistent concept linking*, sehingga interoperabilitas dan integrasi data klinis dapat ditingkatkan. Relevansi CDE-Mapper dalam penelitian ini sangat tinggi karena pendekatan tersebut menunjukkan bagaimana RAG dan LLM dapat digabungkan secara sistematis untuk menyelesaikan tugas *mapping* yang tidak hanya bergantung pada kesamaan leksikal, tetapi juga pada konteks semantik dan struktur atribut dari suatu elemen data.

3.4.1 Framework CDE-Mapper Gilani



Gambar 3.5: Framework CDE-Mapper

Arsitektur penelitian Gilani dkk. digambarkan pada Gambar 3.5. Secara umum, arsitektur tersebut terdiri atas enam komponen utama yang saling berurutan, yaitu *input data dictionary & linking rules*, *query decomposition*, *knowledge retrieval*, *knowledge filtering*, *two-step reranking*, dan *knowledge reservoir integration* (Gilani dkk., 2025).

Komponen pertama adalah *input data dictionary dan linking rules*. Input pada tahap ini berupa *data dictionary* yang memuat atribut seperti *label*, *categorical*, *unit*, *formula*, dan *visit*. Selain itu, disiapkan pula *linking rules* yang dapat dikonfigurasi ulang untuk mengarahkan sistem pada terminologi target yang paling tepat. Sebagai contoh, entitas diagnosis diprioritaskan untuk dihubungkan ke SNOMED CT, entitas obat diarahkan ke RxNorm atau ATC, sedangkan pengukuran laboratorium diarahkan ke LOINC. Logika dari aturan ini adalah bahwa setiap jenis data

klinis memiliki domain terminologi yang paling sesuai dengan tujuan representasinya. Pemilihan kode tidak semata-mata didasarkan pada kemiripan kata, melainkan juga pada kesesuaian domain, tingkat *granularity*, dan fungsi terminologi tersebut dalam ekosistem data kesehatan. Dengan kata lain, jika suatu istilah ditemukan memiliki padanan di lebih dari satu kosakata, maka sistem perlu memprioritaskan kode yang paling tepat secara semantik dan paling sesuai dengan konteks penggunaan datanya.

Komponen kedua adalah ***query decomposition*** atau pemecahan kueri. Tujuan tahap ini adalah memecah kueri kompleks menjadi komponen-komponen kecil yang dapat dicari secara terpisah. Setiap komponen, seperti *base entity*, *associated entities*, maupun kategori nilai, diubah menjadi *sub-query*. Pada tahap ini digunakan LLM, misalnya Llama 3.1 atau GPT-4o-mini, dengan pendekatan *in-context learning* dan contoh-contoh yang disusun oleh ahli. Keluaran akhirnya berupa struktur JSON yang rapi, sehingga dapat langsung dipakai pada tahap pencarian berikutnya (Gilani dkk., 2025). Tahap ini sangat penting karena CDE komposit sering kali tidak dapat dipetakan dengan benar bila diperlakukan sebagai satu frasa utuh tanpa analisis atributnya.

Komponen ketiga adalah ***knowledge retrieval*** dengan strategi *ensemble*. Pada tahap ini digunakan pendekatan *dual embedding* yang menggabungkan SPLADE dan SapBERT (Gilani dkk., 2025). SPLADE berperan sebagai *retriever* yang berfokus pada kecocokan leksikal dan *exact match*. Model ini berguna ketika sistem perlu menemukan konsep kanonik yang secara tekstual sangat dekat dengan kueri. Sebagai contoh, untuk CDE seperti *heart attack*, SPLADE diarahkan untuk mencari istilah yang tepat sebagai satu kesatuan, bukan memecahnya menjadi token-token yang berdiri sendiri. Sebaliknya, SapBERT berperan sebagai *semantic retriever* yang dirancang khusus untuk entitas biomedis. Dengan *self-alignment pretraining*, SapBERT mampu mendekatkan representasi dari istilah-istilah sinonim, sehingga istilah seperti *heart attack* dapat dipetakan dekat dengan *myocardial infarction*. Kedua *retriever* tersebut mencari kandidat konsep dalam *knowledge base* yang telah diperkaya dengan lebih dari jutaan konsep dari berbagai terminologi serta sinonim hasil pemetaan antar-vocabulary. Hasil dari tahap ini adalah daftar kandidat konsep teratas untuk setiap *sub-query*.

Komponen keempat adalah ***knowledge filtering***. Fungsi tahap ini adalah menyaring kandidat yang tidak relevan sebelum dilakukan penilaian ulang yang lebih mahal. Gilani dkk. menggunakan *dual filtering strategy*, yaitu *metadata-based filtering* dan *similarity threshold* (Gilani dkk., 2025). Pada *metadata-based filtering*, kandidat hanya dipertahankan bila sesuai dengan tipe atau domain konsep yang

diharapkan. Misalnya, bila kueri bertipe *condition*, maka sistem hanya mempertahankan konsep dari domain gangguan atau kondisi yang relevan. Pada saat yang sama, *similarity threshold* digunakan untuk membuang kandidat dengan skor kemiripan di bawah ambang batas tertentu. Hasilnya adalah himpunan kandidat yang lebih bersih dari *noise*, sehingga tahap berikutnya dapat fokus pada konsep yang benar-benar layak dipertimbangkan.

Komponen kelima adalah ***two-step reranking***, yaitu tahap yang menjadi salah satu kekuatan utama CDE-Mapper. Pada langkah pertama, LLM diminta memberikan skor relevansi untuk setiap kandidat dalam rentang tertentu. Pada langkah kedua, berdasarkan skor tersebut, kandidat diklasifikasikan ke dalam kategori seperti *exact match*, *highly relevant*, *partially relevant*, dan *not relevant*. Untuk meningkatkan reliabilitas, diterapkan pula mekanisme *self-consistency*, yaitu proses penilaian diulang beberapa kali dengan prompt yang sama dan kemudian dihitung *confidence score*-nya (Gilani dkk., 2025). Hanya kandidat dengan tingkat konsistensi tinggi yang akan dipilih. Strategi ini penting karena penilaian LLM pada kandidat semantik dapat bersifat sensitif terhadap variasi formulasi prompt, sehingga pengulangan dan konsolidasi hasil membantu menstabilkan keputusan akhir.

Komponen keenam adalah ***knowledge reservoir integration***. Tahap ini berfungsi menyimpan hasil pemetaan yang telah divalidasi agar dapat dimanfaatkan kembali pada masa mendatang. Penyimpanan dilakukan setidaknya dalam dua format, yaitu format *dictionary* untuk pencocokan eksak yang cepat, dan format *triple store* untuk relasi yang lebih kompleks antar konsep (Gilani dkk., 2025). Validasi dilakukan secara berlapis: LLM terlebih dahulu memberi label apakah hasil tersebut *correct*, *partially correct*, atau *incorrect*, kemudian ahli klinis meninjau konsep-konsep baru sebelum dimasukkan ke reservoir. Dengan mekanisme *human-in-the-loop* ini, kualitas basis pengetahuan dapat meningkat secara bertahap. Keuntungan utamanya adalah sistem menjadi semakin cepat dan akurat dari waktu ke waktu karena kasus-kasus serupa tidak perlu selalu diproses dari awal.

3.4.2 Temuan Utama Gilani

Gilani dkk. melaporkan bahwa CDE-Mapper menunjukkan **kinerja yang superior dibandingkan berbagai baseline** (Gilani dkk., 2025). Pada berbagai dataset, termasuk NCBI-DC dan *HF Studies*, CDE-Mapper secara konsisten mengungguli model seperti SapBERT, KRISS BERT, BioBERT-SNOMED, dan PromptLink. Pada dataset NCBI-DC, konfigurasi berbasis Llama 3.1 mencapai akurasi 94,4%, sedangkan SapBERT mencapai 83,2%. Pada dataset *HF Studies* yang memuat CDE komposit, CDE-Mapper mencapai akurasi 86,4%, lebih tinggi daripada baseline

terbaik yang berada pada kisaran 77,2%.

Temuan penting berikutnya adalah **keefektifan CDE-Mapper pada berbagai tipe CDE**. Untuk CDE atomik, CDE-Mapper mencapai akurasi sekitar 89,7%. Untuk CDE komposit, akurasinya mencapai sekitar 80,5%, yang tetap berada di atas baseline seperti KRISS BERT dan BioBERT-SNOMED. Pada CDE dependen, performanya juga dilaporkan berada pada kisaran 80,0–86,7%, mengungguli SapBERT (Gilani dkk., 2025). Hasil ini menunjukkan bahwa kombinasi dekomposisi kueri, *retrieval* majemuk, dan *reranking* berbasis LLM memberi keuntungan khusus untuk struktur data yang kompleks.

Gilani dkk. juga menunjukkan **kontribusi nyata dari setiap komponen individual**. Modul *query decomposition* memperlihatkan *recall* yang sangat tinggi dalam ekstraksi atribut, sementara kualitas ekstraksi nilai meningkat ketika digunakan model yang lebih kuat. *Knowledge filtering* terbukti meningkatkan akurasi *retrieval*, terutama dalam konfigurasi yang mempertimbangkan konteks. Demikian pula, *two-step reranking* secara konsisten memberikan peningkatan performa pada berbagai dataset, termasuk pada *HF Studies*, karena membantu LLM membedakan kandidat yang tampak mirip tetapi sebenarnya berbeda tingkat relevansinya (Gilani dkk., 2025).

Dalam **kasus klinis yang kompleks**, CDE-Mapper juga mampu menangani konsep yang tidak sederhana. Sebagai contoh, frasa seperti *heart rate measured in recumbent position* dapat dipetakan ke kombinasi konsep yang merepresentasikan *heart rate* dan *recumbent body position*. Demikian pula, ekspresi seperti *mild to moderate asthma exacerbations* dapat dipetakan ke representasi yang tetap menangkap derajat keparahan klinisnya (Gilani dkk., 2025). Temuan ini penting karena memperlihatkan bahwa pendekatan tersebut tidak hanya cocok untuk istilah tunggal, tetapi juga untuk struktur klinis komposit yang kaya atribut.

Dari sisi **efisiensi dan skalabilitas**, *knowledge reservoir* memberi kontribusi penting karena konsep yang telah tervalidasi dapat digunakan kembali, sehingga beban komputasi untuk kueri berulang berkurang. Selain itu, penggunaan model terbuka seperti Llama 3.1 memperlihatkan bahwa pendekatan *open-source* dapat tetap *cost-effective* tanpa harus mengorbankan akurasi secara berarti (Gilani dkk., 2025). Bagi penelitian ini, temuan tersebut relevan karena implementasi pada konteks Indonesia juga menuntut efisiensi biaya dan kemampuan adaptasi jangka panjang.

Meskipun demikian, Gilani dkk. juga mencatat beberapa **keterbatasan dan area pengembangan**. Kinerja sistem sangat bergantung pada kualitas contoh kontekstual, kelengkapan kosakata, dan mutu *knowledge base*. Dataset yang memiliki

sinonim terbatas atau struktur hierarki yang kurang kaya menunjukkan peningkatan yang lebih kecil. Beberapa kasus *edge*, seperti istilah klinis yang sangat ambigu atau sangat spesifik, masih belum dapat ditangani secara optimal. Selain itu, biaya komputasi dan kecepatan inferensi LLM tetap menjadi tantangan praktis (Gilani dkk., 2025). Dalam konteks penelitian ini, keterbatasan tersebut menunjukkan bahwa CDE-Mapper sangat menjanjikan sebagai fondasi, tetapi tetap memerlukan adaptasi lebih lanjut untuk menghadapi variasi istilah, singkatan, dan gaya bahasa pada data klinis Bahasa Indonesia, sebagaimana tercermin pula dalam tantangan data kesehatan lokal yang telah dibahas oleh Purwitasari dkk. (2023).

3.5 Dataset untuk *Clinical Terminology Mapping*

Setiap penelitian tentang *clinical terminology mapping* memerlukan dataset, baik untuk pelatihan, validasi, maupun evaluasi model yang dikembangkan. Dari telaah berbagai penelitian, sifat dataset yang digunakan dapat dikelompokkan ke dalam beberapa kategori utama, yaitu *open*, *open (credentialed)*, *restricted*, dan *synthetic*. Pengelompokan ini penting karena karakteristik akses data sangat memengaruhi replikasi penelitian, skala eksperimen, serta tingkat generalisasi hasil. Penjelasan kelompok dataset tersebut dapat dirangkum sebagai berikut.

1. ***Open***. Dataset pada kelompok ini dapat diakses publik, biasanya melalui PhysioNet, GitHub, atau repositori institusi, tanpa persyaratan khusus atau hanya dengan registrasi sederhana. Contoh dataset terbuka yang digunakan dalam penelitian pemetaan terminologi antara lain SIGTAP dan Athena pada studi Vanzin dkk. (De Barros Vanzin dkk., 2025), BC5CDR-D dan NCBI-DC pada penelitian CDE-Mapper oleh Gilani dkk. (Gilani dkk., 2025), serta *openEHR* pada penelitian Meizoso dkk. (Meizoso dkk., 2011). Selain itu, terdapat pula sumber terminologi yang secara praktis dapat digunakan luas tetapi tetap memerlukan lisensi tertentu, misalnya SNOMED CT, sebagaimana muncul dalam penelitian Kate (Kate, 2020) dan Zahra dan Kate (Zahra & Kate, 2024). Dalam praktik riset, kelompok dataset seperti ini sangat penting karena memungkinkan eksperimen yang relatif transparan dan lebih mudah direplikasi.
2. ***Open (credentialed)***. Dataset dalam kelompok ini pada prinsipnya tersedia untuk publik, tetapi memerlukan pemenuhan syarat tertentu, misalnya pelatihan etika, akreditasi, atau persetujuan penggunaan data. Contoh yang paling umum adalah MIMIC-IV (Bennett dkk., 2023) dan MIMIC-III yang banyak dipakai dalam penelitian interoperabilitas, pemetaan, dan transformasi model

data klinis (Gilani dkk., 2025; Xiao dkk., 2022). Keunggulan kelompok ini adalah data yang tersedia umumnya kaya, realistis, dan banyak digunakan secara internasional, tetapi aksesnya tetap diawasi untuk menjaga aspek privasi dan tata kelola data.

3. ***Restricted***. Data pada kelompok ini tidak tersedia untuk publik dan umumnya hanya dapat digunakan oleh peneliti internal institusi atau pihak yang memiliki perjanjian kerahasiaan. Jenis dataset ini justru merupakan salah satu yang paling sering digunakan dalam penelitian karena banyak studi terminologi medis berangkat dari rekam medis nyata di rumah sakit tertentu. Contohnya adalah korpus klinis Mayo Clinic yang digunakan oleh Hong dkk. (Hong dkk., 2019). Dataset terbatas juga banyak dijumpai pada studi yang menggunakan data rumah sakit tertentu, misalnya data rumah sakit di Korea yang dimanfaatkan oleh Huh (Huh, 2025), Park dkk. (Park dkk., 2026), dan Eslami dkk. (Eslami dkk., 2026), serta studi lain pada data rumah sakit di Eropa. Secara umum, bila suatu penelitian tidak menjelaskan secara rinci mekanisme akses datanya, ada kemungkinan dataset tersebut juga termasuk dalam kategori terbatas. Kelebihan kelompok ini adalah kedekatannya dengan kondisi dunia nyata, tetapi kelemahannya adalah sulit direplikasi secara luas.
4. ***Synthetic***. Dataset sintetis dibangkitkan secara sengaja oleh peneliti, biasanya dengan tetap berlandaskan pada struktur atau distribusi data asli, untuk mengurangi risiko pelanggaran privasi sekaligus mempertahankan kegunaan analitis data. Pendekatan seperti ini relevan pada penelitian yang berupaya menyiapkan data untuk harmonisasi atau interoperabilitas lintas institusi ketika pembagian data mentah sulit dilakukan. Salah satu contoh yang dapat dirujuk dalam konteks harmonisasi dan perlindungan data adalah studi harmonisasi data lintas institusi yang menekankan kebutuhan perlindungan data dan interoperabilitas. Meskipun dataset sintetis menjanjikan dari sisi perlindungan privasi, tantangan utamanya adalah memastikan bahwa data hasil sintesis tetap cukup representatif untuk menguji performa model *mapping* secara realistis.

Dalam konteks penelitian ini, pemilihan dataset tidak hanya ditentukan oleh ketersediaan akses, tetapi juga oleh kesesuaian bahasa, tingkat variasi istilah, dan kedekatannya dengan praktik klinis nyata. Di tingkat internasional, dataset terbuka dan *credentialed* banyak digunakan untuk membangun pembanding yang reprodu-sibel. Namun, untuk konteks Indonesia, kebutuhan terhadap data yang merepre-sentasikan variasi istilah lokal, singkatan, dan bentuk bahasa tidak baku menjadi

sangat penting. Temuan Purwitasari dkk. (Purwitasari dkk., 2023) menegaskan bahwa data kesehatan berbahasa Indonesia, khususnya pada konteks konsultasi kesehatan daring, memiliki karakteristik leksikal yang khas dan menuntut pendekatan model yang adaptif. Karena itu, pembahasan dataset dalam penelitian ini juga harus mempertimbangkan bukan hanya aspek aksesibilitas, tetapi juga kecocokannya untuk merepresentasikan variasi terminologi klinis Bahasa Indonesia.

3.6 Metrik Evaluasi

Evaluasi pada penelitian *clinical terminology mapping* tidak cukup hanya menggunakan satu metrik tunggal, karena tugas ini melibatkan beberapa tahap, mulai dari ekstraksi entitas, pencarian kandidat, penyaringan, *reranking*, hingga pemilihan kode akhir. Oleh sebab itu, metrik evaluasi yang digunakan perlu mencakup akurasi hasil akhir, kualitas kandidat yang dihasilkan, konsistensi keputusan, dan efisiensi komputasi.

3.6.1 Akurasi (*Accuracy*)

Metrik paling dasar adalah **akurasi** (*accuracy*), yaitu proporsi prediksi yang benar dibandingkan seluruh kasus yang diuji. Dalam konteks *mapping*, akurasi umumnya dipakai untuk menilai apakah kode terminologi yang dipilih sistem sama dengan *gold standard*. Secara matematis, akurasi dapat dinyatakan sebagai Persamaan 3.6.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.6)$$

Metrik ini mudah dipahami dan cocok untuk memberikan gambaran umum performa sistem. Penggunaan akurasi sebagai indikator utama juga tampak pada berbagai studi pemetaan terminologi, misalnya pada CDE-Mapper oleh Gilani dkk., pemetaan terminologi lokal ke SNOMED CT oleh Huh, serta pengembangan alat pemetaan otomatis oleh Park dkk. (Gilani dkk., 2025; Huh, 2025; Park dkk., 2026). Namun, akurasi saja belum cukup, terutama ketika distribusi kelas tidak seimbang atau ketika satu istilah dapat memiliki lebih dari satu kandidat yang secara semantik mendekati benar.

3.6.2 *Precision*, *Recall*, dan *F1-score*

Evaluasi juga perlu menggunakan *precision*, *recall*, dan **F1-score**. *Precision* mengukur proporsi prediksi positif yang benar dari seluruh prediksi positif yang

dihasilkan sistem dan dapat dinyatakan sebagai Persamaan 3.7.

$$Precision = \frac{TP}{TP + FP} \quad (3.7)$$

Recall mengukur proporsi kasus benar yang berhasil ditemukan sistem dari seluruh kasus benar yang tersedia pada *gold standard*, sebagaimana ditunjukkan pada Persamaan 3.8.

$$Recall = \frac{TP}{TP + FN} \quad (3.8)$$

Sementara itu, F1-score merupakan rerata harmonik antara *precision* dan *recall*, sehingga berguna ketika peneliti ingin menyeimbangkan ketepatan dan kelengkapan hasil. Formula F1-score diberikan pada Persamaan 3.9.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.9)$$

Penggunaan tiga metrik ini sangat umum pada tugas ekstraksi maupun pemetaan entitas medis; misalnya, Cai dkk. secara eksplisit melaporkan akurasi, *recall*, dan F1 pada eksperimen NER medis, sedangkan studi Vanzin dkk. menekankan perbandingan performa melalui F1 dan *recall* pada tugas *vocabulary mapping* (De Barros Vanzin dkk., 2025; Xiaocheng dkk., 2022).

3.6.3 Coverage

Pada sistem berbasis *retrieval* dan *reranking*, metrik evaluasi sebaiknya diperluas dengan **coverage**. *Coverage* dapat didefinisikan sebagai proporsi entitas atau istilah yang berhasil diberi kandidat kode yang valid, yaitu tidak kosong, setelah tahap *filtering*. Secara matematis, *coverage* dapat dirumuskan seperti pada Persamaan 3.10.

$$Coverage = \frac{N_{\text{entitas dengan kandidat valid}}}{N_{\text{seluruh entitas}}} \quad (3.10)$$

Metrik ini penting karena suatu sistem bisa saja tampak akurat pada kasus yang berhasil diproses, tetapi sebenarnya gagal menghasilkan kandidat pada banyak kasus lain. Dengan demikian, *coverage* membantu menilai seberapa luas sistem benar-benar dapat menangani keseluruhan data masukan. Dalam kerangka seperti CDE-Mapper, logika evaluasi semacam ini relevan karena performa akhir sangat dipengaruhi oleh keberhasilan sistem menghasilkan kandidat yang layak sebelum tahap pemilihan akhir (Gilani dkk., 2025).

3.6.4 Agreement dan Consistency

Untuk arsitektur yang memanfaatkan LLM pada tahap *reranking*, **agreement** atau **consistency** juga menjadi metrik yang penting. Metrik ini mengukur sejauh mana keputusan sistem stabil ketika proses *reranking* diulang, misalnya melalui mekanisme *self-consistency* (X. Wang dkk., 2023), serta sejauh mana sistem memberi keputusan yang konsisten pada dokumen atau istilah serupa setelah memanfaatkan *knowledge reservoir*. Salah satu bentuk sederhana pengukuran konsistensi dapat dinyatakan sebagai proporsi keputusan yang sama antar-pengulangan, sebagaimana Persamaan 3.11.

$$\text{Consistency} = \frac{N_{\text{keputusan konsisten}}}{N_{\text{seluruh pengulangan atau pasangan kasus}}} \quad (3.11)$$

Untuk penilaian kesepakatan antar-anotator pada pembentukan *gold standard*, koefisien Kappa dapat digunakan untuk memperhitungkan kesepakatan yang terjadi di luar peluang kebetulan. Formulasi umumnya dinyatakan pada Persamaan 3.12.

$$\kappa = \frac{P_o - P_e}{1 - P_e} \quad (3.12)$$

Dalam praktiknya, konsistensi dapat diukur melalui persentase kecocokan antar-pengulangan, tingkat kesepakatan keputusan akhir, atau kestabilan kategori hasil seperti *exact match*, *partially relevant*, dan *not relevant*. Metrik ini penting karena sistem berbasis LLM dapat bersifat sensitif terhadap variasi prompt atau konteks kecil, dan kebutuhan untuk menilai kestabilan keputusan semacam ini sejalan dengan penggunaan *self-consistency* pada CDE-Mapper (Gilani dkk., 2025).

3.6.5 Efisiensi

Selain kualitas hasil, **efisiensi** juga merupakan dimensi evaluasi yang penting. Efisiensi dapat diukur melalui waktu rata-rata inferensi per istilah atau per dokumen, penggunaan sumber daya komputasi, serta dampak *knowledge reservoir* terhadap percepatan proses *mapping*. Salah satu formulasi yang sederhana adalah waktu inferensi rata-rata sebagaimana Persamaan 3.13.

$$\bar{t}_{\text{inferensi}} = \frac{1}{N} \sum_{i=1}^N t_i \quad (3.13)$$

Untuk mengukur peningkatan efisiensi terhadap metode pembandingan, persentase percepatan dapat dirumuskan seperti pada Persamaan 3.14.

$$Speedup(\%) = \frac{t_{baseline} - t_{usulan}}{t_{baseline}} \times 100\% \quad (3.14)$$

Pada sistem yang akan digunakan secara operasional, metrik efisiensi sangat penting karena model yang sangat akurat tetapi terlalu lambat atau terlalu mahal secara komputasi belum tentu layak diterapkan pada skala besar. Pertimbangan efisiensi ini juga tampak pada studi pemetaan berbasis LLM yang menimbang *trade-off* antara kualitas hasil dan biaya inferensi, misalnya pada penelitian Vanzin dkk. dan Gilani dkk. (De Barros Vanzin dkk., 2025; Gilani dkk., 2025).

3.6.6 Metrik *Retrieval* Tambahan

Dalam penelitian berbasis *retrieval*, beberapa metrik tambahan juga sering relevan, misalnya *Top-k accuracy*, *Recall@k*, atau *Mean Reciprocal Rank* (MRR). *Top-k accuracy* menilai apakah kode benar muncul di antara k kandidat teratas yang dihasilkan sistem, yang dapat dirumuskan seperti pada Persamaan 3.15.

$$Top-k Accuracy = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i \in C_i^{(k)}) \quad (3.15)$$

Recall@k mengukur proporsi kasus di mana kandidat benar berhasil masuk ke dalam daftar teratas, sebagaimana pada Persamaan 3.16.

$$Recall@k = \frac{1}{N} \sum_{i=1}^N \frac{|R_i \cap C_i^{(k)}|}{|R_i|} \quad (3.16)$$

dengan R_i sebagai himpunan seluruh konsep relevan untuk kasus ke- i . Jika setiap kueri hanya memiliki satu kode relevan, Persamaan 3.16 ekuivalen dengan *Top-k accuracy*; apabila terdapat beberapa konsep relevan, persamaan tersebut mengukur proporsi konsep relevan yang berhasil ditemukan. Sementara itu, MRR memberi bobot lebih tinggi jika kandidat benar muncul pada posisi yang lebih atas, seperti ditunjukkan pada Persamaan 3.17.

$$MRR = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i} \quad (3.17)$$

Metrik-metrik ini sangat berguna untuk mengevaluasi tahap *retrieval* sebelum *re-ranking*, terutama pada sistem seperti CDE-Mapper yang memisahkan pencarian

kandidat dari pemilihan akhir. Kebutuhan untuk mengevaluasi kualitas kandidat awal juga konsisten dengan temuan Gilani dkk. bahwa peningkatan pada tahap *retrieval* dan *filtering* berkontribusi langsung terhadap hasil pemetaan akhir (Gilani dkk., 2025).

3.6.7 Ringkasan Penggunaan Metrik

Secara keseluruhan, evaluasi pada penelitian ini perlu memadukan metrik akurasi akhir, metrik kualitas *retrieval*, metrik konsistensi keputusan, dan metrik efisiensi. Dengan kombinasi tersebut, performa sistem *mapping* dapat dinilai secara lebih menyeluruh, tidak hanya dari sisi ketepatan kode akhir, tetapi juga dari sisi cakupan penanganan kasus, kestabilan keputusan, dan kelayakan implementasi pada data klinis nyata.

Tabel 3.5: Ringkasan metrik evaluasi untuk *clinical terminology mapping*

Metrik	Fungsi utama	Interpretasi dalam penelitian
Akurasi	Mengukur proporsi prediksi kode yang sama dengan <i>gold standard</i> .	Menilai ketepatan hasil akhir pemetaan.
<i>Precision</i>	Mengukur proporsi prediksi positif yang benar.	Menilai seberapa presisi kode yang dipilih sistem.
<i>Recall</i>	Mengukur proporsi kasus benar yang berhasil ditemukan.	Menilai kemampuan sistem agar konsep benar tidak terlewat.
F1-score	Menyeimbangkan <i>precision</i> dan <i>recall</i> .	Cocok ketika dibutuhkan ukuran performa yang lebih seimbang.
<i>Coverage</i>	Mengukur proporsi entitas yang memperoleh kandidat valid.	Menilai keluasan sistem dalam menangani seluruh masukan.
<i>Agreement/Consistency</i>	Mengukur kestabilan keputusan antar-pengulangan atau antar-konteks.	Relevan untuk <i>reranking</i> berbasis LLM dan <i>knowledge reservoir</i> .
Efisiensi	Mengukur waktu inferensi dan beban komputasi.	Menilai kelayakan implementasi pada skala operasional.
<i>Top-k accuracy, Recall@k, MRR</i>	Mengukur kualitas daftar kandidat hasil <i>retrieval</i> .	Menilai apakah konsep benar muncul cukup awal sebelum <i>reranking</i> .

BAB IV


METODE PENELITIAN

4.1 Gambaran Umum Penelitian

Penelitian ini bertujuan untuk mengembangkan dan mengevaluasi sebuah *framework* adaptif untuk pemetaan terminologi klinis Bahasa Indonesia ke kosakata terkendali standar, seperti SNOMED CT, LOINC, dan ICD-10. Pendekatan utama yang diusulkan adalah adaptasi dari arsitektur CDE-Mapper (Gilani dkk., 2025) dengan optimalisasi komponen ekstraksi teks klinis yang menggunakan bahasa Indonesia dan berupa teks panjang.

4.2 Tahapan Penelitian

Penelitian ini akan dilaksanakan dalam lima tahapan utama seperti digambarkan pada Gambar 4.1.



Gambar 4.1: Tahapan penelitian

Penelitian ini dilaksanakan dalam lima tahapan utama yang saling terkait secara berurutan maupun iteratif. Kelima tahapan pada Gambar 4.1 dijelaskan sebagai berikut.

4.2.1 Persiapan dan Analisis

Tahap ini bertujuan untuk membangun fondasi teoritis dan menyiapkan sumber daya data yang diperlukan sebelum memasuki pengembangan model.

Studi Literatur

Studi literatur dilakukan secara sistematis untuk mengidentifikasi *state-of-the-art* dalam pemetaan terminologi klinis. Ruang lingkup literatur mencakup standar interoperabilitas kesehatan, seperti FHIR, SNOMED CT, LOINC, dan ICD-10, serta implementasinya di SATUSEHAT (Ayuningtyas dkk., 2025; Heryawan dkk., 2025); metode pemetaan dari *rule-based*, *machine learning*, *deep learning*, hingga LLM dan RAG (Gilani dkk., 2025; Hristov dkk., 2021; Meizoso dkk., 2011); serta arsitektur CDE-Mapper dan keterbatasannya dalam memproses teks panjang dengan *multiple CDE* komposit (Gilani dkk., 2025). Hasil studi literatur digunakan untuk merumuskan kerangka konseptual dan menentukan komponen kunci yang akan diadaptasi.

Identifikasi dan Pengembangan Dataset

Kegiatan ini mencakup identifikasi sumber data istilah klinis Bahasa Indonesia. Data diperoleh dari rekam medis elektronik (RME) puskesmas atau klinik swasta, dan platform konsultasi kesehatan daring yang telah dianonimkan. Sumber-sumber ini dipilih karena merepresentasikan variasi nyata istilah lokal, singkatan, dan kesalahan eja (Hossain dkk., 2025; Purwitasari dkk., 2023). Selain itu, dikumpulkan pula kosakata terkendali standar berupa SNOMED CT, LOINC, dan ICD-10 sebagai terminologi target.

Pembangunan dataset emas (*gold standard*) dilakukan dengan menganotasi sampel 100–200 istilah klinis secara manual oleh tenaga medis, seperti dokter atau perekam medis, dengan kode standar yang sesuai. Validasi antar-anotator (*inter-annotator agreement*) dihitung menggunakan koefisien Kappa Fleiss untuk menjamin konsistensi. Dataset emas ini menjadi kebenaran dasar untuk evaluasi performa model.

4.2.2 Perancangan dan Pengembangan Model

Pada tahap ini, arsitektur model usulan dirancang dan komponen *preprocessing* dikembangkan secara spesifik untuk teks klinis panjang dalam bahasa Indonesia.

Adaptasi Arsitektur

Arsitektur CDE-Mapper diadaptasi dengan penambahan modul dekomposisi teks panjang dalam bahasa Indonesia. Karena CDE-Mapper asli hanya menerima satu CDE per *input*, ditambahkan modul yang memecah dokumen klinis panjang menjadi unit-unit kalimat atau klausa yang mengandung CDE potensial. Pendekatan ini menggunakan aturan pemisah kalimat, dan deteksi frasa klinis berbasis pola.

Optimasi *LLM-based query decomposition* untuk *retrieval ensemble* dilakukan agar sesuai dengan karakteristik istilah klinis Bahasa Indonesia dan kebutuhan *multi-terminology mapping*. Selain itu, diintegrasikan pula mekanisme *confidence-based selection* yang diadaptasi dari pendekatan hibrida normalisasi konsep klinis oleh L. Chen dkk. (2020) untuk menangani ketidakpastian dan merekomendasikan kandidat yang perlu validasi manual.

Preprocessing

Preprocessing dirancang khusus untuk membersihkan dan menstandarkan teks klinis sebelum masuk ke pemrosesan lanjutan. Langkah-langkahnya meliputi *case folding* (semua teks diubah menjadi huruf kecil); normalisasi singkatan medis menggunakan kamus singkatan yang dibangun dari literatur dan buku rekam medis, misalnya DM” menjadidiabetes mellitus” dan TD” menjaditekanan darah”; *stemming* Bahasa Indonesia untuk mengurangi kata berimbuhan ke bentuk dasar secara selektif; penanganan variasi ejaan dan istilah sehari-hari; serta segmentasi kalimat untuk menjaga konteks lokal setiap entitas. Tahap ini hanya bertujuan menyiapkan teks bersih dan tidak melakukan pemetaan konsep.

4.2.3 Implementasi Inti Model

Implementasi inti model dibangun dalam sebuah *pipeline* berbasis Python yang mengintegrasikan enam komponen utama secara berurutan. Pertama, ekstraksi multi-entitas dari teks klinis menjadi objek JSON terstruktur, yang memuat entitas utama, domain, kategori, unit, metode, negasi, dan konteks temporal. Kedua, penerapan aturan pemetaan berbasis domain untuk menentukan terminologi target (SNOMED CT, LOINC, atau ICD-10), dilanjutkan dengan dekomposisi kueri menjadi komponen atomik guna menghindari ambiguitas pencarian. Ketiga, pemeriksaan *knowledge reservoir* untuk mengambil hasil tervalidasi jika tersedia dan menghindari komputasi ulang. Keempat, *retrieval ensemble* yang memanfaatkan SPLADE untuk pencarian leksikal dan SapBERT untuk pencarian semantik, guna

menghasilkan daftar kandidat konsep standar dari basis pengetahuan terminologi. Kelima, *filtering* dan *re-ranking* untuk menyaring kandidat yang tidak sesuai domain, atribut, atau status aktif, serta menilai ulang kesesuaiannya terhadap konteks kalimat secara keseluruhan. Keenam, validasi keputusan melalui agregasi penilaian, dengan keluaran akhir berupa kandidat final beserta skor kepercayaan, atau status *abstain* yang memerlukan validasi ahli jika tidak ada kandidat yang memenuhi ambang penerimaan.

4.2.4 Evaluasi dan Validasi

Tahap ini menguji performa model secara kuantitatif dan kualitatif.

Uji Coba Model

Model diuji pada dataset emas dengan skenario sebagai berikut.

1. Uji standar: menggunakan istilah yang sudah baku dalam dataset.
2. Uji variasi leksikal: menggunakan istilah dengan singkatan, ejaan salah, atau bahasa sehari-hari yang diambil dari platform konsultasi daring (Purwitasari dkk., 2023).
3. Uji teks panjang: menggunakan dokumen klinis naratif, misalnya catatan perkembangan pasien, yang mengandung beberapa CDE komposit. Model harus mengekstraksi seluruh CDE dan memetakannya.
4. Uji ablasi: model dijalankan tanpa komponen tertentu, yaitu tanpa modul *rule-based*, tanpa SapBERT, dan tanpa *cross-encoder*, untuk mengukur kontribusi masing-masing komponen.
5. Perbandingan *baseline*: perbandingan utama yang akan dilakukan adalah membandingkan *framework* usulan dengan CDE-Mapper original (Gilani dkk., 2025). Jika memungkinkan, simulasi dengan LLM kecil akan digunakan untuk proses dekomposisi dengan anggaran komputasi yang dibatasi.

Analisis Hasil

Hasil kuantitatif disajikan dalam tabel dan grafik perbandingan. Analisis statistik, misalnya uji-*t* berpasangan, dilakukan untuk menentukan signifikansi perbedaan antar model. Selain itu, dilakukan analisis kesalahan (*error analysis*) dengan mengelompokkan kesalahan pemetaan ke dalam kategori berikut.

1. Kesalahan karena variasi leksikal, misalnya singkatan yang tidak dikenal.
2. Kesalahan karena ambiguitas semantik, yaitu satu istilah dapat merujuk ke dua konsep berbeda.
3. Kesalahan karena kegagalan ekstraksi CDE dari teks panjang.
4. Kesalahan karena keterbatasan pengetahuan terminologi, yaitu ketika konsep tidak ada di basis data.

Setiap kesalahan dianalisis secara kualitatif untuk memberikan rekomendasi perbaikan.

4.2.5 Analisis dan Dokumentasi

Tahap akhir penelitian ini berfokus pada interpretasi, penarikan kesimpulan, dan penulisan laporan.

Interpretasi Hasil

Hasil evaluasi diinterpretasikan dalam kerangka pertanyaan penelitian: seberapa baik *framework* usulan memetakan terminologi klinis Bahasa Indonesia dibandingkan *baseline*; bagaimana kontribusi masing-masing komponen, seperti dekomposisi, *retrieval ensemble*, dan *preprocessing*, terhadap peningkatan akurasi; apakah model mampu menangani teks panjang dengan *multiple CDE* komposit secara simultan; dan seberapa efisien model digunakan untuk teks klinis dalam bahasa Indonesia.

Penarikan Kesimpulan

Kesimpulan dirumuskan berdasarkan tujuan penelitian yang ditetapkan di Bab I. *Framework* adaptif yang dikembangkan diharapkan mampu mengatasi keterbatasan CDE-Mapper asli dalam memproses teks klinis panjang dan mengenali *multiple CDE*. Pendekatan *hybrid rule-based* dan *semantic retrieval* diharapkan efektif untuk konteks *low-resource* bahasa Indonesia dengan akurasi yang kompetitif. Rekomendasi juga diberikan untuk implementasi di SATUSEHAT dan penelitian lanjutan, termasuk perlunya validasi klinis yang lebih luas dan pengembangan mekanisme *active learning* untuk memperbaiki model secara berkelanjutan.

Penulisan Laporan

Seluruh proses, desain, implementasi, data, hasil, dan kesimpulan didokumentasikan secara sistematis dalam naskah disertasi sesuai panduan penulisan Universitas Gadjah Mada. Laporan juga mencakup kode sumber pada repositori pendukung dan dataset anonim yang digunakan sehingga penelitian ini dapat direproduksi dan dikembangkan lebih lanjut oleh peneliti lain.

4.3 Deskripsi Usulan Model

Arsitektur model yang diusulkan untuk mengadaptasi CDE-Mapper agar mampu melakukan pemetaan terminologi klinis secara *end-to-end* dari teks klinis panjang berbahasa Indonesia, menjadi kode standar, yaitu SNOMED CT, LOINC, dan ICD-10. Model diusulkan sebagai *pipeline hybrid* yang menggabungkan ekstraksi entitas berbasis LLM, *retrieval* semantik dan leksikal (*dense + sparse*), serta mekanisme validasi dan penyimpanan pengetahuan (*knowledge reservoir*) untuk meningkatkan akurasi dan efisiensi inferensi (Gilani dkk., 2025).


4.3.1 Tujuan dan Keluaran Model

Secara operasional, model menerima masukan berupa: (1) teks klinis panjang berbahasa Indonesia, misalnya resume medis, catatan perkembangan, atau hasil penunjang; atau (2) daftar istilah atau *field* dari kamus data RME. Keluaran yang diharapkan adalah daftar *clinical data elements* (CDE) hasil ekstraksi beserta pasangan pemetaan ke terminologi target, yang mencakup *mention* asli, tipe entitas, normalisasi istilah, kandidat kode teratas (Top-*k*), skor kepercayaan, serta keputusan akhir, yaitu *exact*, *highly*, *partial*, atau *not relevant*. Untuk kasus komposit, keluaran juga menyertakan dekomposisi atribut, yaitu *Base entity*, *Domain*, *Additional Entities*, *categories*, *Unit*, *Visit*, dan *Method* (Gilani dkk., 2025).

4.3.2 Arsitektur, Alur Proses, dan Komponen Utama

Arsitektur usulan mengadopsi komponen utama CDE-Mapper (Gilani dkk., 2025), kemudian menambahkan lapisan NLP untuk mengubah teks klinis naratif berbahasa Indonesia menjadi sekumpulan CDE terstruktur. Adaptasi ini berfokus pada: (i) penanganan variasi bahasa klinis Indonesia, seperti singkatan, istilah lokal, ejaan tidak baku, negasi, dan konteks temporal; (ii) pemrosesan teks panjang yang dapat mengandung banyak entitas, bukan hanya satu CDE pada setiap masukan; dan (iii) pemetaan ke tiga terminologi dalam ruang lingkup penelitian, yaitu SNOMED CT, LOINC, dan ICD-10.

Secara operasional, arsitektur merupakan rangkaian delapan langkah: pra-pemrosesan dan normalisasi bahasa; ekstraksi multi-entitas dan pembentukan JSON; penerapan *mapping rules* serta transformasi format; dekomposisi kueri secara *batch*; pemeriksaan *knowledge reservoir*; *ensemble retrieval*; *filtering*, *reranking*, dan validasi; serta pembaruan *knowledge reservoir*. Rangkaian tersebut menghubungkan modul NLP yang menjadi kontribusi adaptasi dengan algoritma CDE-Mapper.



Gambar 4.2: Framework adaptasi pemetaan terminologi klinis Bahasa Indonesia

Bagian berarsir hijau pada Gambar 4.2 menunjukkan komponen yang ditambahkan atau disesuaikan untuk Bahasa Indonesia. Penjelasan setiap langkah adalah sebagai berikut.

1. Pra-pemrosesan dan normalisasi bahasa.

- **Fungsi:** membersihkan teks, melakukan segmentasi kalimat, memperbaiki ejaan tidak baku, menormalkan singkatan medis, melakukan *stemming*, serta menstandarkan simbol, angka, dan satuan tanpa menghilangkan informasi klinis penting.
- **Pembersihan teks:** karakter berulang, emotikon, spasi berlebih, dan pemisah baris yang tidak informatif dibersihkan. Implementasi awal dapat memanfaatkan dan menyesuaikan modul *text-normalization* untuk karakteristik data klinis (Utomo, n.d.).
- **Segmentasi kalimat:** dokumen panjang dibagi menjadi kalimat atau segmen koheren agar konteks lokal setiap entitas tetap terjaga. Model segmentasi berbasis transformer untuk Bahasa Indonesia dapat digunakan sebagai acuan atau pembanding (Hananto dkk., 2026).
- **Koreksi bentuk tidak baku:** variasi informal, salah eja, dan pengulangan huruf dinormalkan menggunakan kamus dan aturan yang dapat diadaptasi dari *indo-normalizer* (Dyasputro, n.d.).
- **Normalisasi singkatan medis:** singkatan seperti “Px”, “dgn”, “DM”, “GDP”, dan “TD” diperluas menggunakan kamus singkatan medis lokal. Kamus awal mengacu pada daftar singkatan rekam medis dan selanjutnya divalidasi oleh ahli (Rumah Sakit Islam Sultan Agung, 2019).
- **Stemming selektif:** kata berimbuhan dapat dikembalikan ke bentuk dasar menggunakan Sastrawi (Librian, n.d.). Stemming tidak diterapkan pada kode, nama obat, nilai numerik, dan istilah yang berisiko berubah makna klinis.
- **Contoh input:** “Px dgn DM tipe 2, GDP 126 mg/dL, TD 150/90”.
- **Contoh keluaran:** “pasien dengan diabetes mellitus tipe 2, gula darah puasa 126 mg/dL, tekanan darah 150/90”.
- **Keluaran tahap:** teks klinis bersih yang siap diproses oleh modul ekstraksi entitas.

2. Ekstraksi multi-entitas dan pembentukan JSON.

- **Fungsi:** mendeteksi banyak entitas klinis dari setiap segmen menggunakan LLM atau model NER medis. Model medis yang menyediakan keluaran NER terstruktur, seperti Numind Medical NER LLM, dapat digunakan sebagai salah satu kandidat dan dibandingkan dengan LLM melalui pendekatan *few-shot* (John Snow Labs, 2026).
- **Informasi yang dideteksi:** entitas utama, domain, kategori atau nilai kategorikal, unit, metode atau formula, kunjungan, atribut tambahan, status negasi, dan konteks temporal. Instruksi atau aturan khusus digunakan agar frasa seperti “tidak ada”, “bukan”, dan “tanpa” ditandai sebagai negasi, sedangkan “sebelumnya”, “dulu”, “kini”, dan “saat ini” diberi penanda waktu.
- **Output terstruktur:** setiap entitas disimpan sebagai objek JSON. *Label* memuat nama CDE atau frasa klinis utama; *categorical* memuat daftar atau pasangan kategori nilai; *unit* memuat satuan pengukuran; *formula* memuat aturan perhitungan atau hubungan antarelelemen apabila CDE merupakan hasil turunan; dan *visit* memuat konteks kunjungan atau waktu pengukuran. Metadata tambahan seperti *domain*, *method*, *assertion*, dan *temporal* dipertahankan untuk membantu pemetaan.
- **Contoh hasil:** “diabetes mellitus tipe 2” sebagai diagnosis; “gula darah puasa 126 mg/dL” sebagai pemeriksaan laboratorium; dan “tekanan darah 150/90” sebagai tanda vital.
- **Keluaran tahap:** daftar *mention* terstruktur sehingga satu dokumen panjang dapat menghasilkan beberapa CDE sekaligus (Purwitasari dkk., 2023).

3. Penerapan *mapping rules* dan transformasi format.

- **Fungsi:** memeriksa domain entitas, menentukan terminologi target, membatasi pencarian pada konsep aktif, dan mengubah setiap objek JSON ke format masukan dekomposisi kueri.
- **Aturan terminologi:** domain *condition*, temuan klinis, prosedur, dan kunjungan diprioritaskan ke SNOMED CT; domain *measurement* diprioritaskan ke LOINC dengan SNOMED CT sebagai alternatif jika sesuai; dan diagnosis untuk kebutuhan klasifikasi atau pelaporan diarahkan ke ICD-10. Entitas obat berada di luar terminologi obat khusus pada ruang lingkup penelitian ini; pemetaan hanya dilakukan apabila tersedia

konsep aktif yang sesuai dalam SNOMED CT, sedangkan kasus lainnya ditandai untuk perluasan penelitian.

- **Validitas kandidat:** hanya konsep yang berstatus aktif dalam versi terminologi yang digunakan yang dimasukkan ke ruang pencarian, mengikuti prinsip penyaringan pada CDE-Mapper (Gilani dkk., 2025).
- **Contoh:** “diabetes mellitus tipe 2” diarahkan ke SNOMED CT dan ICD-10, sedangkan “gula darah puasa” diarahkan ke LOINC.
- **Keluaran tahap:** beberapa set JSON, masing-masing mewakili satu entitas beserta metadata dan terminologi targetnya. Format tersebut mengikuti kebutuhan *linking rules* yang dapat dikonfigurasi untuk konteks SATUSEHAT (Ayuningtyas dkk., 2025).

4. Dekomposisi kueri secara *batch*.

- **Fungsi:** memecah setiap entitas kompleks menjadi komponen logis dan unit pencarian atomik agar kueri tidak ambigu atau terlalu spesifik (Gilani dkk., 2025).
- **Contoh entitas:** “gula darah puasa 126 mg/dL”.
- **Contoh dekomposisi:** *base entity* = glukosa; *domain* = pengukuran laboratorium; *context* = puasa; dan *unit* = mg/dL.
- **Adaptasi:** CDE-Mapper memproses satu baris kamus data pada setiap proses, sedangkan arsitektur usulan menjalankan dekomposisi untuk N entitas yang diekstraksi dari satu dokumen. Karena itu, keluaran tahap ini berupa struktur JSON terdekomposisi dan daftar subkueri untuk seluruh entitas.
- **Keluaran tahap:** sekumpulan subkueri terstruktur yang mengarahkan pencarian pada konsep dan atribut yang tepat, bukan sekadar kecocokan satu kata.

5. Pemeriksaan *knowledge reservoir*.

- **Fungsi:** memeriksa apakah kueri dan konteksnya telah memiliki pemetaan yang divalidasi ahli. Mekanisme ini diadopsi untuk mengurangi biaya komputasi dan latensi (Gilani dkk., 2025).
- **Cache hit:** hasil tervalidasi diambil langsung tanpa menjalankan *retrieval* dan *reranking* ulang, setelah kesesuaian konteks, domain, dan versi terminologi diperiksa.

- **Cache miss:** kueri diteruskan ke *ensemble retrieval*, *filtering*, *reranking*, dan validasi.
- **Keluaran tahap:** hasil pemetaan tervalidasi atau subkueri yang perlu diproses oleh tahap pencarian.

6. *Ensemble retrieval kandidat konsep.*

- **Fungsi:** mengambil kandidat dari basis pengetahuan terminologi melalui jalur leksikal dan semantik yang saling melengkapi.
- **Sparse retrieval:** SPLADE membentuk representasi jarang pada ruang kosakata dan memberi bobot pada token penting serta ekspansi leksikal. Jalur ini efektif untuk istilah teknis, singkatan, dan kecocokan kata yang spesifik (Formal dkk., 2021). Skor kandidat mengikuti formulasi *sparse retrieval* pada Persamaan 3.3.
- **Dense retrieval:** SapBERT membentuk representasi padat untuk menangkap sinonim dan kemiripan makna, misalnya hubungan antara “gula darah puasa” dan *fasting blood glucose* (Liu dkk., 2021). Kemiripan dihitung menggunakan Persamaan 3.2.
- **Penggabungan hasil:** kedua daftar kandidat digabungkan agar kandidat yang kuat secara leksikal maupun semantik memperoleh prioritas. Implementasi fusi dan bobotnya ditentukan pada data pengembangan sebagaimana Persamaan 3.4; metode tersebut merupakan pilihan implementasi penelitian dan tidak dinyatakan sebagai metode fusi asli Gilani.
- **Keluaran tahap:** daftar Top-*k* kandidat aktif dari terminologi target yang telah diperkaya sinonim (Gilani dkk., 2025).

7. *Filtering, reranking, dan validasi keputusan.*

- **Filtering:** kandidat yang tidak sesuai domain, tipe semantik, status aktif, atribut, atau ambang kemiripan dieliminasi. Sebagai contoh, kandidat glukosa urin atau glukosa sewaktu dibuang ketika spesimen atau konteks puasa tidak sesuai. Ambang seperti *cosine similarity* dapat membantu mengendalikan kandidat yang masuk ke tahap berikutnya (L. Chen dkk., 2020).
- **Reranking:** kandidat tersisa dinilai ulang menggunakan LLM atau model *reranker* dengan mempertimbangkan label, definisi, sinonim, domain, atribut, granularitas, negasi, konteks temporal, dan konteks kalimat.
- **Kategori keputusan:** *exact*, *highly*, *partial*, atau *not relevant*.


- **Contoh:** “diabetes mellitus tipe 2” diberi label *exact* untuk SNOMED CT 44054006 dan ICD-10 E11.9, sedangkan “diabetes mellitus” tanpa tipe diberi label *partial*.
- **Validasi keputusan:** penilaian dapat diulang dan diagregasi melalui *self-consistency* untuk meningkatkan kestabilan (Gilani dkk., 2025; X. Wang dkk., 2023). Kandidat yang tidak memenuhi ambang penerimaan menghasilkan keputusan *abstain* dan diteruskan kepada ahli.
- **Keluaran tahap:** kandidat final Top-1 dan Top-*k*, label relevansi, skor kepercayaan, serta status diterima atau memerlukan validasi ahli.

8. Pembaruan *knowledge reservoir* dan keluaran.


- **Fungsi:** menyimpan pasangan *mention*, konteks, metadata, terminologi target, dan kode standar yang telah divalidasi ahli.
- **Contoh simpanan:** “DM tipe 2”–SNOMED CT 44054006 dan “DM tipe 2”–ICD-10 E11.9.
- **Manfaat:** mempercepat pemetaan istilah berulang dan meningkatkan konsistensi lintas dokumen.
- **Peran *human-in-the-loop*:** hasil dengan keyakinan rendah, konflik terminologi, atau keputusan *abstain* divalidasi oleh dokter atau perekam medis sebelum disimpan. Dengan demikian, reservoir tidak otomatis menerima keluaran model yang belum diverifikasi.
- **Keluaran tahap:** daftar pemetaan terminologi untuk dokumen masukan dan referensi tervalidasi bagi inferensi berikutnya. Pemeriksaan konteks dan versi terminologi tetap dilakukan untuk mencegah penggunaan ulang pemetaan yang tidak sesuai (Gilani dkk., 2025).

Contoh alur *end-to-end*: masukan “*Px dgn DM tipe 2, GDP 126 mg/dL, TD 150/90*” akan dinormalisasi menjadi istilah baku, dipecah menjadi tiga entitas klinis, diarahkan ke terminologi target yang berbeda, kemudian menghasilkan kandidat seperti SNOMED CT 44054006 atau ICD-10 E11.9 untuk diagnosis diabetes mellitus tipe 2 serta kandidat LOINC untuk observasi glukosa puasa. Dengan demikian, satu dokumen klinis panjang dapat menghasilkan beberapa pemetaan standar secara simultan.

Arsitektur dan alur *pipeline* yang diusulkan secara visual dapat dilihat pada Gambar 4.3.



Ide penyesuaian:



Gambar 4.3: Gambaran arsitektur dan alur *pipeline* yang diusulkan

Pseudo code pada Algoritma 4.1 merangkum alur operasional model dari masukan teks klinis sampai terbentuknya keluaran pemetaan dan pembaruan *knowledge reservoir*.

Algoritma 4.1. Pemetaan Terminologi Klinis Bahasa Indonesia

Masukan: teks klinis panjang atau daftar istilah RME; basis pengetahuan SNOMED CT, LOINC, ICD-10; *knowledge reservoir*; aturan pemetaan; dan parameter model.

Keluaran: hasil pemetaan dan antrian validasi ahli.

```

1. teks_bersih ← pra-pemrosesan dan normalisasi bahasa(teks_masukan)
2. daftar_entitas ← ekstraksi multi-entitas dan metadata ke JSON(teks_bersih)
3. masukan_QD ← penerapan mapping rules dan transformasi format(daftar_entitas)
4. daftar_tugas ← dekomposisi kueri dan penentuan target(masukan_QD)
5. hasil_pemetaan ← ∅; antrean_validasi ← ∅
6. for setiap tugas in daftar_tugas do
7.   rekaman ← cari pemetaan pada knowledge reservoir(tugas)
8.   if rekaman tervalidasi ahli, sesuai konteks, dan kode masih valid then
9.     hasil ← pemetaan dari rekaman
10.  else
11.    kandidat_sparse ← retrieval SPLADE(tugas)
12.    kandidat_dense ← retrieval SapBERT(tugas)
13.    kandidat ← gabungkan skor dan pilih Top-k kandidat (Persamaan 3.4)
14.    kandidat_valid ← filtering domain, atribut, konsep aktif, dan ambang skor hybrid(kandidat)
15.    hasil ← abstain tanpa kode final
16.    if kandidat_valid tidak kosong then
17.      penilaian ← reranking LLM sebanyak T kali(kandidat_valid, tugas)
18.      label, konsistensi ← agregasi hasil penilaian
19.      skor_akhir ← normalisasi dan pembobotan enam komponen (Persamaan 4.7)
20.      terbaik ← pilih kandidat dengan skor akhir tertinggi
21.      if label terbaik memenuhi syarat relevansi, tidak ada konflik, serta skor dan konsistensi memenuhi ambang (Persamaan 4.9) then
22.        hasil ← kode terbaik dengan status diterima otomatis
23.      end if
24.      lengkapi hasil dengan kandidat, label, dan skor penilaian
25.    end if
26.    tambahkan hasil ke antrean_validasi, prioritaskan kasus abstain
27.  end if
28.  tambahkan hasil beserta entitas asal, target, dan konteks ke hasil_pemetaan
29. end for
30. return hasil_pemetaan, antrean_validasi

```

Bersambung ke halaman berikutnya.

Algoritma 4.1. Pemetaan Terminologi Klinis Bahasa Indonesia (lanjutan)

Tindak lanjut ketika hasil validasi ahli tersedia:

```

31. for setiap hasil yang telah diperiksa ahli do
32.   perbarui hasil_pemetaan sesuai persetujuan, koreksi, atau keputusan tidak ada padanan
33.   if pemetaan ke kode valid disahkan ahli then
34.     perbarui knowledge reservoir dengan kueri, konteks, target, versi terminologi, kode, dan metadata validasi
35.   end if
36. end for

```

Catatan: syarat relevansi pada baris 21 adalah label *exact match* atau *highly relevant*, tanpa seri label. Hasil otomatis dapat dikeluarkan langsung, tetapi hanya hasil yang disahkan ahli yang disimpan ke reservoir.

4.3.3 Formalisasi Matematis Model Usulan

Berbeda dari formula umum RAG dan *retrieval* pada Bab III, formula pada bagian ini merupakan operasionalisasi model yang diusulkan dalam penelitian. Formula ini bukan formula asli CDE-Mapper Gilani, melainkan adaptasi yang dirancang agar pemilihan kandidat untuk terminologi klinis Bahasa Indonesia lebih transparan, dapat direplikasi, dan dapat diuji kontribusi tiap komponennya.

Setelah kandidat Top- k diperoleh menggunakan Persamaan 3.4, kandidat disaring berdasarkan ambang skor dan kesesuaian terminologi target:

$$C'(q) = \{c \in C_k(q) \mid s_{\text{hybrid}}(q, c) \geq \tau_{\text{filter}} \wedge d(c) \in D(q)\}, \quad (4.1)$$

dengan $D(q)$ sebagai himpunan terminologi atau domain yang diizinkan oleh hasil klasifikasi dan *linking rules*, $d(c)$ sebagai domain kandidat, dan τ_{filter} sebagai ambang yang ditentukan pada data pengembangan. Penggunaan himpunan $D(q)$ memungkinkan lebih dari satu terminologi tetap dipertimbangkan ketika klasifikasi domain belum pasti. Skor atribut dihitung dari proporsi atribut hasil dekomposisi yang dipertahankan kandidat:

$$S_{\text{atribut}}(q, c) = \frac{|A(q) \cap A(c)|}{\max\{1, |A(q)|\}}, \quad (4.2)$$

dengan $A(q)$ sebagai atribut klinis pada kueri, misalnya lokasi anatomis, specimen, metode, waktu, satuan, posisi tubuh, atau tingkat keparahan, dan $A(c)$ sebagai atribut yang tercakup oleh kandidat.

Kesesuaian domain kandidat dihitung menggunakan probabilitas yang dihasilkan pengklasifikasi atau modul *routing*:

$$S_{\text{domain}}(q, c) = p(d(c) \mid q), \quad (4.3)$$

sehingga kandidat dari domain yang masih diizinkan dapat memiliki tingkat kecocokan yang berbeda. Kesesuaian granularitas dihitung dari jarak antara tingkat kekhususan yang diharapkan untuk kueri dan tingkat kekhususan kandidat:

$$S_{\text{granularitas}}(q, c) = \exp\left(-\frac{|g(q) - g(c)|}{\rho}\right), \quad (4.4)$$

dengan $g(q), g(c) \in [0, 1]$ sebagai tingkat kekhususan yang dinormalisasi menurut hierarki atau atribut terminologi target dan $\rho > 0$ sebagai parameter toleransi. Definisi operasional g disusun bersama ahli dan ditetapkan sebelum pengujian.

Kestabilan *reranking* LLM diukur menggunakan proporsi keputusan mayoritas dari T pengulangan:

$$S_{\text{konsistensi}}(q, c) = \max_{\ell \in \mathcal{L}} \frac{1}{T} \sum_{t=1}^T \mathbf{1}(L^{(t)}(q, c) = \ell), \quad (4.5)$$

dengan $\mathcal{L}$ sebagai himpunan label relevansi. Pengambilan keputusan mayoritas ini mengadaptasi prinsip *self-consistency*, yaitu mengagregasi beberapa jalur keluaran untuk memperoleh keputusan yang lebih stabil (X. Wang dkk., 2023). Karena skor berasal dari komponen yang berbeda, setiap komponen S_j dinormalisasi pada himpunan kandidat suatu kueri:

$$\tilde{S}_j(q, c) = \frac{S_j(q, c) - \min_{c' \in C'(q)} S_j(q, c')}{\max_{c' \in C'(q)} S_j(q, c') - \min_{c' \in C'(q)} S_j(q, c') + \varepsilon}, \quad (4.6)$$

dengan ε sebagai konstanta kecil untuk mencegah pembagian dengan nol. Skor akhir kandidat kemudian menggabungkan enam bukti yang telah dinormalisasi:

$$S_{\text{akhir}}(q, c) = w_l \tilde{S}_{\text{leksikal}}(q, c) + w_s \tilde{S}_{\text{semantik}}(q, c) + w_d \tilde{S}_{\text{domain}}(q, c) \\ + w_a \tilde{S}_{\text{atribut}}(q, c) + w_g \tilde{S}_{\text{granularitas}}(q, c) + w_k \tilde{S}_{\text{konsistensi}}(q, c), \quad (4.7)$$

dengan kendala:

$$w_l + w_s + w_d + w_a + w_g + w_k = 1, \quad w_i \geq 0. \quad (4.8)$$

S_{leksikal} berasal dari SPLADE (Formal dkk., 2021); S_{semantik} berasal dari SapBERT (Liu dkk., 2021); S_{domain} menunjukkan keyakinan modul *routing* terhadap terminologi kandidat; S_{atribut} menunjukkan kelengkapan atribut; $S_{\text{granularitas}}$ menunjukkan kesesuaian tingkat kekhususan konsep; dan $S_{\text{konsistensi}}$ menunjukkan kestabilan keputusan LLM. Bobot awal ditetapkan sama, kemudian dipilih melalui *grid search* pada data pengembangan dengan Accuracy@1 sebagai sasaran utama dan *coverage* sebagai kendala tambahan. Data uji tidak digunakan untuk menentukan bobot atau ambang.

Kandidat terbaik adalah $c^* = \arg \max_{c \in C'(q)} S_{\text{akhir}}(q, c)$. Untuk mencegah pe-

metaan yang dipaksakan, keputusan akhir menggunakan mekanisme *abstain*:

$$\hat{c}(q) = \begin{cases} c^*, & S_{\text{akhir}}(q, c^*) \geq \tau_{\text{accept}} \wedge S_{\text{konsistensi}}(q, c^*) \geq \delta, \\ \emptyset, & \text{selainnya,} \end{cases} \quad (4.9)$$

dengan $\emptyset$ berarti kasus dikirim untuk validasi ahli. Nilai τ_{accept} dan δ ditentukan pada data pengembangan dengan mempertimbangkan pertukaran antara akurasi dan *coverage*.

4.3.4 Asumsi, Batasan, dan Strategi Mitigasi

Model mengasumsikan akses terhadap terminologi standar yang relevan dan/atau ekspor terminologi dari SATUSEHAT, serta ketersediaan sampel data klinis yang dapat dianonimkan untuk pengembangan dan evaluasi. Batasan utama meliputi: (1) variasi bahasa yang sangat ekstrem pada catatan klinis, (2) konsep lokal yang tidak memiliki padanan langsung pada terminologi target, (3) potensi halusinasi pada LLM saat ekstraksi atau *reranking*, serta (4) kebutuhan validasi ahli. Untuk mitigasi, penelitian mengusulkan penggunaan *constraint* terminologi pada tahap *filtering*, penerapan *threshold* dan *self-consistency* pada *reranking*, serta penerapan *human-in-the-loop* dan *knowledge reservoir* untuk meningkatkan kualitas secara iteratif.

4.4 Rancangan Pengujian

Bagian ini menjelaskan rancangan pengujian untuk mengevaluasi performa model usulan pada tugas pemetaan terminologi klinis Bahasa Indonesia ke SNOMED CT, LOINC, dan ICD-10. Rancangan dibuat untuk mengukur akurasi pemetaan, ketahanan terhadap variasi bahasa, kontribusi setiap komponen (*ablation*), serta kesiapan penerapan pada konteks interoperabilitas SATUSEHAT.

4.4.1 Desain Eksperimen dan Skenario Pengujian

1. **Terminology mapping dari istilah pendek (*single-mention*).** *Input* berupa daftar istilah atau *field* dari kamus data RME atau label klinis singkat. Tujuannya adalah mengukur kemampuan normalisasi istilah lokal dan varian ejaan.
2. **End-to-end mapping dari teks panjang (*multi-mention*).** *Input* berupa dokumen klinis panjang berbahasa Indonesia. Tujuannya adalah mengukur *pipeline* lengkap, yaitu ekstraksi dan *mapping*, serta dampak *error propagation*.

3. **Multi-terminology routing.** Pengujian ini menilai kemampuan sistem memilih terminologi target yang tepat, yaitu SNOMED CT, LOINC, atau ICD-10, berdasarkan tipe entitas dan konteks (Ayuningtyas dkk., 2025).
4. **Robustness terhadap variasi bahasa.** Pengujian dilakukan pada subset data yang mengandung singkatan, campuran bahasa Indonesia–Inggris, istilah lokal, dan *typo* (Purwitasari dkk., 2023).

4.4.2 Dataset, Pembagian Data, dan Gold Standard

Dataset evaluasi dibangun dari sampel istilah dan/atau dokumen yang merepresentasikan data klinis Indonesia, kemudian dianotasi menjadi *gold standard* oleh ahli. Untuk memastikan evaluasi yang adil, data dipisahkan menjadi: (i) data pengembangan untuk *tuning threshold*, bobot skor, *prompt*, aturan, dan konfigurasi *retriever*; serta (ii) data uji (*hold-out*) yang tidak digunakan selama pengembangan.

Data untuk Pengembangan Model

Untuk keperluan pengembangan model, penelitian ini menggunakan data istilah klinis dalam bahasa Indonesia yang dikumpulkan dari empat sumber utama.

1. Data terminologi medis standar, yaitu SNOMED CT, LOINC, dan ICD-10, yang diakses dari SATUSEHAT dan sumber terminologi observasional terbuka yang relevan.
2. Kamus data elektronik rekam medis (RME) lokal yang diperoleh dari sampel rumah sakit atau puskesmas di Indonesia yang telah menerapkan RME. Data ini mencakup istilah diagnosis, prosedur, observasi, dan obat-obatan dalam format asli sesuai entri tenaga kesehatan.
3. Dataset dari penelitian Gilani, seperti NCBI Corpus dan BC5CDR, untuk mendukung pengembangan awal dan pengujian komponen tertentu (Gilani dkk., 2025).
4. Platform konsultasi kesehatan daring. Data anonim dari sesi tanya jawab tentang kesehatan dikumpulkan untuk mendapatkan representasi bahasa sehari-hari pasien, termasuk variasi istilah, singkatan informal, dan kesalahan ejaan. Data ini penting untuk menguji ketahanan model terhadap variasi leksikal di dunia nyata (Purwitasari dkk., 2023).

Data untuk Evaluasi

Untuk keperluan evaluasi yang valid, sebuah dataset *gold standard* dikembangkan dengan melibatkan tenaga medis, seperti dokter atau perekam medis. Prosesnya meliputi:

1. **Seleksi sampel.** Memilih sampel istilah dari data sumber, misalnya 100–200 istilah, yang mewakili variasi tantangan, seperti istilah standar, singkatan, dan kesalahan eja.
2. **Anotasi manual.** Minimal dua anotator, misalnya dokter dan/atau perekam medis, melakukan pemetaan secara terpisah. Selain kode benar, anotasi mencakup domain entitas, terminologi target, atribut klinis yang harus dipertahankan, tingkat kekhususan yang diharapkan, dan keputusan apakah kasus dapat dipetakan otomatis atau memerlukan tinjauan ahli.
3. **Validasi antar-anotator.** Tingkat kesepakatan antar-anotator dihitung untuk memastikan kualitas dan konsistensi dataset *gold standard*. Perbedaan diselesaikan melalui adjudikasi oleh ahli ketiga sebelum data digunakan untuk evaluasi.

4.4.3 Baseline, Model Pembanding, dan Varian (Ablation Study)

Evaluasi dibagi menjadi perbandingan dengan *baseline* dan pengujian varian *ablation*. Perbandingan modul pemetaan menggunakan masukan entitas atau CDE yang sama agar perbedaan kemampuan ekstraksi tidak tercampur dengan kualitas pemetaan. Evaluasi *end-to-end* pada teks panjang dilaporkan secara terpisah.

Baseline Pembanding

1. **Pencocokan leksikal.** Pemetaan pada label dan sinonim terminologi menggunakan dua konfigurasi, yaitu *exact matching* setelah normalisasi sederhana dan *fuzzy matching* berdasarkan kemiripan string. Keduanya menjadi pembandingan untuk menilai kemampuan metode sederhana dalam menangani istilah baku dan variasi ejaan.
2. **LLM zero-shot tanpa RAG.** LLM diminta menentukan kode terminologi tanpa contoh pemetaan dan tanpa akses *retrieval*. Untuk mengukur kontribusi penambahan konteks hasil *retrieval*, digunakan pasangan konfigurasi dengan dan tanpa RAG yang memakai model serta versi LLM yang sama, dengan masukan, instruksi tugas, dan format keluaran yang sebanding. Evaluasi

mencakup akurasi dan proporsi kode keluaran yang tidak tersedia dalam versi terminologi yang digunakan.

3. **CDE-Mapper asli.** Arsitektur CDE-Mapper (Gilani dkk., 2025) tanpa adaptasi khusus bahasa Indonesia digunakan sebagai pembanding utama sesuai ketersediaan implementasi dan sumber daya. Pengujian *cross-lingual* dilakukan dengan memberikan CDE berbahasa Indonesia secara langsung. Jika memungkinkan, ditambahkan konfigurasi penerjemahan CDE ke bahasa Inggris sebelum pemetaan. Seluruh konfigurasi diuji pada kasus dan padanan kode yang sama; perubahan konfigurasi yang diperlukan serta keterbatasan replikasi dilaporkan secara eksplisit.

Ablation Study

Setiap varian dibandingkan dengan model lengkap dengan menonaktifkan satu komponen yang ditentukan, sementara komponen lain dipertahankan. Lima varian yang diuji adalah sebagai berikut.

1. **Tanpa *preprocessing* khusus bahasa Indonesia.** Normalisasi singkatan medis dan *stemming* dinonaktifkan, sedangkan pembersihan teknis dan segmentasi kalimat tetap digunakan. Varian ini menilai kontribusi kedua proses tersebut, khususnya pada subset istilah lokal dan singkatan.
2. **Tanpa *knowledge filtering*.** Kandidat Top-*k* diteruskan ke tahap *reranking* tanpa penyaringan pasca-*retrieval* berdasarkan domain, atribut, dan ambang skor. Basis terminologi, pembatasan konsep aktif pada indeks, dan aturan *routing* tetap sama. Varian ini mengukur kontribusi penyaringan kandidat terhadap akurasi dan cakupan pemetaan.
3. **Tanpa *reranking* berbasis LLM.** Penilaian ulang kandidat oleh LLM beserta agregasi label dan skor konsistensinya dinonaktifkan. Kandidat akhir dipilih berdasarkan skor *hybrid retrieval* setelah *filtering*, dengan ambang penerimaan yang ditetapkan pada data pengembangan. Penggunaan LLM pada komponen lain tetap dipertahankan sehingga varian ini secara khusus menilai kontribusi tahap *reranking*, bukan seluruh penggunaan LLM.
4. **Tanpa pemanfaatan *cache knowledge reservoir*.** Pengambilan langsung hasil pemetaan terdahulu dinonaktifkan sehingga setiap kueri menjalani proses pencarian dan penilaian kandidat. Contoh pemetaan untuk komponen lain dipertahankan tetap sama. Efisiensi dibandingkan pada kondisi *cold cache*

dan *warm cache* melalui waktu inferensi, jumlah panggilan LLM, penggunaan token, dan tingkat *cache hit*, disertai pemeriksaan akurasi. Reservoir tidak diisi dengan jawaban *gold standard* data uji; sumber pemetaan tervalidasi dan urutan kueri untuk pengujian cache ditetapkan sebelumnya.

5. **Tanpa *routing* terminologi sebelum pencarian.** Pencarian dilakukan pada gabungan SNOMED CT, LOINC, dan ICD-10 tanpa pembatasan awal berdasarkan domain entitas. Konfigurasi ini dibandingkan dengan pencarian terarah pada terminologi hasil *routing*, sementara basis terminologi, jumlah kandidat Top- k , dan penyaringan pasca-*retrieval* tetap sama. Evaluasi menilai presisi, Recall@ k , dan ketepatan terminologi keluaran untuk mengetahui dampak pembatasan ruang pencarian.

Seluruh perbandingan menggunakan pembagian data uji yang sama dan versi terminologi yang terdokumentasi. Konfigurasi kamus, sinonim, model, serta parameter dicatat untuk menjaga keterbandingan. Penyesuaian ambang atau aturan keputusan yang diperlukan ketika suatu komponen dinonaktifkan hanya menggunakan data pengembangan. Pada pengujian ablation selain cache, penggunaan ulang hasil pemetaan dinonaktifkan secara seragam pada model lengkap dan variannya agar komponen yang diuji benar-benar dijalankan.

4.4.4 Metrik Evaluasi

Metrik evaluasi pada penelitian ini dirancang untuk mengukur performa *framework* secara komprehensif pada dua tingkat, yaitu tingkat pemetaan kandidat kode dan tingkat performa *end-to-end* dari ekstraksi hingga normalisasi konsep. Pemilihan metrik ini mengikuti praktik evaluasi pada tugas *clinical concept normalization*, *ontology alignment*, dan *retrieval-augmented terminology mapping*, yang menekankan ketepatan kandidat teratas, ketercakupan kandidat benar dalam Top- k , keseimbangan antara ketepatan dan kelengkapan ekstraksi, serta efisiensi inferensi (L. Chen dkk., 2020; Gilani dkk., 2025; He dkk., 2022; Park dkk., 2026; Yu dkk., 2026). Definisi konseptual dan persamaan matematis untuk metrik-metrik tersebut telah dibahas pada Bab III, sehingga pada bagian ini rumus tidak dituliskan ulang, tetapi direferensikan sesuai label persamaan yang tersedia.

1. **Accuracy@1.** Untuk mengevaluasi ketepatan kandidat teratas, penelitian ini menggunakan metrik akurasi sebagaimana didefinisikan pada Persamaan 3.6. Pada implementasinya, akurasi digunakan untuk menilai proporsi pemetaan yang benar pada kandidat utama yang dipilih sistem (L. Chen dkk., 2020; Gilani dkk., 2025).

2. **Accuracy@k.** Untuk menilai apakah kode *gold standard* muncul di dalam himpunan Top-*k* kandidat, penelitian ini menggunakan metrik *Top-k accuracy* sebagaimana dinyatakan pada Persamaan 3.15. Metrik ini relevan karena pada skenario *retrieval* kandidat benar tidak selalu berada pada peringkat pertama, tetapi tetap perlu muncul dalam daftar kandidat teratas untuk ditinjau lebih lanjut (Gilani dkk., 2025; He dkk., 2022; Park dkk., 2026).
3. **MRR dan Recall@k.** MRR pada Persamaan 3.17 digunakan untuk menilai seberapa awal kandidat benar muncul, sedangkan Recall@*k* pada Persamaan 3.16 digunakan ketika satu kueri memiliki lebih dari satu konsep relevan.
4. **Precision, Recall, dan F1-score.** Untuk skenario *end-to-end* pada teks panjang, ketika sistem harus mengekstraksi entitas klinis sekaligus memetakannya ke terminologi target, penelitian ini menggunakan *precision*, *recall*, dan F1-score yang masing-masing dirumuskan pada Persamaan 3.7, Persamaan 3.8, dan Persamaan 3.9. Ketiga metrik ini digunakan untuk menilai keseimbangan antara ketepatan prediksi, kelengkapan temuan entitas, dan performa keseluruhan sistem (L. Chen dkk., 2020).
5. **Coverage.** Untuk mengetahui sejauh mana sistem mampu memberikan setidaknya satu kandidat kode valid setelah tahap *retrieval* dan *filtering*, penelitian ini menggunakan metrik *coverage* sebagaimana didefinisikan pada Persamaan 3.10. Metrik ini penting karena sistem yang tampak akurat pada kasus tertentu belum tentu memiliki keluasan cakupan yang baik terhadap seluruh data masukan (Gilani dkk., 2025; Park dkk., 2026).
6. **Agreement atau consistency.** Untuk menilai kestabilan keputusan sistem, penelitian ini menggunakan dua ukuran yang saling melengkapi, yaitu konsistensi hasil *reranking* sebagaimana dirumuskan pada Persamaan 3.11 dan koefisien Kappa untuk kesepakatan antar-anotator sebagaimana dinyatakan pada Persamaan 3.12. Penggunaan dua ukuran ini penting karena penelitian memerlukan *gold standard* yang andal sekaligus sistem yang stabil ketika dihadapkan pada istilah atau dokumen yang serupa (Gilani dkk., 2025; Januel dkk., 2011).
7. **Efisiensi.** Selain akurasi, penelitian ini juga mengukur efisiensi komputasi melalui rata-rata waktu inferensi sebagaimana dirumuskan pada Persamaan 3.13. Untuk membandingkan peningkatan efisiensi terhadap metode pembandingan, digunakan pula persentase percepatan sebagaimana dinyatakan pada Persamaan 3.14. Kedua ukuran ini diperlukan agar model yang diusulkan

tidak hanya akurat, tetapi juga layak diterapkan pada skenario penggunaan praktis (Gilani dkk., 2025; Park dkk., 2026).

8. **Pertukaran akurasi–coverage.** Mekanisme *abstain* dievaluasi pada beberapa nilai τ_{accept} dan δ . Analisis ini menunjukkan perubahan akurasi pada kasus yang diterima ketika proporsi kasus yang dipetakan otomatis dinaikkan atau diturunkan.

Melalui kombinasi metrik tersebut, evaluasi pada penelitian ini tidak hanya menilai apakah sistem menghasilkan kode yang benar, tetapi juga menilai kemampuan sistem menyediakan kandidat yang relevan, mengekstraksi entitas secara lengkap, mempertahankan konsistensi hasil, dan bekerja secara efisien pada skenario penggunaan nyata.

4.4.5 Prosedur Pengujian dan Analisis Hasil

1. **Konfigurasi.** Menetapkan variasi model, yaitu *baseline* versus usulan, parameter *retrieval* (Top- k), bobot skor, *threshold filtering*, ambang penerimaan, jumlah pengulangan LLM, dan *prompt* atau format *output* untuk LLM. Seluruh parameter dipilih hanya dari data pengembangan.
2. **Eksekusi pada data uji.** Menjalankan seluruh model pada dataset uji dan menyimpan *output* terstruktur, yaitu kandidat, skor, keputusan, dan log komponen.
3. **Perhitungan metrik.** Menghitung Accuracy@1, Accuracy@ k , Recall@ k , MRR, Precision, Recall, F1, *coverage*, konsistensi, dan efisiensi komputasi.
4. **Ablation dan uji sensitivitas.** Menjalankan varian *ablation* untuk mengukur kontribusi modul dan komponen skor, serta menguji sensitivitas terhadap bobot, Top- k , τ_{filter} , τ_{accept} , δ , dan jumlah pengulangan LLM.
5. **Error analysis.** Mengelompokkan kesalahan menjadi: (a) *error* ekstraksi, yaitu entitas terlewat atau salah tipe; (b) *error retrieval*, yaitu kandidat benar tidak muncul; (c) *error filtering*, yaitu kandidat benar ditemukan tetapi dibuang; (d) *error reranking*, yaitu kandidat benar ada tetapi tidak dipilih; (e) *abstention error*, yaitu kasus yang sebenarnya dapat dipetakan tetapi ditolak; (f) *overconfident error*, yaitu kandidat salah diterima dengan skor tinggi; (g) *error* terminologi, yaitu tidak ada padanan; dan (h) *error* bahasa, seperti singkatan, *typo*, atau ambiguitas. Hasil analisis digunakan untuk menyusun rekomendasi perbaikan iteratif pada komponen dan *guideline* anotasi.

4.5 Jadwal Penelitian

Tahapan kegiatan penelitian dan rencana jadwal pelaksanaan untuk setiap tahapan kegiatan dalam penelitian ini, yang difokuskan pada Tahun II dan Tahun III, secara ringkas ditunjukkan pada Tabel 4.1.

Tabel 4.1: Rencana jadwal pelaksanaan kegiatan penelitian

Jenis Kegiatan	Tahun II				Tahun III				Indikator
	1	2	3	4	1	2	3	4	
Tahap I									
Kajian teori dan studi pustaka	✓	✓	✓	✓					Diperbaruinya referensi sebagai penunjang tinjauan pustaka
Menentukan <i>roadmap</i> penelitian	✓	✓							<i>Roadmap</i> penelitian dan draf proposal
Ujian proposal			✓						Ujian pra-komprehensif dan komprehensif
Revisi proposal				✓					Proposal yang telah direvisi dan ditandatangani tim penguji
Tahap II									
Adaptasi model CDE-Mapper			✓	✓	✓				Terbentuknya model dan prototipe CDE-Mapper untuk teks klinis panjang; naskah publikasi
Pembangunan dataset			✓	✓	✓				Dataset untuk pengujian dan pelatihan model siap digunakan
Implementasi <i>preprocessing</i> teks klinis				✓	✓	✓			Terbentuknya model untuk <i>preprocessing</i> teks klinis panjang dalam bahasa Indonesia
Implementasi inti model					✓	✓			Terbentuknya model adaptasi CDE-Mapper
Pengujian model						✓	✓		Pengujian model pada berbagai skenario uji; naskah publikasi
Pembuatan laporan akhir dan persiapan ujian tertutup						✓	✓		Draf laporan disertasi
Tahap III									
Penilaian dan kelayakan disertasi						✓			Laporan disertasi layak untuk diujikan
Ujian tertutup						✓			Terlaksananya ujian tertutup
Revisi hasil ujian tertutup							✓		Laporan disertasi disetujui oleh tim penguji

DAFTAR PUSTAKA

- Agrawal, A. (2018, December). Evaluating lexical similarity and modeling discrepancies in the procedure hierarchy of SNOMED CT. *BMC Medical Informatics and Decision Making*, 18. doi: 10.1186/S12911-018-0673-Z
- Ayuningtyas, N. W., Mufidah, P. K., Yusuf, S., Sitompul, T., & Susanti, M. I. (2025, August). Bringing Interoperability into Action: Adoption of Health Terminology Standard in Indonesia. *Studies in health technology and informatics*, 329, 83–87. doi: 10.3233/SHTI250806
- Banerjee, I., Chen, M. C., Lungren, M. P., & Rubin, D. L. (2018). Radiology report annotation using intelligent word embeddings: Applied to multi-institutional chest CT cohort. *Journal of Biomedical Informatics*, 77, 11–20. Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85035789284&doi=10.1016%2Fj.jbi.2017.11.012&partnerID=40&md5=fdba0d0aad6003b7a23cd3ac0a076ca1> doi: 10.1016/j.jbi.2017.11.012
- Bennett, A. M., Ulrich, H., Damme, P. V., Wiedekopf, J., & Johnson, A. E. W. (2023, April). MIMIC-IV on FHIR: converting a decade of in-patient data into an exchangeable, interoperable format. *Journal of the American Medical Informatics Association*, 30(4), 718–725. doi: 10.1093/JAMIA/OCAD002
- Bidgood, W. D. (1998). The SNOMED DICOM microglossary: Controlled terminology resource for data interchange in biomedical imaging. *Methods of Information in Medicine*, 37(4-5), 404–414. Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-0032441952&doi=10.1055%2Fs-0038-1634557&partnerID=40&md5=0e7135272b511982ee1152e7d9ef47cc> doi: 10.1055/s-0038-1634557
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020, July). *Language Models are Few-Shot Learners*. arXiv. Retrieved 2026-04-26, from <http://arxiv.org/abs/2005.14165> (arXiv:2005.14165 [cs]) doi: 10.48550/arXiv.2005.14165
- Chang, E., & Sung, S. (2025, October). Quantitative analysis of the comprehensiveness and granularity of biomedical terminology systems. *Scientific Reports*, 15(1), 34525. Retrieved 2026-05-04, from <https://www.nature.com/articles/s41598-025-17737-0> doi: 10.1038/s41598-025-17737

-0

- Chen, L., Fu, W., Gu, Y., Sun, Z., Li, H., Li, E., ... Huang, Y. (2020, October). Clinical concept normalization with a hybrid natural language processing system combining multilevel matching and machine learning ranking. *Journal of the American Medical Informatics Association*, 27(10), 1576–1584. doi: 10.1093/JAMIA/OCAA155
- Chen, Y., Hu, D., Li, M., Duan, H., & Lu, X. (2022, March). Automatic SNOMED CT coding of Chinese clinical terms via attention-based semantic matching. *International Journal of Medical Informatics*, 159, 104676. Retrieved 2026-04-18, from <https://linkinghub.elsevier.com/retrieve/pii/S1386505621003026> doi: 10.1016/j.ijmedinf.2021.104676
- Chu, L., Kannan, V., Basit, M. A., Schaefflein, D. J., Ortuzar, A. R., Gloriosso, J. F., ... Willett, D. L. (2019, January). Snomed ct concept hierarchies for computable clinical phenotypes from electronic health record data: Comparison of intensional versus extensional value sets. *JMIR Medical Informatics*, 7(1). doi: 10.2196/11487
- Cimino, J. J. (1998, November). Desiderata for controlled medical vocabularies in the twenty-first century. *Methods of Information in Medicine*, 37(4-5), 394–403.
- Cimino, J. J. (2006, June). In defense of the Desiderata. *Journal of Biomedical Informatics*, 39(3), 299–306. Retrieved 2026-05-04, from <https://linkinghub.elsevier.com/retrieve/pii/S1532046405001334> doi: 10.1016/j.jbi.2005.11.008
- De Barros Vanzin, V. J., De Abreu Moreira, D., & Marcondes Marcacini, R. (2025, October). LLM-based approaches for automated vocabulary mapping between SIGTAP and OMOP CDM concepts. *Artificial Intelligence in Medicine*, 168, 103204. Retrieved 2026-04-15, from <https://linkinghub.elsevier.com/retrieve/pii/S09333365725001393> doi: 10.1016/j.artmed.2025.103204
- De Lusignan, S. (2005, March). Codes, classifications, terminologies and nomenclatures: definition, development and application in practice. *Journal of Innovation in Health Informatics*, 13(1), 65–69. Retrieved 2026-05-04, from <http://access.portico.org/stable?au=phwlp03q0v6> doi: 10.14236/jhi.v13i1.580
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019, May). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understan-*

- ding. arXiv. Retrieved 2026-04-29, from <http://arxiv.org/abs/1810.04805> (arXiv:1810.04805 [cs]) doi: 10.48550/arXiv.1810.04805
- Dyaspupro, D. M. (n.d.). *drestanto/indo-normalizer: Python library untuk normalisasi teks bahasa indonesia. mengubah alay words, ekspansi singkatan, dan koreksi kata tidak baku (yg ada di kamus) secara otomatis, dengan menjaga kalimat tetap sesuai. cocok untuk preprocessing nlp* Retrieved from <https://github.com/drestanto/indo-normalizer>
- El-Sappagh, S., Franda, F., Ali, F., & Kwak, K.-S. (2018, December). SNOMED CT standard ontology based on the ontology for general medical science. *BMC Medical Informatics and Decision Making*, 18(1), 76. Retrieved 2026-05-04, from <https://bmcmmedinformdecismak.biomedcentral.com/articles/10.1186/s12911-018-0651-5> doi: 10.1186/s12911-018-0651-5
- Eslami, B., Dligach, D., Azarvash, N., De La Pena, P., Strickland, B., & Tootooni, S. (2026, February). A Hybrid Language Framework for Ontology-Based Clinical Concept Extraction. *Journal of Healthcare Informatics Research*. Retrieved 2026-04-18, from <https://link.springer.com/10.1007/s41666-026-00232-0> doi: 10.1007/s41666-026-00232-0
- Fennelly, O., Grogan, L., Reed, A., & Hardiker, N. R. (2021, May). Use of standardized terminologies in clinical practice: A scoping review. *International Journal of Medical Informatics*, 149, 104431. Retrieved 2026-05-04, from <https://linkinghub.elsevier.com/retrieve/pii/S1386505621000575> doi: 10.1016/j.ijmedinf.2021.104431
- Ferté, T., Cossin, S., Schaefferbeke, T., Barnette, T., Jouhet, V., & Hejblum, B. P. (2021, May). Automatic phenotyping of electronic health record: PheVis algorithm. *Journal of Biomedical Informatics*, 117. doi: 10.1016/j.jbi.2021.103746
- Formal, T., Piwowarski, B., & Clinchant, S. (2021). SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking. In *Proceedings of the 44th international acm sigir conference on research and development in information retrieval* (pp. 2288–2292). doi: 10.1145/3404835.3463098
- Gallifant, J., Chen, S., Moreira, P., Munch, N., Gao, M., Pond, J., ... Bitterman, D. S. (2024). Language Models are Surprisingly Fragile to Drug Names in Biomedical Benchmarks. *EMNLP 2024 - 2024 Conference on Empirical Methods in Natural Language Processing, Findings of EMNLP 2024*, 12448–12465. (ISBN: 9798891761681) doi: 10.18653/V1/2024.FINDINGS-EMNLP.726
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... Wang, H. (2024, Mar-

- ch). *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv. Retrieved 2026-05-01, from <http://arxiv.org/abs/2312.10997> (arXiv:2312.10997 [cs]) doi: 10.48550/arXiv.2312.10997
- Gazzarata, R., Almeida, J., Lindsköld, L., Cangiolli, G., Gaeta, E., Fico, G., & Chronaki, C. E. (2024, September). HL7 Fast Healthcare Interoperability Resources (HL7 FHIR) in digital healthcare ecosystems for chronic disease management: Scoping review. *International Journal of Medical Informatics*, 189. doi: 10.1016/j.ijmedinf.2024.105507
- Gehrmann, J., Dogan, A., Hagelschuer, L., Quakulinski, L., Koy, A., & Beyan, O. (2025, September). Catnip for MedCAT: Optimizing the Input for Automated SNOMED CT Mapping of Clinical Variables. *Studies in health technology and informatics*, 331, 142–152. Retrieved from <https://ebooks.iospress.nl/doi/10.3233/SHTI251390> doi: 10.3233/SHTI251390
- Gilani, K., Verket, M., Peters, C., Dumontier, M., Rocca, H.-P. B.-L., & Urovi, V. (2025). CDE-Mapper: Using retrieval-augmented language models for linking clinical data elements to controlled vocabularies. *Computers in Biology and Medicine*, 196, 110745. Retrieved from <https://www.sciencedirect.com/science/article/pii/S0010482525010960> doi: <https://doi.org/10.1016/j.compbimed.2025.110745>
- Hananto, V. R., Santoso, M. E., & Nurcahyawati, V. (2026, 4). Transformer-based text segmentation for indonesian: Benchmarking and application to abstractive summarization. *ICACS 2025 - Proceedings of the 9th International Conference on Algorithms, Computing and Systems*, 92-98. Retrieved from </doi/pdf/10.1145/3789418.3789430?download=true> doi: 10.1145/3789418.3789430
- Harris, M. R., Ruggieri, A. P., & Chute, C. G. (2003). From clinical records to regulatory reporting: formal terminologies as foundation. *Health Care Financing Review*, 24(3), 103–120.
- He, Y., Chen, J., Antonyrajah, D., & Horrocks, I. (2022). BERT-Map: A BERT-Based Ontology Alignment System. In (Vol. 36, pp. 5684–5691). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85141700244&doi=10.1609%2Faaai.v36i5.20510&partnerID=40&md5=9d09c83b913d75b7ebd6ee9094c30f6c> doi: 10.1609/aaai.v36i5.20510

- Heryawan, L., Mori, Y., Yamamoto, G., Kume, N., Lazuardi, L., Fuad, A., & Kuroda, T. (2025, April). Fast Healthcare Interoperability Resources (FHIR)-Based Interoperability Design in Indonesia: Content Analysis of Developer Hub's Social Networking Service. *JMIR formative research*, 9, e51270. Retrieved from <http://www.ncbi.nlm.nih.gov/pubmed/40257749><http://www.pubmedcentral.nih.gov/articlerender.fcgi?artid=PMC12036547> doi: 10.2196/51270
- Hong, N., Wen, A., Shen, F., Sohn, S., Wang, C., Liu, H., & Jiang, G. (2019, December). Developing a scalable FHIR-based clinical data normalization pipeline for standardizing and integrating unstructured and structured electronic health record data. *JAMIA Open*, 2(4), 570–579. doi: 10.1093/JAMIAOPEN/OOZ056
- Hossain, M. K., Sutanto, J., Handayani, P. W., Haryanto, A. A., Bhowmik, J., & Frings-Hessami, V. (2025, February). An exploratory study of electronic medical record implementation and recordkeeping culture: the case of hospitals in Indonesia. *BMC Health Services Research*, 25(1), 249. Retrieved 2026-02-11, from <https://bmchealthservres.biomedcentral.com/articles/10.1186/s12913-025-12399-0> doi: 10.1186/s12913-025-12399-0
- Hristov, A., Tahchiev, A., Papazov, H., Tulechki, N., Primov, T., & Boytcheva, S. (2021). Application of Deep Learning Methods to SNOMED CT Encoding of Clinical Texts: From Data Collection to Extreme Multi-Label Text-Based Classification. *International Conference Recent Advances in Natural Language Processing, RANLP*, 557–565. (ISBN: 9789544520724) doi: 10.26615/978-954-452-072-4_063
- Huh, S. (2025, May). Comparative Analysis of ChatGPT-4 for Automated Mapping of Local Medical Terminologies to SNOMED CT. *Studies in Health Technology and Informatics*, 327, 813–817. Retrieved from <https://ebooks.iospress.nl/doi/10.3233/SHTI250472> (ISBN: 9781643685960) doi: 10.3233/SHTI250472
- Januel, J. M., Luthi, J. C., Quan, H., Borst, F., Taffé, P., Ghali, W. A., & Burnand, B. (2011). Improved accuracy of co-morbidity coding over time after the introduction of ICD-10 administrative data. *BMC Health Services Research*, 11. doi: 10.1186/1472-6963-11-194
- John Snow Labs. (2026, jan). *Numind medical ner llm v1 (jsl_meds_ner_2b_q8_v1)*. https://nlp.johnsnowlabs.com/2026/01/07/jsl_meds_ner_2b_q8_v1_en.html. (Healthcare NLP Model 6.2.2)

- Jung, H., Park, H.-A., Kang, H., Lee, M., Sung, S., & Park, S. (2022, May). Mapping Korean National Health Insurance Pharmaceutical Claim Codes to SNOMED CT. In B. Séroussi dkk. (Eds.), *Studies in Health Technology and Informatics*. IOS Press. Retrieved 2026-04-18, from <https://ebooks.iospress.nl/doi/10.3233/SHTI220462> doi: 10.3233/SHTI220462
- Kate, R. J. (2020, November). Automatic full conversion of clinical terms into SNOMED CT concepts. *Journal of Biomedical Informatics*, 111. doi: 10.1016/j.jbi.2020.103585
- Khare, R., An, Y., Li, J., Song, I.-Y., & Hu, X. (2012). Exploiting semantic structure for mapping user-specified form terms to SNOMED CT concepts. In (pp. 285–294). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-84863248734&doi=10.1145%2F2110363.2110397&partnerID=40&md5=1bc5210945dfff6667ae7798fc552963> doi: 10.1145/2110363.2110397
- Kim, H. K., Choi, S. W., Bae, Y. S., Choi, J., Kwon, H., Lee, C. P., ... Ko, T. (2020). MARIE: A context-aware term mapping with string matching and embedding vectors. *Applied Sciences (Switzerland)*, 10(21), 1–11. Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85095684965&doi=10.3390%2Fapp10217831&partnerID=40&md5=2e1360d23e6380863f659ab842c5ff0b> doi: 10.3390/app10217831
- Kim, T. Y. (2014, August). Automating lexical cross-mapping of ICNP to SNOMED CT. *Informatics for Health and Social Care*, 41(1), 64–77. doi: 10.3109/17538157.2014.948173
- Latip, A. A., Domingo, M. S. T., Sulaiman, I. M., & Rahim, T. N. T. A. (2021, January). Automated SNOMED CT Mapping of Clinical Discharge Summary Data for Cardiology Queries in Clinical Facilities. *International Journal of Pharma Medicine and Biological Sciences*, 10(1), 8–16. doi: 10.18178/IJPMBS.10.1.8-16
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2021, April). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. arXiv. Retrieved 2026-04-26, from <http://arxiv.org/abs/2005.11401> (arXiv:2005.11401 [cs]) doi: 10.48550/arXiv.2005.11401
- Librian, A. (n.d.). *sastrawi: High quality stemmer library for indonesian la-*

- nguage (bahasa). Retrieved from <https://github.com/sastrawi/sastrawi>
- Liu, F., Shareghi, E., Meng, Z., Basaldella, M., & Collier, N. (2021). Self-alignment pretraining for biomedical entity representations. In *Proceedings of the 2021 conference of the north american chapter of the association for computational linguistics: Human language technologies* (pp. 4228–4238). doi: 10.18653/v1/2021.naacl-main.334
- Meizoso, M., Allones, J. L., Taboada, M., Martinez, D., & Tellado, S. (2011). Automated Mapping of Observation Archetypes to SNOMED CT Concepts. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 6686 LNCS(PART 1), 550–561. Retrieved from https://link.springer.com/chapter/10.1007/978-3-642-21344-1_57 (ISBN: 978-3-642-21344-1) doi: 10.1007/978-3-642-21344-1_57
- Michel, J., Lawley, M. J., Chu, A., & Barned, J. (2011). Mapping the Queensland Health iPharmacy Medication File to the Australian Medicines Terminology using snapper. In *Studies in Health Technology and Informatics* (Vol. 168, pp. 104–116). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-83155183396&doi=10.3233%2F978-1-60750-791-8-104&partnerID=40&md5=75bcd67ce55959605c8b055290e29471> doi: 10.3233/978-1-60750-791-8-104
- Michel-Picque, Sandra, B. S., Pascal, P. P., Namrata, P. N., & Guilhem, M. G. (2024). Classifier Chains for LOINC Transcoding. In *Studies in Health Technology and Informatics* (Vol. 316, pp. 1314–1318). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85202003505&doi=10.3233%2FSHTI240654&partnerID=40&md5=fa8c690204706da0789293c4ce1a7299> doi: 10.3233/SHTI240654
- Park, Y., Kang, H., Kim, J., Shin, S.-Y., Cho, D., Rhee, S. Y., ... Bae, S. (2026, March). Development and Evaluation of SNOMED CT Automated Mapping Tool: Advancing Terminology Standardization and Semantic Interoperability. *JMIR Medical Informatics*, 14, e82670. Retrieved 2026-04-15, from <https://medinform.jmir.org/2026/1/e82670> doi: 10.2196/82670
- Peters, M., Ammar, W., Bhagavatula, C., & Power, R. (2017). Semi-supervised sequence tagging with bidirectional language models. In *Proceedings of*

- the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 1756–1765). Vancouver, Canada: Association for Computational Linguistics. Retrieved 2026-04-29, from <http://aclweb.org/anthology/P17-1161> doi: 10.18653/v1/P17-1161
- Peterson, K. J., & Liu, H. (2020). Automating the Transformation of Free-Text Clinical Problems into SNOMED CT Expressions. *AMIA Joint Summits on Translational Science proceedings. AMIA Joint Summits on Translational Science, 2020*, 497–506.
- Pezoulas, V. C., Sakellarios, A., Kleber, M., Bosch, J. A., Laan, S. W. v. d., Lamers, F., ... Fotiadis, D. I. (2021). A hybrid data harmonization workflow using word embeddings for the interlinking of heterogeneous cross-domain clinical data structures. *BHI 2021 - 2021 IEEE EMBS International Conference on Biomedical and Health Informatics, Proceedings*. (ISBN: 9781665403580) doi: 10.1109/BHI50953.2021.9508484
- Purwitasari, D., Abdillah, A. F., Juanita, S., Purnama, I. K. E., & Purnomo, M. H. (2023). A Comparison of Transformer and BiLSTM Based BioNER Model with Self-Training on Low-Resource Language Texts of Online Health Consultatio. *International Journal of Intelligent Engineering and Systems, 16*(6), 213–224. Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85177423493&doi=10.22266%2Fijies2023.1231.18&partnerID=40&md5=54f4c6c96c4fecccf07a926a267dd29> doi: 10.22266/ijies2023.1231.18
- Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). *Improving language understanding with unsupervised learning* (Tech. Rep.).
- Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., ... Liu, P. J. (2023, September). *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*. arXiv. Retrieved 2026-04-29, from <http://arxiv.org/abs/1910.10683> (arXiv:1910.10683 [cs]) doi: 10.48550/arXiv.1910.10683
- Rinaldi, E., Drenkhahn, C., Gebel, B., Saleh, K., Tönnies, H., Loewenich, F. D. v., ... Thun, S. (2023, December). Towards interoperability in infection control: a standard data model for microbiology. *Scientific Data, 10*(1). doi: 10.1038/S41597-023-02560-X
- Rodrigues Jean-Marie, Robinson David, Della Mea Vincenzo, Campbell James, Rector Alan, Schulz Stefan, ... Brand Persson Kristina (2015). Semantic Alignment between ICD-11 and SNOMED CT.

- In *Studies in Health Technology and Informatics*. IOS Press. Retrieved 2026-05-04, from <https://www.medra.org/servlet/aliasResolver?alias=iospressISBN&isbn=978-1-61499-563-0&spage=790&doi=10.3233/978-1-61499-564-7-790> doi: 10.3233/978-1-61499-564-7-790
- Rouhizadeh, H., Yazdani, A., Zhang, B., Alvarez, D. V., Hüser, M., Vanobberghen, A., ... Teodoro, D. (2025, January). Large Language Models Struggle to Encode Medical Concepts — A Multilingual Benchmarking and Comparative Analysis. *medRxiv*. Retrieved from <http://medrxiv.org/lookup/doi/10.1101/2025.01.15.25320579> (Backup Publisher: medRxiv) doi: 10.1101/2025.01.15.25320579
- Ruch, P., Gobeill, J., Lovis, C., & Geissbühler, A. (2008). Automatic medical encoding with SNOMED categories. In *BMC Medical Informatics and Decision Making* (Vol. 8). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-54949095170&doi=10.1186%2F1472-6947-8-S1-S6&partnerID=40&md5=9257b1b42a8aba68247d5b7cbce91902> doi: 10.1186/1472-6947-8-S1-S6
- Rumah Sakit Islam Sultan Agung. (2019). *Kebijakan penyelenggaraan rekam medis: Lampiran daftar singkatan dan simbol rekam medis*. Surat Keputusan Direktur Nomor 154.1/PER/RSI-SA/IV/2019. Semarang, Jawa Tengah. Retrieved from <http://61.8.75.226/itblog/attachments/article/1387/lampiran%20Daftar%20Singkatan%20dan%20Simbol%20Rekam%20Medis.pdf>
- Sathappan, S. M. K., Jeon, Y. S., Dang, T. K., Lim, S. C., Shao, Y. M., Tai, E. S., & Feng, M. (2021, August). Transformation of Electronic Health Records and Questionnaire Data to OMOP CDM: A Feasibility Study Using sg_{t2dm} Dataset. *Applied Clinical Informatics*, 12(4), 757–767. doi: 10.1055/S-0041-1732301
- Schulz, S., & Cornet, R. (2009, July). SNOMED CT's Ontological Commitment. *Nature Precedings*. Retrieved 2026-05-04, from <https://www.nature.com/articles/npre.2009.3465.1> doi: 10.1038/npre.2009.3465.1
- Schulz Stefan, Rodrigues Jean-Marie, Rector Alan, & Chute Christopher G. (2017). Interface Terminologies, Reference Terminologies and Aggregation Terminologies: A Strategy for Better Integration. In *Studies in Health Technology and Informatics*. IOS Press. Retrieved

- eved 2026-05-04, from <https://www.medra.org/servlet/aliasResolver?alias=iospressISBN&isbn=978-1-61499-829-7&spage=940&doi=10.3233/978-1-61499-830-3-940> doi: 10.3233/978-1-61499-830-3-940
- Seong, Y., You, S. C., Ostropolets, A., Rho, Y., Park, J., Cho, J., ... Park, R. W. (2021, January). Incorporation of Korean Electronic Data Interchange Vocabulary into Observational Medical Outcomes Partnership Vocabulary. *Healthcare Informatics Research*, 27(1), 29–38. Retrieved from <http://e-hir.org/journal/view.php?doi=10.4258/hir.2021.27.1.29> doi: 10.4258/HIR.2021.27.1.29
- Sitaru, S., Nhan, F., Gasteiger, C., Rueckert, D., Biedermann, T., & Zink, A. (2024, October). Digitalising the past decades: automated ICD-10 coding of unstructured free text dermatological diagnoses. *BMC Health Services Research*, 24(1), 1297. Retrieved 2026-04-18, from <https://bmchealthservres.biomedcentral.com/articles/10.1186/s12913-024-11761-y> doi: 10.1186/s12913-024-11761-y
- Soriano, I. M., Pena, J. L. C., Breis, J. T. F., Roman, I. S., Barriuso, A. A., & Baraza, D. G. (2019, June). Snomed2Vec: Representation of SNOMED CT terms with Word2Vec. *Proceedings - IEEE Symposium on Computer-Based Medical Systems, 2019-June*, 678–683. (ISBN: 9781728122861) doi: 10.1109/CBMS.2019.00138
- Spackman, K. A. (2001). Normal forms for description logic expressions of clinical concepts in SNOMED RT. *Proceedings. AMIA Symposium*, 627–631.
- Sugiarto, P., Purnami, C. T., & Jati, S. P. (2024). Supporting and Inhibiting Factors in Implementing Electronic Medical Records (EMR) Policy in Indonesia. *BIO Web of Conferences*, 133, 00038. Retrieved 2026-04-13, from <https://www.bio-conferences.org/10.1051/bioconf/202413300038> doi: 10.1051/bioconf/202413300038
- Tavakoli, K., Kalaw, F. G. P., Bhanvadia, S., Hogarth, M., & Baxter, S. L. (2023, December). Concept Coverage Analysis of Ophthalmic Infections and Trauma among the Standardized Medical Terminologies SNOMED-CT, ICD-10-CM, and ICD-11. *Ophthalmology Science*, 3(4). doi: 10.1016/j.xops.2023.100337
- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., ... Lample, G. (2023). *LLaMA: Open and Efficient Foundation Language*

- Models*. arXiv. Retrieved 2026-04-29, from <https://arxiv.org/abs/2302.13971> (Version Number: 1) doi: 10.48550/ARXIV.2302.13971
- Tu, T., Loreaux, E., Chesley, E., Lelkes, A. D., Gamble, P., Bellaiche, M., ... Chen, M.-J. (2022). Automated LOINC standardization using pre-Trained large language models. In *Proceedings of Machine Learning Research* (Vol. 193, pp. 343–355). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85171421517&partnerID=40&md5=35b85b4aba9ca95f5e71956acbfd651e>
- Utomo, M. N. Y. (n.d.). *yasirutomo/text-normalization: Normalisasi teks atau preprocessing untuk data media sosial*. Retrieved from <https://github.com/yasirutomo/text-normalization>
- Utter, G. H., Cox, G. L., Atolagbe, O. O., Owens, P. L., & Romano, P. S. (2018, October). Conversion of the Agency for Healthcare Research and Quality's Quality Indicators from ICD-9-CM to ICD-10-CM/PCS: The Process, Results, and Implications for Users. *Health Services Research*, 53(5), 3704–3727. Retrieved from [/doi/pdf/10.1111/1475-6773.12981](https://doi/pdf/10.1111/1475-6773.12981)<https://onlinelibrary.wiley.com/doi/abs/10.1111/1475-6773.12981><https://onlinelibrary.wiley.com/doi/10.1111/1475-6773.12981> doi: 10.1111/1475-6773.12981
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). *Attention Is All You Need*. arXiv. Retrieved 2026-04-26, from <https://arxiv.org/abs/1706.03762> (Version Number: 7) doi: 10.48550/ARXIV.1706.03762
- Wang, X., Wei, J., Schuurmans, D., Le, Q. V., Chi, E. H., Narang, S., ... Zhou, D. (2023). Self-consistency improves chain of thought reasoning in language models. In *The eleventh international conference on learning representations*. Retrieved from <https://openreview.net/forum?id=1PL1NIMMrw>
- Wang, Z., Torres, K., Foster, H., Walker, G., Garza, M. Y., Palmer, A., ... Zozus, M. N. (2025, September). Measuring alignment between the ADRC UDS data elements, FDA, and EHR data standards. *Alzheimer's & Dementia*, 21(9), e70628. Retrieved 2026-04-21, from <https://alz-journals.onlinelibrary.wiley.com/doi/10.1002/alz.70628> doi: 10.1002/alz.70628
- Willett, D. L., Kannan, V., Chu, L., Buchanan, J. R., Velasco, F. T., Clark, J. D., ... Basit, M. A. (2018, July). SNOMED CT Concept Hierarchies for Sharing Definitions of Clinical Conditions Using Electronic Health Record Data.

- Applied Clinical Informatics*, 9(3), 667–682. doi: 10.1055/S-0038-1668090
- Wu, S., Xiong, Y., Cui, Y., Wu, H., Chen, C., Yuan, Y., ... Xue, C. J. (2025, March). *Retrieval-Augmented Generation for Natural Language Processing: A Survey*. arXiv. Retrieved 2026-05-01, from <http://arxiv.org/abs/2407.13193> (arXiv:2407.13193 [cs]) doi: 10.48550/arXiv.2407.13193
- Xiao, G., Pfaff, E., Prud'hommeaux, E., Booth, D., Sharma, D. K., Huo, N., ... Jiang, G. (2022, October). FHIR-Ontop-OMOP: Building clinical knowledge graphs in FHIR RDF with the OMOP Common data Model. *Journal of Biomedical Informatics*, 134. Retrieved from <https://pubmed.ncbi.nlm.nih.gov/36089199/> doi: 10.1016/j.jbi.2022.104201
- Xiaocheng, C. X., Erhua, S. E., & Jiali, L. J. (2022). Research on Application of Named Entity Recognition of Electronic Medical Records Based on BERT-IDCNN-CRF Model. In *ACM International Conference Proceeding Series* (pp. 80–85). Retrieved from <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85145553650&doi=10.1145%2F3561518.3561531&partnerID=40&md5=a18181ac29d1c3baa2859dca76f744ec> doi: 10.1145/3561518.3561531
- Yu, S., Cho, E.-J., Kim, S., Park, K., Kim, M.-S., Oh, Y., & Ryu, H. (2026, April). Large Language Models' Performances regarding logical observation identifiers names and codes mapping in laboratory medicine: A comparative analysis of ChatGPT-4.0, Gemini, and Perplexity. *International Journal of Medical Informatics*, 209, 106270. Retrieved 2026-04-21, from <https://linkinghub.elsevier.com/retrieve/pii/S1386505626000109> doi: 10.1016/j.ijmedinf.2026.106270
- Zahra, F. A., & Kate, R. J. (2024, January). Obtaining clinical term embeddings from SNOMED CT ontology. *Journal of Biomedical Informatics*, 149. doi: 10.1016/j.jbi.2023.104560
- Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., ... Wen, J.-R. (2026, March). *A Survey of Large Language Models*. arXiv. Retrieved 2026-04-22, from <http://arxiv.org/abs/2303.18223> (arXiv:2303.18223 [cs]) doi: 10.48550/arXiv.2303.18223
- Zhou, D., Gan, Z., Shi, X., Patwari, A., Rush, E., Bonzel, C. L., ... Cai, T. (2022, September). Multiview Incomplete Knowledge Graph Integration with application to cross-institutional EHR data harmonization. *Journal of Biomedical Informatics*, 133, 104147. Retrieved from <https://www.sciencedirect.com/science/article/pii/>

S1532046422001599 doi: 10.1016/J.JBI.2022.104147

Zhou, X., Dhingra, L. S., Aminorroaya, A., Adejumo, P., & Khera, R. (2024). A Novel Sentence Transformer-based Natural Language Processing Approach for Schema Mapping of Electronic Health Records to the OMOP Common Data Model. *AMIA ... Annual Symposium proceedings. AMIA Symposium, 2024*, 1332–1339.